

DataFun. 系列电子专题书

数据产品专题第 1 期

独家资料

数据产品经理 学习手册

产品工具 用户画像 数据分析

数据产品经理在线峰会专享



目录

活动专题数据产品建设	1
全链路市场投放的数据产品策略	17
挖掘客户意见，驱动经营改善	40
比你更了解你，浅谈用户画像	63
用户画像场景与技术实现方案	91
网易数据部用户画像实践	113
网易严选画像建设实践	133
数据驱动消费者精细化运营产品和生态	150
百信银行用户-产品-企业经营多维分析实践	174
如何搭建数据指标体系	198
如何建设好的数据指标体系	214
数据安全工具建设经验分享	238
如何提升数据化管理效率	263
网易数据治理工具-资产 360 产品实践	276
数据中台的底层逻辑	293
数据产品+数据中台双引擎模式实践	312
“转变”，贝壳找房数据平台演变之路	325
专业数据准备工具的介绍和应用	347



活动专题数据产品建设



活动专题数据产品建设

王媛媛 快手 数据产品经理



分享嘉宾：王媛媛 快手 数据产品经理

编辑整理：冯敬舜 神策

出品平台：DataFunTalk

导读：活动作为一种有效运营手段，因其能够在短期内带来高收益而被广泛应用，尤其是被用在各互联网平台。快手作为多业务综合性平台，不仅可以兼容目前主流所有活动形式，还能够多业务协助共建大型活动专项，但随着活动的运营开展，业务的关注重点也从是否达成目标转变为了如何在预期 ROI 下达成目标。快手的活动数据产品通过统一活动分析思路、提供一站式产品服务，对外提升业务运营决策效率，对内提高数据支持效率，助力活动目标达成。



本文将介绍快手活动专题数据产品建设。内容分为四个部分：

- 业务背景
- 产品定位
- 产品设计
- 拓展应用

01

业务背景：活动业务分析

1. 平台视角

平台类的产品都会开展大量的运营活动。从平台举办活动的目的与活动运营的方向看，这些活动大致分为如下几个方向：用户增长、业务促进、用户互动和情感共鸣。



业务背景

- 从平台视角来看，常见活动类型按运营方向可分为：用增、业务促进、互动与情感共鸣



用户增长活动，常见的包括裂变、组队、助力等，目标是获取新用户，拉长用户生命周期，提升用户规模。业务促进活动，常见的有满减、折扣、限免、首单优惠等，目标是吸引用户消费，提升交易规模或业务服务规模。用户互动活动，包括转评赞、参与话题、创作等，目标是促进平台内互动，提升用户粘性。情感共鸣，常见的有总结报告、主题晚会等，目标是提升用户对平台认同，形成自发传播。

在用户增长和业务促进类型活动的在线期间，能够看到明显数值增长效果，比如用户规模量是否扩大、用户活动率提升，电商 GMV、内容 VV、TS 是否增长等。而互动和情感共鸣类型活动则相对需要较长的运营周期，业务目标是选择与用户匹配契合的运营方式，通过活动跟用户产生共鸣从而逐渐影响用户心智，让用户对平台产生粘性。

2. 用户视角：用户、创作者、商家都是我们的服务对象



业务背景

- 从用户视角来看，活动主要收获包含：权益、服务、情感
- 以短视频平台为例，活动中除平台与用户外，还有不同角色的参与



从用户视角来看，用户参与活动，主要目的是收获权益、获得服务或者满足情感。为了满足用户的目的，平台还需要商家跟创作者一起参与进来，比如短视频平台通过平台提供用户权益与服务，分发创作者提供的内容、商家提供的商品给用户。

而创作者与商家，既是我们的合作者，共同参与活动来给用户提供好的体验；同时，商家、创作者等也是我们的服务对象，我们会通过 ToB 的服务为创作者与商家提供的数据产品，这两者其实是能够有商业化变现的一种产品。

02

产品定位



公司内部数据产品，主要是服务于参与公司内部的活动运营相关的同学，对此我们通过梳理运营同学的工作流来进一步明确产品定位，如下图所示：

产品定位

- 内部活动运营的主要工作流程：


• **活动沉淀**：有没有效果好的活动方案可沉淀？活动过程中有没有优质的活动包可持续运营？

• **目标管理**：活动目标达成是否有风险？要不要追加资源？

• **触达用户**：在最小成本下如何实现最佳触达转化效果？

• **参与活动**：用户是否看到了活动？参与热度如何？

• **方案调整**：活动难度是否过高/低？要不要替换调整任务门槛？



• **ROI目标**：严控预算情况下预计能获得多少收益？

• **业务目标**：选择什么指标？预计能够达到多少数值？

• **活动各阶段安排**：是否拆分活动阶段？阶段小目标如何设定？

• **活动参与路径设计**：活动的主线、支线如何设计？选择什么类型产品/运营/营销方案？

在各运营 workflow 环节中，业务都要做很多的思考和决策，数据产品的定位是帮助他们提升决策的效率和质量。具体来说，我们通过数据产品服务业务运营，协助解决他们所处问题场景下各种数据相关问题，比如确定运营目标、运营预算管理、运营过程数据监控、运营结果数据等。

理想情况如下图，在六个环节中用户都能高效获取数据，并做出决策。我们以此为目标来找到产品迭代的重点和方向。



产品定位

业务理想态



产品愿景：业务理想态最终目标

产品定位：目标场景 + 目标用户 + 目标问题

产品主线/目标/版本规划：服务现状到理想态的距离，根据优先级拆分多个阶段实施落地

一个数据人的自留地
SHU JU REN CLUB

DataFun.

03

产品设计

这部分谈一下产品设计的三个方面：

- 数据指标体系设计
- 产品交互能力设计
- 主线版本迭代设计

数据产品从内容角度来讲，核心是数据指标体系设计，在不同的公司会有不同的角色来设计数据指标体系，基本上是数据分析师和数据产品来做。另外产品的交互能力和版本迭代，需要结合公司发展情况、组织形式来确定。



1. 数据指标体系

■ 产品设计-数据指标体系

- 如何建设好的数据指标体系-OSM方法论



运营活动的指标体系适合采用 OSM 方法。如上图：从目标、策略到业务度量来分层设计指标体系。

活动首先要明确目标。以快手为例，业务主要在两方面：核心业务场景是短视频和内容，其次是电商业务。我们的北极星指标可以分三类：活跃、内容消费和电商消费。

目标明确后就要做策略设计：按达成目标找到业务和用户的触点，即哪些环节能让用户参与进来，从而找到一个活动参与路径。

一般来说我们通过内外渠道投放去触达用户，然后用户进入活动页面，参与产品设计的主线活动跟支线活动。用户在自己参与的玩法里，通过一些设计吸引用户，比如闯关活动、集卡或者 PK 等，引导用户完成任务获得奖励。奖励可以是电商券，也可以是内容会员等，而这些



激励又可以促进电商跟内容的消费。策略调控本质上来讲是围绕着目标达成和成本控制这两块进行均衡。

目标策略明确后，依赖数据指标体系来衡量策略表现的好坏。同时也提供制定策略所需数据，优化策略提升能效，比如流量分析中包含了触达、分发，这个环节我们主要是提升触达分发的效率；在互动和任务完成环节，我们会根据实际情况提供分析方法，让运营能够发现活动表现的差异在哪里，用户对不同权益的兴趣差别有多大。具体交付的可以是一个看板、一个分析体系，还可以是一个归因下钻分析让用户能按照维度拆解问题表现数据，做自助探索性分析。

产品设计-数据指标体系



上图是实际工作中，根据 OSM 落地的活动指标体系的架构图。

最上层是业务目标，第二层是活动参与的行为路径，第三层开始设计具体的策略，下边蓝色的部分就是业务度量。最底层是数据指标体系，按照用户的行为路径的六个环节从上到下分别设计的指标体系。




2. 产品交互能力

■ 产品设计-产品能力交互

- 产品结构示例



- 平台交互示例



一个数据人的自留地
SHU JU REN CLUB

DataFun.

不同平台会根据自己的产品定位来设计产品交互。

快手的活动平台定位有三大部分：活动信息管理、活动分析、活动沉淀。其中活动分析部分会有较多的交互，其他两个部分用户在交互上感知并不强烈。数据进入到活动平台后，我们会把信息管理起来，让数据能够在分析模块便捷的使用，比如活动复盘环节，需要用到活动设计、活动过程中的各样数据。另外通过指标体系跟策略模型把数据沉淀下来，在之后的活动设计中能基于沉淀做效果提升的迭代。信息管理的一个重点是把数据跟其他平台协同使用起来，API 层面的交互能力非常重要，另外在产品上要方便用户快速在各个系统、平台之间跳转跟切换来完成用户的工作流。

3. 产品主线版本迭代



产品设计-主线版本迭代



一个数据人的自留地
SHU JU REN CLUB

DataFun.

产品的迭代基于一个主线：业务的理想态跟现状存在差异，而迭代就是不停地发现差异，然后抹平差异的一个过程。

业务方最大的诉求和痛点，就是我们迭代的主要指引。在满足业务诉求的同时，我们会把数据沉淀积累下来，让业务使用数据的能效不断提升：从简单的数据看板、指标体系再到归因分析等。再往上我们还会尝试跟上下游的平台打通，协同发挥更大的作用，比如跟推荐平台、策略平台的打通。因为在活动中，需要各个平台协同才能高效完成活动。



04

拓展应用

接下来针对重点项目，来讲一下实际活动中的应用。比如，每年双 11 是一个重大的活动，此外还有其它一些重要活动，如春节等节假日中平台的运营活动。

针对活动的特点，参与到活动的角色的诉求来设计产品形态。如下图：

产品拓展-重点项目实践

- 分类场景选择展示终端

用户类型	数据需求方向	数据大屏（敏感+氛围）	移动端（高敏感）	PC端（分级控权）
		* 指挥室/集中办公区氛围感营造	* 随时随地/非办公区域	* 深度分析/精细化运营
管理者	- 目标监控 - 下发决策	- 目标监控 - 下发决策 - 活动氛围	- 目标监控 - 下发决策	——
调控执行者	- 接收决策并落地 - 监控用户行为 - 策略调控 - 数值效果优化	- 接收决策并落地 - 监控用户行为 - 活动氛围	——	- 接收决策并落地 - 监控用户行为 - 策略调控 - 数值效果优化
普通参与者	- 活动氛围 - 活动效果感知	- 活动氛围 - 活动效果感知	——	——



在这些活动中，管理者主要的诉求是目标的监控和决策的下发，另外管理者会随时随地看数据，所以适合他们的产品是移动端的高度敏感的数据驾驶舱，一个大盘的监控。

他们的决策会传达给调控执行者，这部分用户诉求是要求数据保持管理者的视角，方便快速去了解管理者的决策意图然后高效地调整策略。



他们既需要看到数据大屏，还需要看到更明细的执行数据，我们通过 PC 端的数据专题来帮他们解决这方面的诉求。

对于普通参与者来说，对活动付出了很多，需要去感受一下活动的氛围和效果。我们会把数据放到氛围大厅和集中办公区，打造一个活动氛围感，让大家通过一些数据来感受活动氛围。

05

精彩问答

Q：怎么让数据治理工作能够内嵌到开发工作当中，而不是多出来的一项工作？

A：很多业务在使用数据的时候，是只开发不治理，这种方式会遗留下来不少需要治理的问题。很难避免要去单独做数据治理。如果在业务开发初始阶段就把数据规范、指标体系、指标口径有一个规划设计，并且按照规范落实，那么后续会减少很多治理的动作。

比如一开始创建表的时候，就要指定好是否分区表、数据的生命周期，到期后就可以自动删除，也不会涉及这个表占用了多少存储，需要额外梳理跟确定是否需要下线的工作。

Q：请问活动的投入预算和产出预测是用什么方法来进行确定的？



A: 常规来说, 前期的活动预算是给定的。公司一般会有一个先期预算, 随着活动进行, 可能会追加。对于产出预测来讲, 首先回到活动目标。不同的目标会有一些衡量产出的方法, 比如新增一个用户, 会计算整用户生命周期价值, 能带来多少 GMV 等, 从而产生一个粗略的公式, 其中会涉及到业务拆解。另外也会利用到前期积累的经验, 同类型活动, 大概的转化率, 能覆盖什么范围的用户。这里会涉及到历史活动的积累跟预测。第二块就是需要对大盘水位的一些预测, 比如去年一个活动投入了 100 万, 获取到了 10 万用户。今年大盘涨到了 100 万, 不同的基数根据业务特色要做不同的预测。总体考虑活动规模然后折合成价值, 就是一个大概的产出预测。

Q: 是否做过全流程的效果评估, 比如说一些电商活动, 活动流量跟用户购买成交之间的关系分析评估?

A: 其实当前我们分析的链路的话没有那么长, 一般对于 GMV 交易转化, 我们会从两方面计算。首先从触达的规模效果来分析, 比如分析优惠券的发放效果, 然后再去拆分并分析它对于交易的引导转化。从整个链路来讲, 会有一个大的漏斗, 先去看整个渠道触达了多少人, 然后每个漏斗做下钻分析, 比如看不同渠道的转化差异, 然后优化整体的漏斗转化。

Q: 数据产品周期会经历哪些阶段, 数据产品搭建指标体系跟商分的指标体系有没有本质上面的区别?



A: 数据产品的周期跟业务周期类似，用户端的产品有衰退期的概念。数据产品的衰退期不像 C 端产品那么明显。会有初期、成长期，比如随着业务场景的发展，活动产品也会随着变化发展，因为会涉及到业务的方方面面，甚至会有 PR、财务的需求等。各方都会提需求过来。另外随着业务策略的迭代，数据产品也会跟着迭代变的更加智能跟实用。

指标体系这块，数据产品跟分析师是互相合作的关系，从分析师角度来讲，他需要一个分析框架；对于产品来说，要能够在产品上沉淀迭代数据指标，比如策略的迭代需要一个稳定合理的指标体系来支撑。指标体系结合了分析体系跟用户路径，分析师可能会侧重于优化分析算法模型，产品会侧重指体系的应用比如说可视化跟交互分析能力。

Q: 不同的活动方案叠加一起时，如何区分不同活动的影响权重？

A: 用 DAU 为例，活动会有一个归因口径，比如 DAU 到底时通过哪个玩法拉来多少人，这都有一套标准的归因算法。对于不同的活动，它的拉新规模裂变系数可以计算对比。

另外对于不同的活动，还有自己独特的小目标，比如集卡带来的裂变效果不明显，但是带来的留存效果很好；PK 这种玩儿法，留存一般但是拉新很好。所以，我们既要看到对 DAU 的贡献，也要看单独的小目标达成效果。如果一个活动的小目标达成效果很好，那么大目标的



贡献效果只是作为一个参考，因为小目标是更具体更可衡量的一个目标。

今天的分享就到这里，谢谢大家。扫码观看本文视频回放。





全链路市场投放的数据产品策略

网易严选 | DataFun.

全链路市场投放的 数据产品策略

宋腾辉 网易严选 用户数据产品负责人



分享嘉宾：宋腾辉@网易严选

编辑整理：黄乐平

出品平台：DataFunTalk

导读：企业数字化转型的战斗正酣，释放数据价值成为企业当前的核心任务。本次分享主要关于网易严选内部的业务型数据产品，通过贴近严选投放场景以及业务需求落地搭建了面向内部的全链路市场投放平台数据产品，同时也将分享严选在产品设计中通用的方法论。

今天的介绍会围绕下面四点展开：



- 网易严选业务背景
- 全链路投放数据产品建设
- 场景化数据产品建议
- 后续答疑

01

网易严选业务背景

网易严选的业务背景主要想让大家来认识一下严选以及严选市场投放的特点，以及该业务形态下对数据的诉求。

网易严选是一家自营全品类的精品电商品牌，覆盖了从商品的研发、生产、采购、物流、仓储、销售、配送，最后到消费者手中的环节。整个链路过程其实是比较长的，所以严选更需要能够利用数据去帮助业务提升决策的效率。



网易严选作为品牌广告主而言，在市场投放生产关系过程中，会和很多行业内的广告投放平台或者与品牌基调相符的媒体进行合作，包括抖音、微博等信息流；小米、华为等应用商城；网易内部云音乐、邮箱等渠道。网易严选在上述提及的媒体上会去设立账户同时进行有预算的广告投放，利用这些媒体渠道给严选拉新、促活及转化增长。





1. 严选市场特点

整体严选市场的特点包括三个方面：

- 多渠道+多代理。因为严选的渠道方较多，但市场投放的同学人力有限，所以会在投放的过程中通过代理方式结合数据转化择优选取；
- 投放考核多面且标准严格。严选在考核过程中会考虑 ROI（投入产出比），除了前期投入的成本估算，还包括整体投放后的中长期转化；
- 投放随业务发展动态调整。前期严选会注重用户的规模，到发展中后期也会将重心从用户的”量”到用户的“质”，追求长效发展。



2. 严选市场投放数据诉求



严选根据市场投放的特点，市场投放业务场景对数据侧提出的诉求抽象为四个方面：

- 安全：安全一方面指的是与内外部媒体进行投放而产生数据交互，其过程中发生转化的用户是公司重要的数据资产。其实严选本身也有非常丰富的数仓团队和数据产品团队，所以在投放的过程中不倾向于对接内部的数据服务商。另一方面指的是在投放场景中，需要做好场景的风险监测和预警工作，例如规避在拉新场景过程中吸引一些“羊毛党”，造成优惠力度权益的“浪费”。
- 高时效：广告投放是一个时效性非常高的业务过程，不论是与媒体端的交互还是内部归因，必须满足高时效的要求，才能够帮助业务去实时调整投放的策略。
- 业务全面：网易严选覆盖的业务面较为广泛，需要考虑多方面的业务环节。
- 链路完整：基于严选的自营电商的背景，覆盖了电商所有的链路环节，与投放相关的因素需要考虑齐备。



02

全链路投放数据产品建设

严选投放全链路数据产品设计思路基于上述提及的业务场景对数据所提出的诉求，具体包括：

- 安全加高时效。为了满足安全加高时效的要求，严选在设计的过程中自接入了 30+ 的媒体，自建了激活归因、订单归因以及风控监测。
- 业务场景全面。产品设计过程中自建了丰富的指标评估体系和投放分析体系，涵盖了外部渠道核心因素以及内部电商常规分析的人、货、场三个核心因素。



- 业务链路完整。一方面，指的是从媒体前端投放到严选后端转化的一个链路完整性，即投放端和转化端的关联。另一方面，指的是严选内部投放业务，从立项、计划、投放、结算全链路场景设计的完整性。

综上，严选投放全链路数据产品设计思路核心主要做了三件事，其一是投放的归因体系，其二是投放的指标评估体系，再者是投放的分析体系。



下面详细展开在三个核心体系上的实践。

1. 严选投放归因体系

严选是一个有着 APP 端和 PC 端的自营电商。在客户流量上，严选会更加偏向于沉淀 APP 端的用户，因为后续的转化以及



长期的生命周期价值更高。因此当前在投放过程中，严选会引导用户下载 APP 为主，直接引导用户发生转化为辅。

基于这样的一个主辅关系，严选的归因体系就需要建设包括激活归因以及订单归因两个方面。而归因的核心元素包括场景、优先级以及效期三个点，特色就是会更加贴近严选的投放场景。

对于场景而言，严选会细化典型场景，例如判断用户终端归属问题，即是否在 APP 端或非 APP 端内下单；判断用户访问支付的方式，包括同端或者跨端；若为跨端的方式，则会判断是用户自发行为，还是扫码、唤起等行为。通过层层细化，严选能够真正了解用户的行为转化对应的场景。

对于优先级而言，严选与业界相同采用的是最终点击（last click/visit）。

对于效期而言，严选会考虑封闭 APP 内的效期较短，非 APP 内效期适当加长，这里主要是考虑到用户对 APP 的粘性和感知力会更强一些。并且由于严选投放的角色是一个广告主的角色，所以在广告的效期设置上比常规广告平台效期设置稍微短一些。



2. 严选投放指标评估体系

在业务发展过程中，首先是确立业务的发展目标，包括制定业务战略目标以及业务执行策略。其次，搭建指标体系，包括 KPI 指标以及业务执行指标，KPI 指标对应上一过程中的业务战略目标，业务执行指标对应的是业务执行策略，最后才是去落地执行。这个思路它不仅仅局限于投放场景，而是一个通用数据产品指标体系搭建的思路。具体实操如下：

① 拆分目标

首先，如果业务是多过程，先拆分为单过程，再区分指标的具体分类，包含规模类（诸如支付用户数）、效率类（诸如户转周期）、质量类（诸如复购频次、用户留存）等指标分类。其次，结合战略战术目标去拆分核心类指标、非核心类的指标，映射到战略层和战术层。最后还要注意，业务链路的过程性指



标分析也非常重要，能够基于此清晰定位哪一步的漏斗环节发生了问题。

② 目标的交叉验证

第一步完成后，初步的指标体系已基本完成，如何真正有效去反映业务的发展，需要对指标体系进行验证。并且在验证过程中，可能会存在阶段性目标调整的情况，所以实际上就是验证与确定目标的不断交互。

举个例子，严选有个时期，投放核心指标除了拉新规模外还有新用户的一个首单质量，包括首单成本和首单流水 ROI。但通过数据交叉验证，团队会发现低价的商品能够保证较低成本吸引用户，但并不是高质量的用户，往往吸引一些薅羊毛的低质量用户群体，后续的价值流水转化很低。基于观测到的数据结果结合业务发展过程，投放目标逐渐从用户首单质量逐步调整为用户中长期的贡献质量，在不断的调整优化过程中，不断设立指标确认业务目标，将建议反馈给业务方，形成一个良性自增长闭环。



3. 严选投放指标体系实践

基于上面的指标体系设计思路完成了严选投放场景下指标体系建设，以现阶段指标体系的实践举例：



严选今年拉新场景投放目标主要是保证拉新规模达标的前提下，达成用户中长期的流水价值。业务侧将这个战略目标拆分



成了三个可执行的战术目标——保证成本的拉新规模目标、用户的短期流水价值目标、中期用户从首单转化成三单的目标。这些直接反映目标的指标，即为我们的核心指标。在核心指标的基础上，结合上文提到指标体系分类思路，严选同样侧重规模类、质量类以及过程类的指标分类。

- 规模类包含支付用户数、新增用户数等；
- 质量类包含用户价值、投入产出、用户健康度、风控等；
- 过程类包含电商的链路追踪，包括访问-注册-支付、访问-商品详情-加购-支付等。

严选整个市场投放指标体系能够把从严选外部曝光、点击的前置链路，到内部激活、注册、付费、留存全过程完整反映出来。

4. 严选投放分析体系



分析体系的设计思路是一个不断进阶的过程，包括从“业务发生了什么”，对业务问题进行基础描述性分析；再到“为什么发生”（诊断性分析），即当数据存在波动或者异常进行诊断分析；到“什么将会发生”（预测性分析），即基于历史积累用户数据对未来进行预测，结合预测的结果给业务中长期发展作参考；最后到“最后如何指导业务决策”，即决策性分析。核心介绍一下诊断性分析和预测性分析：

① 诊断性分析

指的是探索问题发生的根源。举个例子，针对异常诊断而言，是将业务核心关注点以及专家经验沉淀下来反哺于业务。如图所示，异常可能有正向或负向两类，严选针对每一个投放渠道进行异常的拆解，下钻到每一个影响因素。这个工具可以很高



效地帮助业务将问题定位到具体某个出错的环节；如果是正向异常就可以强加利用，如果是负向异常就及时调整。




② 预测性分析

指的是从历史的数据中去探索规律，识别未来可能的风险或者是商机。以严选渠道拉新为例，如果说只是单一考虑将用户拉来，这个成本可能在用户购买首单或者前几单都无法达到损益为正，但可以设置了一个 $ROI > 0$ 的时间目标。

举个例子，严选有一段时间的目标是新用户在未来 365 天内贡献的履约毛利能够使 $ROI > 0$ 。为预测该目标在未来能否达成，利用的是用户的历史积累数据，包括流水特征、支付特征、流量特征、时间特征等进行预测，利用算法帮助业务了解投放中长期转化效果。



如图所示，严选针对每一个渠道，关注用户在 T（当天）、T+7（周）、T+28（月）、T+365（年）的 ROI。除此之外，以 T+365 为例，严选会帮助业务去监测哪些渠道提前完成目标，哪些渠道离目标较远，业务基于此进行相应调整或者保持相同投放策略。除此之外，预测性分析常被用于电商环节提升用户粘性。例如不少电商采用“省钱月卡”或者“首单 0 元领”等运营策略，其核心是希望用户在未来中长期有一个比较好的复购表现。基于上述的预测性分析产品，能够帮业务去提前了解到运营的效果。




对于业务的决策进阶是数据产品的一个终极目标，但是到底能否介入决策，主要取决于业务。当业务的决策模式能够抽象形成通用方法论，产品化方案是可行的，例如上文提到的业务将 T+365 的 ROI=1 作为目标，是可以利用数据辅助业务进行决策，但也存在一些业务场景不太好提炼。所以，除了决策性分



析以外，严选为了将数据发挥最大的价值，将数据放在整个业务链路每一个环节，让数据更好地辅助业务，帮助业务提效。

比如：

- 投放前立项，通过将核心指标抽象出来，辅助于领导层进行立项计划审批；
- 投放前计划管理，通过线上化规范生成投放链接，事前打标，事后分析；
- 投放中干预，通过诸如用户总线串联等策略提升转化率，例如用户在外部广告投放的时候看到商品，能够直接进到主站后购买这个商品，最短路径的方式去完成转化；
- 投放后费用管理，通过数据去支持严选百万级月度计算以及报销支撑。同时在结算的过程中，基于严选风控数据，给业务方在结算时一定的费用扣减等建议支持。




5. 严选产品应用实践

综上，为了满足业务对投放场景提出的安全高时效、业务全面、链路完整的诉求，严选基于其自有数据、媒体上报数据及通过 MarketingAPI 接入数据，搭建了严选的投放归因体系。结合严选的战略战术目标制定指标体系，包括 KPI 指标以及日常监控指标，对应战略层及执行层。在此基础上，进一步基于严选电商自营的特性，抽象了所有影响投放的因素，搭建了包含基础性分析、诊断性分析、预测性分析的分析体系，不断迭代升级的同时将数据建议输出给业务方。上层的数据产品应用落地方面包括 PC 端以及 APP 移动端，方便业务侧随时随地查看投放效果。



如下有一些严选在产品应用实践上的落地举例：左上角产品为严选在异常诊断上的落地；中间为用户主路径的漏斗转化，从访问、商详、购买、下单、付款到支付的全链路流程；左下方为画像分析中地域性分析；右侧为移动端数据产品，这里截取的是关于不同渠道的投放效果，因为方便易用获取了领导们的大力认可，后期也是在不断迭代优化的过程中，涵盖更多具体的场景分析，并推广到各个业务线，从而满足业务所见即所得的诉求。



03

场景化数据产品建议

产品一般都非常了解用户体验五要素，其实用户体验五要素与严选数据产品设计思路也不谋而合。

第一层是战略层，需要业务先行制定业务战略和战术目标；

第二层是范围层，需要确定指标体系，包括具体的分类（核心/非核心、规模类/工程类等）以及按递归验证的形式去做指标体系和目标的校验；

第三层是结构层，需要在分析体系中确认业务核心影响因素，结合业务场景分析影响业务的因素维度；



第四层是框架层，是从基础监控、分析诊断到决策建议的进阶流程；

第五层是表现层，即将下面的四层（战略层、范围层、结构层、框架层）确定的内容展现到用户面前，做到直接、方便使用。

整个设计过程需要时刻去考虑对业务链路覆盖的完整性，这样才能牢牢地吸引产品对应的用户来提升产品的使用率和价值的发挥。



在严选数据产品构建的过程中，形成了一个感悟，即数据产品价值体现在数据使用者手中，越到高层越体现价值。在此基础上提出了一些建议：



- 在做数据产品的过程中，需要真正的深入业务，贴近业务场景设计帮助业务解决问题的产品，从而得到业务的认可和使用；
- 在业务侧多进行宣贯，给业务做指导，培养业务系统思维。在实际操作过程中，许多功能的上线业务并不感知，不知道哪些工具能帮助解决业务痛点和诉求，所以更要加强对业务的宣贯；
- 向上输出，抓住目标高层用户，对业务的决策指导才会更加直接并且快速，也容易获得高层用户的推广和宣传。



业务场景化数据产品构建的建议

2020 年终·大会
DATAFUNITALK

 网易严选



数据产品价值体现在数据使用者手中
越到高层越体现价值



Tips:

- 深入参与到业务过程中
- 多宣贯，培养业务系统思维
- 向上输出，抓住目标高层用户

归根到底，数据产品是一个需要沉住气静下心来做的一个工作，耐得住寂寞才能守得了繁华，数据能够给我们带来无限的可能，祝各位互联网数据人走得更远攀得更高！



04

后续答疑

1. 诊断性分析类似于归因分析，严选是采用通用的分析框架还是也包含了个性化算法在内？

答：诊断性分析类似于归因分析，其核心是一个通用的分析框架，但严选会把业务核心关注诊断的点进行抽象，固化到数据产品内。业务基于数据去进行查找分析投放中的问题，通过层层下钻找到真正影响异常的因素。个性化算法是在预测性分析中，结合了用户的历史相关数据去进行算法推导，评估用户中长期价值。

2. 严选是否有其他的数据产品，例如知识图谱等？

答：严选面向业务场景的数据产品还是比较多的，例如面向商品端的数据产品、面向供应链端的数据产品、以及营销一体化的数据产品，还包括一些公司级底层数据产品支撑。

3. 马尔科夫模型在归因分析中是否有应用？

答：马尔科夫模型在投放分析体系中没有应用。马尔科夫链主要是解决用户可能在多个场景被触达的归因问题。在严选实际的业务过程中，投放链路流程并不是特别复杂，而且按



历史探查的数据，拉新投放场景下用户被多次投放干预的比例较小。在严选内部，除了有投放归因还有触达归因。触达归因指的是针对已经在严选的用户，去提升用户的复购转化。严选会根据不同的触点对用户进行 Push 短信等干预，这里主要采用时间衰减权重+个性化场景个性化分配权重的思路，也没有用到马尔科夫模型这种较为复杂的模型。马尔科夫模型主要适用于类似淘宝、京东等复杂流量入口的场景。归因分析应该基于业务属性，核心还是把复杂问题简单化数据化，也要考虑减少业务的理解成本。

今天的分享就到这里，谢谢大家。扫码观看本文视频回放。





挖掘客户意见，驱动经营改善



京东零售数据算法通道
JDR DATA ALGORITHM CHANNEL

DataFunTalk

2021

挖掘客户意见，驱动经营改善



焦文健 京东零售 数据产品专家

分享嘉宾：焦文健 京东零售 数据产品专家

编辑整理：吴祺尧 加州大学圣地亚哥分校

出品平台：DataFunTalk

导读：现在大家越来越重视用户研究。一个公司成功的核心要素首先要去确定目标市场的需求和需要，并且要能够比竞争对手更好地提供顾客满意度。本次分享会从产品和业务的角度去展示在实际京东的业务场景下文本挖掘技术是如何发挥作用和价值。

今天的介绍会围绕下面四点展开：

- 客户意见的重要性
- 文本挖掘方案及架构



- 场景化产品洞察方案
- 应用案例

01

客户意见的重要性

用户研究的重要性

DataFunTalk


- 一个公司要想成功，就必须精确的确定目标市场的需要和需求，并比竞争对手提供更好的**顾客满意度**。
- 驱动在市场营销者与顾客之间营造成功关系的四大因素：顾客价值、**高水平的顾客满意**、高度的顾客信任感和建立一套顾客维持体系。

——《消费者行为学》Leon · G · Schiffman

- IDC研究发现，擅长用户研究，并收获良好客户体验的公司**收入比竞争对手高出4-8%**；卓越的体验可将**客户生命周期价值提高6-14倍**。

市场营销的成功四大要素中，基本上都是围绕着顾客价值、顾客满意、顾客的信任感和顾客维系体系来建立。在 IDC 的研究中发现在擅长用户研究并收获良好客户体验的公司中，它们会比竞争对手的收入高出 4% 到 8%。



京东主要经营电商业务，我们也研究了用户买单的动机。传统上商品基本上围绕着客户核心功能上的需求来进行销售。现在越来越多的商品对概念进行了延伸。除了核心的物理功能外，如外观设计、售后、配送服务等构成了中间的形式层面的产品。在最外层，在精神层面，商品需要和用户进行更深入的交流，属于附加产品。基本上任何一款产品想要成功都需要在这三个层面上有不同程度的完善。




我们如果仅仅针对用户的行为进行分析，比如通过浏览、点击、收藏、加购等，还不能完全满足对消费者的刻画、理解以及认知，具有一定的局限性。它无法去捕捉客户的主观意见，难以对用户心智层面进行洞察。在电商的环境下，用户的行为分析更多的是分析用户在下单前、购买前的用户行为数据，但是在用户购买产品后的使用体验是用户行为无法捕捉到的。这更多地需要使用用户的评论，售后的咨询或者与客服的电话沟通中的文本信息进行分析。对于文本的通用分析有较高的门槛，在未来潜力巨大。根据 IDC 的研究，整个结构化的数据目前只占到全部数据量的 20%，另外 80% 会以文件的形式存在。这种非结构化的数据增长非常快，所以未来有很大的潜力。

02

文本挖掘方案及架构



每天有近五亿的用户活跃在京东的平台上，每日新增的评价、咨询、搜索等信息达到几千万条。这背后蕴含了大量的文本信息，我们希望能从中挖掘用户的根本需求，即他们在使用一款产品后会用到什么，遇到什么样的问题，还有哪些方面还没有得到需求上的满足。这就需要使用我们对非结构化数据的解析以及分析能力。



整体业务逻辑如上图所示。最左边是用户的原始反馈数据，包含用户对商品提出的各种意见和问题。在此基础上，我们会使用NLP算法对数据做抽取，并在此基础上把用户的正负向情感做分类，之后在结构化地抽取客户在吐槽什么类型的问题。最后，我们会将得到的结果产品化，变成一种给予业务分析师直接使用的功能，使得他们可以从分析的视角更直观地应用数据。从文本的分析角度来看，比如最左侧的一列是用户的原声，即包含用户的吐槽，我们需要把每一句中大家在吐槽哪一种类型的问题提取出来。这是一个分类问题，我们还需要对类型做梳理，将类型层层拆解，



分为大概五级的细粒度类别。例如，“我买完就降价”这一句话，首先把它理解成吐槽商品的价格问题，而进一步我们可以把它理解成吐槽商品降价快这一问题点，从而使得问题可以有一个相应的改善。


过程梳理 - 标准化的观点分类层级，提炼关键业务要素

DataFunTalk

一级问题	二级问题	三级问题	四级问题	五级问题	六级问题	七级问题	八级问题	九级问题	十级问题	十一级问题	十二级问题	十三级问题	十四级问题	十五级问题	十六级问题	十七级问题	十八级问题	十九级问题	二十级问题	
商品问题	商品属性	产品属性	品牌	品牌名称	品牌名称	品牌名称	品牌名称	品牌名称	品牌名称	品牌名称	品牌名称	品牌名称	品牌名称	品牌名称	品牌名称	品牌名称	品牌名称	品牌名称	品牌名称	品牌名称
		规格	规格名称	规格名称	规格名称	规格名称	规格名称	规格名称	规格名称	规格名称	规格名称	规格名称	规格名称	规格名称	规格名称	规格名称	规格名称	规格名称	规格名称	规格名称
		重量	重量名称	重量名称	重量名称	重量名称	重量名称	重量名称	重量名称	重量名称	重量名称	重量名称	重量名称	重量名称	重量名称	重量名称	重量名称	重量名称	重量名称	重量名称
		尺寸	尺寸名称	尺寸名称	尺寸名称	尺寸名称	尺寸名称	尺寸名称	尺寸名称	尺寸名称	尺寸名称	尺寸名称	尺寸名称	尺寸名称	尺寸名称	尺寸名称	尺寸名称	尺寸名称	尺寸名称	尺寸名称
		颜色	颜色名称	颜色名称	颜色名称	颜色名称	颜色名称	颜色名称	颜色名称	颜色名称	颜色名称	颜色名称	颜色名称	颜色名称	颜色名称	颜色名称	颜色名称	颜色名称	颜色名称	颜色名称
		材质	材质名称	材质名称	材质名称	材质名称	材质名称	材质名称	材质名称	材质名称	材质名称	材质名称	材质名称	材质名称	材质名称	材质名称	材质名称	材质名称	材质名称	材质名称
		产地	产地名称	产地名称	产地名称	产地名称	产地名称	产地名称	产地名称	产地名称	产地名称	产地名称	产地名称	产地名称	产地名称	产地名称	产地名称	产地名称	产地名称	产地名称
		保质期	保质期名称	保质期名称	保质期名称	保质期名称	保质期名称	保质期名称	保质期名称	保质期名称	保质期名称	保质期名称	保质期名称	保质期名称	保质期名称	保质期名称	保质期名称	保质期名称	保质期名称	保质期名称
		生产日期	生产日期名称	生产日期名称	生产日期名称	生产日期名称	生产日期名称	生产日期名称	生产日期名称	生产日期名称	生产日期名称	生产日期名称	生产日期名称	生产日期名称	生产日期名称	生产日期名称	生产日期名称	生产日期名称	生产日期名称	生产日期名称
		商品属性	商品属性	商品属性	商品属性	商品属性	商品属性	商品属性	商品属性	商品属性	商品属性	商品属性	商品属性	商品属性	商品属性	商品属性	商品属性	商品属性	商品属性	商品属性
服务问题	服务属性	服务态度	服务态度	服务态度	服务态度	服务态度	服务态度	服务态度	服务态度	服务态度	服务态度	服务态度	服务态度	服务态度	服务态度	服务态度	服务态度	服务态度	服务态度	服务态度
		服务效率	服务效率	服务效率	服务效率	服务效率	服务效率	服务效率	服务效率	服务效率	服务效率	服务效率	服务效率	服务效率	服务效率	服务效率	服务效率	服务效率	服务效率	服务效率
		服务专业性	服务专业性	服务专业性	服务专业性	服务专业性	服务专业性	服务专业性	服务专业性	服务专业性	服务专业性	服务专业性	服务专业性	服务专业性	服务专业性	服务专业性	服务专业性	服务专业性	服务专业性	服务专业性
		服务及时性	服务及时性	服务及时性	服务及时性	服务及时性	服务及时性	服务及时性	服务及时性	服务及时性	服务及时性	服务及时性	服务及时性	服务及时性	服务及时性	服务及时性	服务及时性	服务及时性	服务及时性	服务及时性
		服务完整性	服务完整性	服务完整性	服务完整性	服务完整性	服务完整性	服务完整性	服务完整性	服务完整性	服务完整性	服务完整性	服务完整性	服务完整性	服务完整性	服务完整性	服务完整性	服务完整性	服务完整性	服务完整性
		服务友好性	服务友好性	服务友好性	服务友好性	服务友好性	服务友好性	服务友好性	服务友好性	服务友好性	服务友好性	服务友好性	服务友好性	服务友好性	服务友好性	服务友好性	服务友好性	服务友好性	服务友好性	服务友好性
		服务透明度	服务透明度	服务透明度	服务透明度	服务透明度	服务透明度	服务透明度	服务透明度	服务透明度	服务透明度	服务透明度	服务透明度	服务透明度	服务透明度	服务透明度	服务透明度	服务透明度	服务透明度	服务透明度
		服务可追溯性	服务可追溯性	服务可追溯性	服务可追溯性	服务可追溯性	服务可追溯性	服务可追溯性	服务可追溯性	服务可追溯性	服务可追溯性	服务可追溯性	服务可追溯性	服务可追溯性	服务可追溯性	服务可追溯性	服务可追溯性	服务可追溯性	服务可追溯性	服务可追溯性
		服务可预期性	服务可预期性	服务可预期性	服务可预期性	服务可预期性	服务可预期性	服务可预期性	服务可预期性	服务可预期性	服务可预期性	服务可预期性	服务可预期性	服务可预期性	服务可预期性	服务可预期性	服务可预期性	服务可预期性	服务可预期性	服务可预期性
		服务可定制化	服务可定制化	服务可定制化	服务可定制化	服务可定制化	服务可定制化	服务可定制化	服务可定制化	服务可定制化	服务可定制化	服务可定制化	服务可定制化	服务可定制化	服务可定制化	服务可定制化	服务可定制化	服务可定制化	服务可定制化	服务可定制化

京东零售数据算法通道
JDR DATA ALGORITHM CHANNEL


京东的品类非常多，不同类目的商品的问题结构或者标签结构不太一样，需要我们逐步地做一些梳理。比如食品，快消，电脑数码这些品类，它们的问题点不太一样。我们使用五个级别进行梳理，其中到了第四级就是偏产品属性的维度，例如是在描述材质问题还是 CPU 内存方面的问题，也有可能是外观不好看，用料差，内存不够用的一些细粒度的观点。



我们文本挖掘的架构设计会首先将原始的用户评价的文本做清洗与切词。有的时候一句很长的评论里面可能会包含多种情感与观点，此时我们需要切成短句之后再进行抽取和分析。中间我们还加入了业务侧的知识沉淀，因为在京东的场景下，每一个品类的内部会有自己的分析师，他们会通过关键词等方式积累一些业务的分类。为了更好地拓展整个中台的能力，我们会把他们的知识引入来丰富我们的标签结构，也可以用来丰富标注数据。如果文本命中了业务维护好的信息，就可以直接输出业务维护的标签内容；反之则输入情感模型来判断当前短句是属于中性情感，正向情感还是负向情感。中性情感和正向情感我们会进行其他的处理。对于负向情感，我们会将其分为两大类。第一类是服务类的问题，比如物流、配送、客服等通用性问题，不同品类之间这类问题相差不多，所以我们可以直接对文本使用 TextCNN 这种多分类模型识别属性，最后使用 USE 对属性与标签进行相似度的识别，最终



输出多级标签的分类结构。第二类是商品类的问题，如材质、外观、CPU 内存等。这类问题品类之间差异化比较大，我们通过引入 Roberta 模型进行属性分类，并在此基础之上使用 USE 进行标签与属性的相似度识别，最后形成模型的分类结果。




下面和大家分享一下文本挖掘架构中几个关键的设计要点。

首先是业务知识的引入。在前期使用业务数据的关键词可以对架构做一个补充，一方面能够提高效率，另一方面也能够提供给我们很多可以用于在标注时参考的短句。另外，有时候业务会针对用户文本中的一些短句直接判断出所属的问题以及背后的原因，属于专业性的业务知识判别。比如我们看到显示器边角存在黑屏或者暗角的描述，我们往往会认为这个可能是在描述屏幕本身出现了什么样的问题，但是从专业的电脑行业知识来看，很大的概



率是背后的电路或者显像管发生故障。所以在架构中维护业务知识可以直接去指导改善文本中反映的问题。

第二部分是我们在模型层面的优化。我们的业务分析师会通过建立关键词库的方式处理每一个品类中一些问题的标签关键词以及其对应的短句。在此基础之上，我们做了深度模型的训练和召回，使得准确率和观点识别量均有非常大的提升。最近京东线上跑的模型全部都已迁移成了预训练的 roberta base 加上对比学习的方式来支持。当然这对于硬件的成本会有很大的消耗，它需要有 GPU 的支持。如果我们不需要很高的精准度，那么将 roberta 替换成两层的 lstm 也可以实现类似地效果，而且它直接通过 CPU 就可以完成训练，成本的消耗相对较小。



第三部分是标注环节的规范化和优化。对于文本类的处理，标注环节决定了模型的上限效果。如果标注做得好，那么模型的上限



以及效果会比较好。对客户的文本意见进行处理和分析时，因为模型是一个多分类问题，标注的类目和分类非常多。此时遇到的问题是如何提高标注效率和精准度。京东的经验是通过多次标注的方式。在第一阶段，我们先通过多分类标注为所有商品提供每一类的属性。每一类属性下提供了一定量级的样例样本，例如外观、工艺材质、活动介绍等。在标注人员调整完标定的标签之后，我们可以对标注结果进行扩散，最终使用 USE 在样本的范围中做一些其他相似语料的扩散。第二阶段是对扩散完毕的数据进行进一步标注，只不过这里只需要进行一个二分类的标注即可。具体地，我们对扩散完毕后新扩充的语句交由标注人员去判断是否真正属于扩散的属性。综上所述，每一个模型的训练需要经过两轮标注，但是每一轮标注的数据量可以大幅减少，同时这种方式可以更好地扩展出一些优质的标注数据。对样例较少的数据，这种方式还可以解决数据失衡的问题。针对第五级的标签，即观点层面上，比如细粒度的语句“外观不好看”等，由于它的分类特别多，所以我们采用 USE 相似度的方式找到衍生的短句，并在它们中标识是否真正属于我们提取的标签。如果它属于当前标签，我们会使用聚类的方式形成新的标签。通过这一流程，我们可以扩充、完善前期没有总结出来的标签类别。

在最后一个环节，我们需要在训练集和测试集上由模型跑出一个效果来，但是在最终业务应用的环节里我们还会给业务人员一些具体的样例数据去做验证，以此来观察模型是否符合实际业务经



验。这个环节往往会耗费较大的精力和时间。模型迭代之后，我们会抽取一些文本进行人工评估，基本上 1000 条数据平均需要三个小时才能完成。此外，验收过程中不同的评估人员会存在理解偏差。为了解决这些问题，我们构建了一个标准化的测试集。具体地，我们预设了一批文本和对应答案。当模型进行迭代需要验证效果时，我们直接可以使用建立好的测试集进行实验，标准化的结果（准确率、召回率等）可以直接被计算出来，省去了耗时耗力的人工过程，提高了工程效率。

03

场景化产品洞察方案



基于前述文本挖掘的设计架构，我们制作了一个产品使其能运用到不同的场景中解决用户的问题。它最直观的应用是在业务人员



的使用体验的改善。我们把大量的文本语义做了结构化处理后，通过对不同品类、品牌、产品的聚合，使用产品化的方式提供给业务人员，让他们更方便地分析、定位用户的吐槽以及吐槽背后的原因。



我们拆解的逻辑是结合 NPS 的十大要素。NPS 是行业里比较通用的净推荐值，用来度量用户满意度。传统上，它通过采样调研的方式手机用户反馈，通过问卷的形式来让抽样用户对自己的产品进行打分。但是这样的指标，虽然它在一定程度上能够度量客户的满意度，但是它无法解释指标产生变化的背后原因。我们通过大小数据结合的方式，就可以通过产品评价、售后中用户的吐槽来分析哪些问题比较集中。或者哪些问题是影响用户体验的核心问题。




第二个应用场景是需求的洞察，包括针对特定的消费者去挖掘它们背后的观点。因为在每一款产品、每一个品牌背后都有自己特定的目标人群。我们可以结合京东的大数据，基于用户画像做用户的分群。通过这种方法，我们可以针对不同年龄，不同性别或者新用户、首购用户、复购用户、流失用户等群体，观察他们的吐槽分别是什么样子的，收到什么样因素的影响，流失到了其他哪些品牌。这样的信息对业务有着更实际的指导意义。



在意图洞察中，我们对搜索词进行了词性的划分和分析。每一个品类里，我们把用户长搜词和热词，或者最近增长最快的一些词找出来，评估每一个词的需求满足度。每一个词可能就代表着背后的一种需求，如果它的需求满足度不高，就意味着用户有大量的搜索是没有找到自己需要的商品。上述未被满足的需求在细分的品类和市场当中可能蕴含着一些机会等着我们去发掘。此外，比如“老年手机”是手机中一个细分的品类，它最近的增长趋势较好，那么用户可能同时会搜索“超长待机”、“大屏”、“大字体”、“大声”等信息。从搜索词里就蕴含着围绕老年手机我们应该去主打什么类型的功能卖点。



同时，我们也支持一些灵活的批量文本自定义上传。如果有些其他源的文本也可以直接上传至产品系统，形成简报或者通过 API 来调用数据。本质上来说，我们通过产品化的方式，将算法与模型的结果做了封装，从而让它们更好地在业务中进行应用。



洞察结果产品化的核心价值是通过研究海量的文本数据，实现用户研究的智能化升级以前我们的品牌或者业务想要了解用户的体




验以及用户人群差异需要通过调研问卷等方式去实现。这种方法覆盖的样本量比较少，研究周期很长，成本也比较高。对于一些小公司，根本没有时间与精力投入这样的用户研究中。通过洞察结果产品化的方式可以大大简化流程环节，通过海量的数据覆盖到核心的目标用户群体。智能分析可以快速提高可供决策参考的结果。

04

应用案例

下面展示几个实际的业务场景的例子。




比如耳机耳麦这个案例。我们最近完成完成了一个试点，它在特定的一个品类上做了上线，上图最左边就是上线后的效果。原来的评价都是用户的原始语义标签，现在我们将耳机耳麦中核心的、




用户最关心的功能点，如音质、做工、电池性能、连接性能、佩戴舒适等进行抽取。然后，针对这一款产品，在每个功能点上展示用户的平均。例如大部分用户任务你的连接性能很好，但是觉得音质不太好，导致整个产品评价不高。所以，通过分析品类重点属性，可以把产品实际的表现拆解为各个方面呈现给消费者。以前大家只能通过商家的商品详情页上的描述来获取商品的功能介绍，现在我們也可以通过用户原始评价中抽取它们，省去了用户的翻阅操作。于此同时，商家也可以借此契机对展示的问题做一些相关的改善。对于一些质量不高，对质量把控不严的商家，这种展示形式会带来更大的压力。我们发现通过这样的方式，在不同维度上，商家对产品是会进行相应的改善。比如包装的破损，商家就从原来的塑料包装改成了纸盒进行替代。在整个品类中，我们也会去寻找质量问题较为集中的品牌，对低质量的品牌做清退；或者对于“佩戴不舒适”等这类型的问题，我们会推动品牌开放七天无理由退换货的政策，以此来保证更好的用户体验。

我们检测了上线一个月 NPS 的效果，分析用户的满意度得分，发现上线后的八月比七月的 NPS 上升了 27% 左右。包装的差评率也得到了很大程度的改善。




另外一个例子是 SSD 固态硬盘这一产品。很多用户回去吐槽“不配螺丝无法安装”这一问题。那么我们就去推动近一半的品牌将螺丝作为赠品赠送给购买 SSD 的用户。通过这一做法，针对配件不满意的用户比例大幅下降，这其实在背后是大量用户的体验得到了改善，原本可能会流失或者不在这个品牌里进行购买的用户会被挽留。







在需求端，传统的用户分析有一个经典的 Kano 模型。它希望我们在做产品规划前分析用户需求时，能够基于需求的功能点和用户的期望程度进行划分。因为不同类型的功能用户的期待不同，有的技术需求必须要被满足，而且再次基础之上还会有用户的期望需求，以及用户还没有发现但做出来会给他们带来惊喜的需求。通过这一模型可以按照需求的不同层次去组织自己的资源。



虽然这是一个偏理论性的模型，但是我们可以基于用户的评价信息或者搜索信息，把客户的关注度以及市场上需求的满足度进行评估和划分。例如上图所示，最右下角是客户关注度很高，但是满足度比较低，有可能负向的声音较多或者搜索后没有找到心仪的产品，我们称这个区域为心智抢占区。在这个区域的产品，如果你能及时尽早地做出来，是可以较好地去抢占用户的心智，找到一个潜在的商机。



同样地，我们也需要去了解用户在选购每一款产品的背后关注的因素是哪些。比如笔记本，用户关注的属性有外观、尺寸、材质、CPU 类型等。我们可以通过搜索词的分析和统计识别用户最关心的要素。笔记本品类下用户首先会去考虑品牌，其次会去考虑需要买多大尺寸的电脑。针对外观尺寸这一属性，下面又会有很多类型。我们可以从中找到目前市场潜力比较大，增长率会比较高，且市场竞争还相对没有那么大、头部市场的集中度还没有达到饱和状态的类型，从而在组合的策略中优先去考虑如上图右上角的潜力趋势。



我们组织成了一个启明星系统，在里面把功能按照体验洞察、商机挖掘、用户超市进行拆分，以此把我们的核心算法能力，结构化、非结构化数据，结合我们的业务应用场景，整合成一个内外部统一的系统来给大家使用，使得我们的算法通过产品化的方式规模化地应用至业务中。

最后做一个简单的总结。现在我们越来越多地发现用户体验在经营中被重视，这也是因为我们可以把产品的价值分为实用功能价值以及创新体验价值，而能够带来溢价的往往是创新的这一部分。但是如何做创新，就需要从用户的洞察中去发掘。其次，整个数据的价值发挥依赖于三个条件，而且缺一不可。第一个是数据的资源，即你有多少的评价和搜索数据；第二个是数据的能力，比如算法、算力等；另外一点是应用的场景，如体验诊断、精准营销、推荐等。这三个条件组合在一起才能够把数据的价值发挥出来。最后，深度学习是无法单独地体现算法价值的。在使用深度



学习之前，我们需要能够洞察和分析业务的场景以及问题，找到内在逻辑。在深度学习之后，还需要使用输出的结果指导业务的决策和优化。多方面协同才能够把深度学习的价值发挥出来。

05

精彩问答

Q：产品的五个属性等级是预定义好的吗？

A：定义需要不同的业务部门进行处理。其实产品的一些工作也会有业务人员的参与。我们这产品上也有自助分析的功能，会把新词、高频词分析出来。通过这样的工具更有助于产品以及业务人员从数据中总结用户可能会关注的一些标签和问题。所以它不是一成不变的，而是持续地在应用过程中进行丰富和扩展。

Q：标注的标准由谁来决定？

A：标注的标准需要产品、研发、算法部门一起来跟进。我们会把标准清晰地给到标注人员。为了让他们更好地理解标注标准，我们会同时给出正例和反例。比如哪一句话属于外观问题，哪一些短句是相似的，还有那些不属于外观的短句等。因为文本分析和标注没有通用和统一的标准，所以我们尽量会让标注人员去做选择题，而不是人工地往文本数据中维护一些信息。我们两轮的



标注，第一轮会给标注人员多分类任务，即选取文本中包含的属性是什么；第二轮标注是判断一个短句是否属于一个属性标签。具体的标准是由产品的研发人员去指定，然而对于一些标注错误的情况，我们还会额外抽取出来，再进一步给标注人员做一些宣贯。

今天的分享就到这里，谢谢大家。扫码观看本文视频回放。





比你更了解你，浅谈用户画像



比你更了解你，浅谈用户画像

王志杰 明略科技 营销事业部行业架构师



分享嘉宾：王志杰 明略科技

编辑整理：刘薇薇 百度

出品平台：DataFunTalk

导读：今天主要和大家分享明略对于用户画像的认识，包括如何理解用户画像，为什么需要用户画像，以及明略在建设和应用用户画像过程中总结的方法论，让大家了解如何构建好的用户画像。



01

什么是用户画像

首先来看用户画像的定义。

1. 用户画像的定义

用户画像的定义



百度百科的定义：

用户画像又称用户角色，作为一种**勾画目标用户**、联系用户诉求与设计方向的有效工具，用户画像在各领域得到了广泛的应用。我们在实际操作的过程中往往会以最为浅显和贴近生活的话语将用户的**属性、行为**与期待的数据转化联结起来。

英文称为User Profile或者User Personas

© 2006-2021 明略科技 版权所有

DataFunSummit

上图是百度百科中的定义。这个定义有两个重点，一是勾画目标客户，二是行为、属性。这个定义强调了用户画像的本质是对目标客户的一种勾画或描绘，这种勾画比我们平时在马路上看到的快速肖像画要丰富得多，多出了行为、属性。

那么换一种技术化的视角，画像的定义是什么？



更技术化的定义



用户画像可以简单理解成是海量数据的**标签**，根据用户的目标、行为和观点的差异，将他们区分为不同的类型，然后每种类型中抽取出典型特征，赋予名字、照片、一些人口统计学要素、场景等描述，形成了一个**人物原型 (personas)**。

用户画像就是与该用户相关联的数据的可视化的展现；一句话来总结就是：**用户信息标签化**。

© 2006-2021 明略科技 版权所有

DataFunSummit

引用这个定义是为了引出标签的概念，以及标签在画像中的作用，或者说标签和画像之间的关系。标签可以理解为对用户各种类型数据的提炼总结，可能就是用**一个词**或者说是用**一个短语**来表达用户在某个方面的一项特征。用户有各种各样的特征，因此需要有海量的标签去完整地描述一个用户。这样做的好处在于能够可视化表征用户特征，让我们更加便捷清晰的了解我们的客户，这是用户画像的意义所在：用户画像其实就是对用户关联数据去进行可视化的展现。


一句话总结一下，用户画像的技术特点就是把用户的信息标签化。

2. 常见用户画像维度

到现在为止对用户画像进行了多种角度的定义，但还是停留在概念层面，不够直观。下面举几个例子加深理解。



常见用户画像维度



首先看一个人物画像，它其实是由各种标签来构成的，文静、可爱、善解人意、活泼等等，都是对用户某些属性的描述，非常直观。在这张图上也可以发现，标签被分成了几个类型，有基本属性类的，有消费购物类的，还有网络社交类，其实还会有更多的分类，在这里没有一一列举。之所以会形成对标签的分类，一是便于对标签的管理，另一个重要的原因是在不同的场景中，这些标签可以帮助我们实现不同的目标。场景和目标是非常重要的。

结合这张图：蓝色的像年龄、性别、所在的区域，都是一些比较通用的基本属性，可能在多个场景中使用到。这类标签通常是会再去配合其他标签去使用。而左上角黄色的消费购物类的标签，可能在电商场景中会用的比较多。根据用户的标签，比如消费偏好领域为服贸，我们判断用户可能购买服装类的物品会比较多，因此在进行推荐或者是促销的时候，可以优先挑服装鞋帽等品类推送给用户。但如果不考虑这些标签，而去给用户推荐一些 3C



电子类的产品，用户可能会完全不感兴趣，也就起不到促进购买的作用。

再比如“偏好价格区间”是“200 到 500”。虽然我们偶尔也会不太在乎价格的购买一些非常心仪的东西，但大多数的购买其实还是会在一个范围区间之内，这个区间可能用户自己都不能直接的量化出来，但是通过用户画像，可以将其框定在某个范围之内。这就是“画像比你自己更了解你自己”的点之一。通过对于偏好价格区间的标签化，企业就可以针对性的进行后续的推荐和促销，效果也会更加显著。

最后我们来看网络社交类的标签，左下角紫色的部分，基本都是和我们日常使用社交网络相关的，图例中都是和微博相关的，比如说粉丝数、关注数、互动数等等。在进行社交舆情分析的时候，网络社交相关的标签对我们的分析会非常有帮助。

3. 金融产品常见用户画像

前面列举了用户画像在营销和舆情分析场景中的应用，其实还有一个非常早就开始应用用户画像来助力其日常业务的领域，那就是金融领域。而金融领域里面最常见的一个场景就是信用评分画像。



金融产品常见用户画像



© 2006-2021 明略科技 版权所有



DataFunSummit

在这个场景中，可以看到用户的标签都是和个人信用相关的，和前一个例子的标签集合差异比较大。跟个人信用相关的标签包括，如用户在平台的注册年限，是不是修改过注册信息，是不是在其他平台有过逾期行为，还是一向都表现良好，也包括用户的个人信息，比如婚姻状况，有没有小孩儿，以及在社交媒体上的表现，比如粉丝数，活跃度等等。这一系列的信息都可以综合起来，帮助我们判定用户的信用评分及信用等级，辅助业务部门去做出决策。这又提出了一个非常重要的概念，就是辅助决策，后面我们也会提到这一点。

4. 群体维度常见的画像


除了可以对单个用户去进行画像之外，也可以对某个群体来进行画像。




群体维度常见的画像



粉丝性别分布



粉丝年龄分布



粉丝标签分布



粉丝地域分布



DataFunSummit

前面在定义阶段，我们说画像其实是一种可视化的展现，但是这个展现的形式不是单一的。举个例子，对微博上某个车评人的粉丝情况的分析，和刚刚单一用户的画像就很不一样。单一用户画像，更多的是把每一个属性进行分类和排列，帮助我们了解某一个单独对象的信息。而针对群体的画像，更多的是将单一标签类型汇聚在一起，去展示统计信息（也就是标签、标签值的分布），比如说性别里面男女各占多少比例，地区里每个省份所占的比例，或者是每个省份的热度是多少等等。而在处理连续的值，或者说比较多的离散值的时候，我们也可以去进行分段，比如说右上角年龄，可以针对典型的年龄段进行划分，至于具体怎么去划分，则是业务强相关了。

02

为什么要做用户画像



前面对于用户画像进行了理论上的定义和直观上的认识，那么，我们为什么要去构建用户画像，构建出来有什么用？下面和大家分享一下我个人的一些看法。

1. 为什么要做用户画像

为什么要做用户画像



业务上：

- 构建具象认知，构建战略、战术方向
- 探索用户足迹，用户(市场)导向

技术上：

- 构建底层数据基础，服务上层应用
- 方便信息的处理

总之用户画像完美地抽象出一个用户的信息全貌，可以看作企业应用大数据的根基。需要做到的终极形态是不同用户视角，打开同一个网站或者APP，体验完全不同

我们从业务和技术两个角度进行理论分析。

在业务层面，我们通过用户画像可以去构建具象的认知，构建战略和战术方向，同时也可以去探索用户足迹，形成以用户为导向的一个方向。在对核心用户达成统一而且具象的认识之后，我们后续的投入才能方向明确，有的放矢。

在为用户设计产品的时候，要以用户为导向，清楚地知道目标用户是什么样的，有什么样的行为、属性特征。根据用户画像信息来做产品设计，才可能为公司提供一种战略和战术层面上的指导。



探索用户的足迹，形成用户走向，是指在详细了解真实用户是如何和产品及其相关内容进行互动之后，我们才能进一步的去深化产品。当我们为用户进行画像的时候，一定是要从这种业务场景出发的，带着业务场景的目标去解决实际的业务问题。比如要去进行画像，要么就是去获取新用户，要么就是去提升用户体验，再或者可能是为了挽回流失的用户，总之一定是有非常明确的目标在先。

从**技术层面**上讲，我们通过用户画像的构建，可以帮助构建底层数据基础，来服务上层应用，同时也方便对于信息的处理。

其实用户画像除了可以做比较直观的展示之外，更多时候是服务上层应用，比如在推荐系统里面，用户画像作为推荐系统非常重要的一环，能够提升推荐效果；另外像前面提到的金融领域的应用，用户画像也可以在风控应用，作为一些规则特征而存在，用于量化用户的信用等级。

有标签之后，计算机可以方便地处理一些量化的需求，比如去做分类统计，或者去做深入的数据挖掘，喜欢买榴莲的用户，通常喜欢什么服装品牌，经常又买咖啡又买大蒜的用户的年龄段分布大概是什么样子等等，基于画像，我们可以做一系列量化分析。

总之，用户画像可以完美地抽象出一个用户的信息全貌，是企业应用大数据的根基，可以帮助企业为用户提供个性化的产品和服务




务。对于给客户提供服务的企业而言，我们最终的目的都是，在用户使用企业提供的产品、打开 APP 或者网站的时候，可以看到的内容和体验都是针对他来设计的，或者说是符合用户的调性的，这就是所谓的千人千面，这样用户的体验才会有真正的提升。

2. 示例：画像支撑业务应用

接下来，结合明略的用户画像和营销自动化产品，来给大家举一个画像支撑业务应用的例子，非常浅显易懂。

示例-画像支撑业务应用



© 2006-2021 明略科技 版权所有

DataFunSummit

例如，我们想要举行一场营销活动，但是不希望直接面向所有用户群体，而是针对某一类具有一定特征的用户来去进行。首先我们就会用到用户画像产品，根据目标用户的标签来去进行人群圈选。目标用户的标签，指的是，根据业务上确定的条件，在画像产品里面通过输入条件来把目标人群圈选出来。比如说通过消费行为的标签，可以把 360 天之内都没有进行过购买的用户，筛选



出来。下一步，真正去做营销的时候，就可以将上一步中筛选出来的用户群体作为活动的目标人群，轻松的实现定向营销。

以上，我们将画像视为一个整体，讨论了它的作用、存在的必要性，也谈到了标签，画像和标签之间存在着紧密的联系。下面我们来具体来谈一谈标签的重要性，标签到底有什么样的作用。

3. 标签的作用

- 标签可以将数据及其含有的信息转化成带有明确的可决策行为的指导。
- 人参与决策越多的地方，越需要将信息数据进行标签化，以提升人对数据的理解和处理效率，实现人机协同。

下面讨论这两点的具体含义。观察一下所谓的数据产品，比如营销领域的 DMP、CDP，或者一些通用的数据产品，BI、DASHBOARD 等等，它们的共同之处在于，关注如何用数据让人去产生快速的理解。

比如说在当今疫情环境下，有一个大家日常经常会遇到的标签，体温超过 37 度，可能就是发烧需要去看医生了，这个发烧点就是一个重要的标签。再比如驾车过程中，如果时速超过 120，导航上的显示就变成红色，这也是一个非常明确的标签，说明已经超



速，该松油门减速了。所以我们在日常生活中其实总是能遇到一些特别典型的标签，指导我们去做决策。

我们再从另一个角度来去看一下，为什么我们需要去做标签。以各种新闻类或者短视频类的 APP 为例，其背后普遍有非常好的推荐能力，这些推荐能力可能不需要标签，因为它有大量的用户反馈数据去帮它做决策，就可以自己不断的去进行刷新，去训练提升它的模型。但是如果说某些场景环境需要人来参与做决策，人参与决策的地方越多，就越需要将数据和信息进行标签化。因为人处理信息不可能像机器那样，通过大量的运算来决策。人类能够处理的信息其实是有限的，为了提升处理效率，最终实现人机协同，我们要把大量数据和数据演算的结果，通过信息的标签化，变成人可以快速理解快速去做决策的形式。

下面我们来举一个例子看看标签的作用，如何通过下面这 4 个步骤将数据转化为标签，并且最终指导决策。



标签的作用



- 标签可以将数据及其含有的信息转化成带有明确的可决策行为的指导
- “人”参与决策越多的地方，越需要将数据/信息进行标签化，以提升人对数据的理解 and 处理效率，实现人机协同

数据在线	数据-信息	信息-标签	标签-决策
用户名：王二妮	用户名：女性化	性别：女	适合妈妈型的沟通方式和称呼
收货地址：北京市东城区特别贵小区302	房价：¥99,000/平	收入水平：¥55,000~70,000	推荐更高端的系列
联系电话：138xxxx8888	手机尾号：8888	态度标签：传统文化/相信运气	邀请参与抽奖类、福袋类活动
下单时间：2020/10/19 23:33:10	购买行为：直接购买	品牌认知：品牌认知度高	转化会员
付款时间：2020/10/19 23:33:15	活跃时间：23点以后	生活习惯：夜猫子	11点以后推送信息/广告
商品：有机幼儿配方奶粉3段6罐	商品：1~3岁适用	人生阶段：育婴期-家中有婴幼儿	推荐其他婴幼儿商品并关注消费周期性特征（计算推送辅食的时间）

© 2006-2021 明略科技 版权所有

DataFunSummit

第一步：数据在线

数据在线指的是通过数字化转型，将业务流程在线化，这样业务流程中产生的数据也就跟着实现了在线化，具备了进一步处理的先决条件。比如以前我们都在超市里买东西，其实很难去统计哪个用户买了什么东西，后续的分析也就很难进行。现在很多人都在电商购物，购物记录实现了数据在线。未来，随着越来越多的业务流程在线化，可以分析的内容也会越来越丰富。

第二步：数据信息转换

用户数据转换为信息，这个信息指的是，在我们业务场景下能够解读出来的内容。比如用户姓名王二妮，是一个女性化的名字，当然，可能并不是所有的转化都这么直接。从数据到信息的过程中，需要基于对业务场景的理解，我们不仅需要直接的分析数据，



转换数据，还需要赋予数据新的信息，这就是所谓的信息转换，信息增益。

第三步：信息标签转换

我们可以通过一些规则，将信息转化为标签。举个例子，当我看到这信息（用户名叫王二妮）的时候，我们就可以判断，大概率 90% 以上，这个用户是一位女性，就可以给用户一个性别标签，这是一种预测性的标签，所以这个标签是带有权重的，比如 90%。

第四步：标签指导决策

根据标签如何产生决策？在电商场景，用户购买了一款婴儿奶粉产品，接下来该如何去跟他互动？我们结合性别女的标签，去判断，用户大概率是一个妈妈，就应该是适用妈妈型的沟通方式和称呼。这个当然也有可能会有错，比如用户是帮别人买的，送人的。因此可能会要结合多种标签应用，帮助我们决策用什么方式去和用户进行沟通。在这个环节中，并不要求决策百分之百正确。因为大多数业务只是需要一个可以尝试的推荐。接下来每一条数据都是这样的，比如通过数据在线，获得了收货地址，东城区特别贵小区 302，通过信息增益补充了房价信息，然后再结合收入和房价模型，就能大概推断出用户的大概收入水平，生成收入水平标签。有了收入水平标签后，能进一步指导决策：对于收入水



平比较高的用户，推荐更高端的产品系列。这就是一个典型的，通过数据转化为标签，最终指导决策的过程。

03

如何构建用户画像

明略在用户画像构建，标签体系构建，标签生成方面，不仅有成熟的产品，例如 CDP、DMP，也有非常专业的实施服务团队和方法论。下面，结合明略自有的方法论和通用的方法论，和大家聊一聊如何构建用户画像。

1. 数据在线


画像构建流程的第一步是数据在线，也就是数字化转型，应用系统打通，终端埋点建设等等，技术层面内容这里就不一一展开了。

这里说一下我们比较关注的两类数据，一开始在定义阶段就提到过的属性和行为，具体包括静态数据和动态数据。

(1) 静态数据



数据在线（静态数据）



© 2006-2021 明略科技 版权所有

DataFunSummit

静态数据是用户相对稳定的一些信息，如人口属性、商业属性等，这类信息通常自成标签。如果说企业有真实的信息，就可以直接进行转换，不需要建模或预测，更多的是数据清洗的工作，但如果某些静态信息不准确或者缺失，可能需要进行建模预测，后面也会提到这几种情况。

(2) 动态数据

数据在线（动态数据）





动态数据是用户不断变化的行为信息。我们可能会更多地聚焦在用户在互联网上的行为，比如在浏览了某品牌的网页，浏览了某一个品类的一个单品页，或是发了一条微博等等这些信息，这种就是动态数据。

这两类数据对构建标签非常重要，也非常有用。

2. 标签体系建设

数据有了之后，在构建标签之前，我们先聊一聊标签体系的建设。

标签体系建设



标签体系=基于既有经验预设好的数据解决问题的模型



所谓标签体系，是基于我们既有经验预设好的，用数据解决问题的模型。我们在设计标签体系的时候，参考了通用的数据解决问题的方法论，即：

- 第一步:明确问题和目的是什么,用数据解决问题也不例外;



- 第二步：梳理现有条件，从中锁定问题的关键点；
- 第三步：确认分析的维度，即确定分析的对象以及分析角度；
- 第四步：确定分析方法，例如，求解一道三角形相关的几何体，明确分析对象是三角形，下一步应该考虑用哪个定理去分析它；
- 第五步：圈选，圈定数据来得到结果，把思路都理顺之后，只需把题干中条件数往公式定理中一带，就能得出最后的结论，算出答案。

以上五步，就是用数据去解决问题的通用途径。制定标签体系设计路径的时候，也是类比通用路径，因此也有五个步骤。

- 第一步：明确带目标的场景。所谓带目标的场景，指的是，设计标签体系要解决的是什么场景下的问题。不仅要知道场景，还需要知道具体的目标。比如广告投放是一个场景，这个场景里面可能会有多种不同的目标，可以是在固定投入的情况下，触达到更多的人，或者是在固定触达人数的情况下，尽可能减少预算；如果要选媒体，那么在不同的目标之下的情况可能也是大不相同的。
- 第二步：明确场景中的流程和角色。比如广告投放的场景，角色可能会有哪些？比如要选媒体，选媒体点位，选完点位



之后，需要确定投放的素材，确定完素材之后，还需要确定时间。考虑时间的时候，还要考虑每个媒体提供的不同的时间的人流量表现是不一样的。这个过程中就包含很多的角色，这些角色在不同的环节中完成不同的工作，他们的关注点也是不一样的，我们需要了解每一个角色在这个过程中需要去解决的问题是什么。

- 第三步：明确场景中需要被标签化的对象，也就是要去给谁打标签，比如刚刚提到的场景中，我们做广告投放的时候，如果说目标是要去触达到更多的用户，那么用户可能就是打标签的对象。
- 第四步：明确我们不同对象在场景中需要的标签类型，例如，是基本属性标签，还是消费偏好表现，是动态标签，还是静态标签，是预测标签，还是行为标签，等等。
- 最后：确定了类型之后，需要列举出标签的值，比如人口属性标签中的年龄段标签，需要进一步确定出“0-15 岁”，“16-18 岁”，“18 岁以上”等具体的值。

以上是我们构建标签体系的比较通用的方法论，适用于各种用户画像构建过程中设计标签体系。

3. 标签与权重



用户画像的最终形态，就是通过对用户行为的分析为用户打上标签，以及标签的权重。那么，标签与权重，具体是什么样子？

标签与权重



用户画像的最终形态是通过分析用户行为，最终为每个用户打上标签，以及该标签的权重。如：李宁 0.8、小米 0.6；

- **标签**：表征了内容，用户对该内容有兴趣、偏好、需求等等。
- **权重**：表征了指数，用户的兴趣、偏好指数，也可能表征用户的需求度，可以简单的理解为可信度，概率。

© 2006-2021 明略科技 版权所有

DataFunSummit

以这两个标签为例：李宁 0.8，小米 0.6。标签的部分，表征用户对哪些内容有兴趣、爱好或者需求，权重则表征了爱好或者需求的指数，也可能是需求度、可信度、概率等。

4. 标签建模方法

标签建模方法



标签=用户标识 + 时间 + 行为类型 + 接触点（网址+内容）的聚合，某用户因为在什么时间、地点、做了什么事，所以会打上**标签。

- **事件模型**：主要通过收集用户行为，并结合上下文构建事件模型。主要为 5w(who、when、where、what、which);who:通过唯一的用户标识来锁定某个人(用户名、手机号、qq、微信、cookie等); when:主要收集时间因素; where:主要收集地理位置因素; what:主要收集交互的商品/内容的标识，最终标签基本出自于对what的具象或者抽象; which:标识用户什么行为，比如点击、浏览、购买、观看。
- **整体思考建模**：用户标签的权重可能随时间的增加而衰减，因此定义时间为衰减因子r，行为类型、网址决定了权重，内容决定了标签，进一步转换为公式：标签权重=衰减因子×行为权重



下面对标签建模方法做进一步讨论。标签是对用户标识、时间、行为类型、接触点（网址、内容）的聚合，即，因为用户在什么时间什么地点干了什么事，所以我们才需要给用户打上一个某某标签。进一步的，从整体思考和建模，可能需要加入权重方面的设计。例如，在某些场景下，我们需要定义时间衰减因子，即时间越长，可能性或者说概率就越低，权重也就越低。

标签建模方法（举例）



如：用户A，前天在天猫李宁官网浏览了一双价值699元的运动鞋，昨天在天猫超市购买了一个价值为50元的杯子。

标签：李宁，运动鞋，杯子

时间：因为是昨天的行为，假设**衰减因子**为： $r=0.9$ （不妨这里衰减简单地选取为每天下降为前一天的0.9，具体衰减可以通过数据分析得到，一般为指数级衰减）

行为类型：浏览行为记为权重0.5，购买行为记为权重1

地点：李宁官网权重为0.8，天猫超市权重为0.4（因为天猫超市品类更泛，所以权重相对于李宁专业运动品牌商要小）

则用户**偏好标签**是：杯子，权重是 $0.9 * 1 * 0.4 = 0.36$ ；李宁、运动鞋，权重是

$0.9 * 0.9 * 0.5 * 0.8 = 0.324$ 即，用户A：杯子 0.36、李宁 0.324，运动鞋：0.324。

© 2006-2021 明略科技 版权所有

DataFunSummit

举例说明：某用户，前天在天猫李宁官网上浏览了一双鞋，昨天在天猫超市买了一个杯子，我们可以比较轻松地提取出来几个标签，李宁运动鞋、杯子，以及相关时间，昨天发生，前天发生。我们再做一个简单的假设，重要性每天可能会有百分之十的衰减，就是前一天可能是今天的 0.9。




对于行为类型的标签，不同行为权重不同，比如购买行为权重是 1，浏览权重只是 0.5，也可能引入地点的权重，例如品牌官网的权重可能会重一些，天猫超市可能稍微低一些。

所以计算标签的时候，需要把以上所有内容都考虑进去，时间衰减、行为类型、地点等等，计算出标签以及权重值。

上面讲的这些方法和例子仅供参考，当我们真正去设计标签的时候，首先需要根据业务需求进行建模，然后才能明确标签、权重的值到底应该是怎样设定，并且要不断的迭代和优化。

5. 标签分类

下面我们从另外一个角度去看一下标签的分类，如图所示，分成了四层：





底层：其实不是标签，而是原始数据，是我们通过数据在线从各个渠道中采集汇聚回来的数据，通过这些数据进行简单的分析就可以得到第一类标签-事实标签。

事实标签：是从一些简单的事实中提炼出来的，甚至是不用提炼直接就能形成的标签。例如原始数据里面已经有了用户的注册信息，其中有用户的性别，可以直接构建标签，也有的可能需要经过简单的统计，比如通过累加，我们能得到产品购买的次数，投诉的次数等等，这些都是一些基于事实直接可以拿到的标签。

模型标签：如果标签不可直接获得，通常就需要通过建模计算来生成，比如通过对历史购物行为的建模分析获得用户的产品购买偏好：对于哪个品类或者哪个品牌的标签权重是多少等等。


预测标签：这类标签的生成更多是依赖算法。例如在电商场景中，可以通过用户购买的商品、年龄、性别，预测用户的人群属性：年轻的妈妈，或者高收入白领等。

以上，就是关于标签分类的讨论。

6. ID 打通



利用Super ID实现ID打通



讨论了数据在线、标签体系设计、标签生成之后，我们来说一说构建画像过程中另外一个比较精彩的部分，通过 Super ID 的构建来实现 ID 的打通。这里暂且不讨论具体的技术，重点分享为什么需要实现打通。我们前面讨论的构建画像的过程其实是简化了的：假设来自不同场景的数据都可以直接和用户产生关联。而在实际场景中，企业可能构建了多种渠道触达用户，可能是直接提供服务的渠道，也可能是广告营销的渠道，渠道的多样化就导致了用户行为的碎片化。如何将复杂的碎片归一化，认知用户特征，最后形成用户画像，挖掘用户需求，这一系列的解决方案是很重要的需求，也是大多数企业今天面临的挑战。

在明略的解决方案中，我们围绕用户构建了一个 SuperID，通过一些确定性的绑定关系和一些不确定性的匹配关系，将这些多种渠道获得的 ID 围绕 Super ID 形成连接，最终实现多个渠道多个




ID 的打通，这样就可以将多个渠道获得的用户行为数据进行连接，来支撑模型标签和预测标签的计算。

7. 用户画像示例

用户画像示例

重组割裂数据，基于业务形态构建标签体系，洞悉客户特征



DataFunSummit

最后结合我们的用户画像产品，举一个简单的例子。当今很多企业可能会有多个触点来获得用户行为，在左边的图中，有四个触点，因此形成的用户的多个碎片化的信息：可能是关注了公众号，通过一次广告点击进入到了活动主页，然后在小程序里面进行了一些咨询，最后线下购买。我们通过不同渠道，获得了用户的行为。当我们把这些行为串联起来去看的时候，可以直接从行为中提取一些事实标签，例如关注了公众号，那就是“xx 公众号的读者”，使用爱奇艺，可能是“xxAPP 的使用者”，关注了新品，因此是“xx 新品的关注者”，这些都是比较直观的解析。通过这些直观的解析，再经过模型的计算，我们就可以得到一些深层次的标签，



例如，商务白领。怎么推断出来的？用户在南京西路商圈活动，同时还在这个地方消费。假如用户只是去看一看，不买，我们可能也推断不出来，但用户既在附近活动，又消费，我们就能做一个推断，用户是一个商务白领等等。结合这种行为解析，就可以产生高层次标签。

其实刚才的例子少了一个步骤，如何将多个渠道获得的用户数据打通？建立 Super ID。通过第一个渠道，我可以把用户的 deviceID 或者 openID 连接起来。第二个渠道可以把手机号和 openID 连接起来。通过引入一个 Super ID 作为唯一标识，就可以把所有渠道里获得的信息进行串接，打通。完成这部分之后，我们就把整个用户的属性进行了归一化；通过标签生产，还可以进行人群分类。比如我发现用户是一个商务白领，同时年龄是在 20 到 35 岁之间，可能就可以把它分到年轻白领人群里面去。这是我们对于用户分群的支持。

通过前面这几个步骤的工作，包括数据来源，从数据中直接提取一些基本标签，用户的行为轨迹追踪，ID 打通，以及基于客户特征的分群等等，我们拼成了一个真正的用户的样子，能看到这张图就不再是碎片，而是形成了完整的 360 度的用户画像。

04

精彩问答



Q1: 在标签建模的过程中，如何为新登录的用户打标签，如何为具有较少行为的用户打标签？

A: 这个问题其实可以理解为怎么针对用户做冷启动的问题：当用户行为比较少的时候，怎么去标识他。其实就是我刚才提到的，当你从这一个渠道里获得用户的信息不多的时候，就要去尝试如何能够获得数据在线的能力，从多个渠道获得更丰富的信息，然后再来对用户进行（建设）更全面更丰富的标签的过程。

Q2: 明略科技更多是乙方的角色，为很多企业（甲方）搭建了用户客户画像、落地了很多项目，想请教一个问题，我们观察到，市场上很多用户画像没有发挥出应有的价值，可否帮忙从乙方的角度总结一下，你觉得一般来说，会有哪些因素制约用户画像的落地效果？

A: 结合之前方法论提到的一点，构建画像的第一步，应该去锁定带目标的场景。可能很多乙方在给甲方服务的时候，会强调，我有很多经验。经验有好的，也有很多不好的地方，比如一味的重落地，忽略了甲方的实际目标是什么。没有透彻的理解甲方的场景，就把经验、标签铺上去，这时候，经验反而成为了绊脚石。明略这边非常注重第一个步骤：重视客户端场景和业务目标。如果第一步没有做好，往往就事倍功半了。

Q3: 建立 SuperID 时，出现多对多的情况，应该怎么处理？



A：有不同的处理方法。当出现多对多的时候，可能有几种场景，一种是您刚才说的，一个人有多个 device id。这种是合理的业务场景，需要存多个。技术选型就不在这里讨论。另外就是在不同渠道拿到不同的信息，比如，从某个渠道拿到用户的信息自称性别是男，另外一个更加靠谱的渠道，比如从身份证信息中拿到用户的更高权重的信息，性别是女，这种从业务场景上来看，是不可能存在多个的，我们需要选择可信度更高的。

今天的分享就到这里，谢谢大家。扫码观看本文视频回放。





用户画像场景与技术实现方案

一个数据人的自留地 | DataFun.
— SHU JU REN CLUB —

用户画像场景与技术实现方案

赵宏田 某科技公司 大数据架构师



分享嘉宾：赵宏田 大数据架构师

编辑整理：苏丽萍 彩讯股份

出品平台：DataFunTalk

导读：感谢 DataFunTalk 和一个数据人的自留地的邀请，今天和大家分享的主题是用户画像的场景与技术实现方案。主要分三大部分：

- 用户画像常见应用场景
- 画像产品功能



- 技术实现方案

01

常见应用场景

1. 画像常见的应用场景

不同行业业务属性不同，能采集到的数据源也不同，对画像的应用场景有不同的需求，下面梳理互联网 TOC、电商和安防等行业的画像应用场景，提供画像应用思路。

常见的 360 全息画像，就是给一个人打完全部标签之后，输入 ID 可以返回这个人的全部标签，看到这个人的全息画像，然后基于标签做个性化内容推送和消息推送，以及提供实时管控预警、专项场景分析。比如我们常见的事件分析、漏斗分析等数据分析模型，其实都是基于标签和行为数据，把数据模型产品化之后做成的特定场景分析，提供个性化的运营服务支持。



画像常见的应用场景



不同行业业务属性不同能收集到的数据也不同，对画像的应用场景有不同的需求，下面梳理了几个行业的画像应用场景，提供画像可以应用的思路。

除了360全息画像、个性化内容推送等场景外，还可以提供实时预警管控、专项场景分析、个性化人工运营服务等方面支持

	互联网TOC	电商	安防	互联网金融服务	
行业特点与可采集到的数据	用户的注册身份信息； 用户认证数据； 用户在app站内的行为数据； 维度数据等；	用户注册信息； 用户在app站内的行为数据； 用户购买订单数据/退货/投诉数据； 物流数据； 商家/物品数据等；	用户的身份证、住宿、上网、乘火车、飞机、居住登记、各平台聊天、短信、通话等信息网全数据； 用户出行、驾驶被天网抓拍识别到的物联网数据；	用户的注册信息； 用户在app站内的行为数据； 用户的借贷数据； 手机装载的app...	
画像应用场景	1、给C端用户推荐站内的内容资讯； 2、给用户推荐适合其的个性化服务； 3、SOP营销流程；	1、给用户进行日常的精细化push内容推送 2、定期进行个性化短信营销 3、app站内的个性化弹窗与广告推送 4、给vip用户提供急速退款、专人客服等个性化服务	1、对每个人建立全息档案画像 2、针对不同的分析场景如重点部位、开车驾驶、聊天对话等，建立模型分析潜在风险的用户 3、实时的安防布控，当达到预警条件时，实时触发告警通知	1、对每个人建立360度画像 2、风控潜在风险的账号 3、基于个人资金水平，多头借贷等情况综合评价信誉； 4、对vip大客户提供针对性的人工干预运营	

不同行业有不同侧重点，主要源于不同行业采集到的数据源不同、不同行业的应用场景不一样。

- 互联网 toC 覆盖范围非常广，能采集到数据包括用户注册身份信息、用户强认证信息（比如身份证、银行卡等）、用户在 APP 站内的行为数据、填写表单的维度数据等。互联网 toC 的场景化主要包括，给 C 端用户推荐站内的内容资讯，向用户推荐适合的个性化服务，SOP 标准化营销流程。
- 电商也类似，主要基于用户的注册信息、站内行为数据和基础属性数据为用户提供服务，常见的发短信、发邮件、APP 的消息弹窗等，以及给用户提供个性化的 VIP 服务。
- 安防场景的很多，比如用户的基础身份信息、出行数据、人脸识别数据等，基于这些数据给每个人建安全的全息档案画像。安防有自己行业特性的分析场景，针对一些重点部位、



人的行为轨迹等等。也会有实时的安防布控，去告诫可能潜在风险的人员，做提前的预警管控。

- 互联网金融服务，比如收集用户的注册信息、站内行为数据、用户的强行证明数据、用户手机装载的 APP 数据等，这些数据可以对每个人做 360 度画像，以及管控潜在的风险账号，比如多头借贷，多次违约等等，还可以基于建立的画像提供服务，包括评估个人还贷水平、违约等级等，根据评估来决定给用户提供对应的运营策略。

上面讲的比较概念化，下面详细讲解几个具体场景。

① 互联网 TOC——微信场景 (1)

互联网ToC—微信场景(1)



下面先看几个在微信中常见到的场景

渠道活码

用企业微信沉淀顾客，可以在每个渠道都附上带活码的渠道专属二维码。比如可以在自己的公众号、朋友圈广告、企业官网以及其他物料上都附上二维码，将前来咨询新老客户都引进到企业微信，这些客户会被随机分配给某个员工，这样既能保证员工工作的公平，又能避免单个员工当日加人达到上限的情况。



触发欢迎语

个性化推送一人一语
用户扫码添加企业成员后，自动推送指定消息。支持同一个码不同员工推送不同内容，帮助企业实现精细化运营，快速转化。



SOP 推送

基于给新加用户打的标签来实现定时推送个性化消息

Sop推送是微信私域运营的一个重要工具/手段。给不同类型的客户在不同时间段推送不同的内容



- **渠道活码：**用企业微信沉淀顾客，可以在每个渠道都附上带活码的渠道专属二维码，比如在自己的公众号、朋友圈广告、



企业官网以及其他物料上都附上二维码，将前来咨询新来客户都引进到企业微信，这些客户会被随机分配给某个员工，这样既能保证员工工作的公平，又能避免单个号当日加入达到上限的情况。用户在扫码过程中会被自动打上标签，标识渠道来源。

- **触发欢迎语：**给用户打上标签，标识渠道来源之后，可以触发欢迎语。用户扫码添加企业成员后，自动推送指定消息，可以实现个性化推送一人一语，支持同一个码不同员工推送回复不同的内容，帮助企业实现精细化运营，快速转化。
- **SOP 推送：**SOP 是 Standard Operating Procedure（标准化的运营流程）。SOP 推送是微信私域运营的一个重要工具/手段，可以给不同类型的客户在不同时间段推送不同的内容。比如基于给新加用户打的标签来实现定时推送个性化消息，当用户扫描渠道码后，打上线上新人标签，后台先配置好运营推送策略，定时推送内容拉动活跃。

② 互联网 TOC——微信场景（2）

基于群、基于个人的个性化 SOP 推送包括先给人或者给社群打标签。创建任务给不同标签的人或者社群推送不同的个性化内容。比如基于一些标签创建某些定时任务，给某一批标签的人或某一




批标签的群做定时推送，维护整个社群的活跃程度，以及促进用户在不同阶段的转化。

互联网ToC—微信场景(2)

DataFun.

基于群、基于个人的个性化sop推送包括先给人、给社群打标签。创建任务给不同标签的人或者社群推送不同的个性化内容



截图自某SCRM厂商的功能宣传页



这里截图了某 SCRM 厂商的功能宣传页，我们都知道 CRM 是客户关系管理，SCRM 就是 Social CRM。

国内 SCRM 基本都是基于企业微信场景做的功能，常见场景：前期基于渠道活码、裂变获客、抽奖引流、自动标签、自动回复等的引流工作；后期基于标签、基于来源渠道，做定制化的高效沟通；高效沟通完成之后，SCRM 去做智能化的定向营销，比如 SOP 定向营销、个性化的群聊推送、个性化朋友圈。

在电商，零售，教育培训等不同行业，都有基于微信场景的 SCRM 产品做一些行业的东西。这种也是基于用户画像、用户标签做的一种应用，这种应用的数据量级比较轻，基于单机的应用就可以做后台的数据处理过程，这种小数据也是跨站的一种重要的组成



部分，也有很广阔的应用场景，我们日常接收到的一些快销产品的短信，很多也是基于轻量级的 SCRM 场景去实现功能。

③ 电商场景

电商场景包括如下几种：

- **短信推送营销**：比如在京东买过书、保健产品、在优衣库买过衣服后，商家会做定期推送。通常隔两三个月会收到推送短信，告知优惠信息，通知续买。还有像京东阿里平台的商家也会自建或采购第三方轻量级 SCRM 产品，把自身在京东淘宝的商铺数据接到第三方产品做定时的智能化营销推送以及邮件推送。
- **邮件推送营销**：邮件推送现在用的比较少了，当然也是很重要的场景，比如买了阿里云服务，经常收到阿里云定时推送的营销邮件。
- **Push 消息**：有几个应用场景，一是促活，根据用户浏览内容进行推荐，用户感兴趣点击查看，可以促进用户在站内的活跃；二是促进转化，当用户活跃度高之后，可能会多浏览广告或者带来下单转化。通常基于自己产品做 Push 消息配置是免费的，而像邮件短信则是有渠道成本的。

④ 安防场景



安防场景

DataFun.

安防场景能采集到的数据源非常多，包括物联网和信息网的数据。主要用途是抓捕坏人。

比如管控不当言论。



安防场景就在我们身边，保护我们的安全



比如识别、抓捕轰动国内的知名犯罪分子。



比如识别驾驶车辆的犯罪分子。



安防场景能采集到的数据源非常多，包括物联网和信息网的数据。主要用途是安防管控抓捕坏人，或者预防潜在的坏人做坏事。比如我们近期看到的抓捕犯罪分子新闻，基本是基于人脸识别来识别，然后再和后台预警管控的名单做实时数据比对校验，当比对相似度大于某个阈值时会触发预警，后续视情况进行人为干预。

这种安防场景在我们生活中有很多，比如识别不当言论去管控潜在的风险犯罪分子，以及去识别犯罪分子驾驶的车辆。人脸的面部识别、基于车牌号的识别其实都类似，都可以基于潜在风险的身份信息去做预警管控。

2. 关于画像场景的一些思考

① 画像场景总结起来，包括：

- 营销卖货：短信/邮件/电话/微信等各种渠道的营销来卖货。



- **营销促活**: 同样是各种渠道的营销来把用户拉/引到平台上, 有人活跃的地方就有流量就有生意。
- **个性化服务**: 这里不仅指个性化推荐(比如淘宝上推荐商品, 基于用户浏览或购买过兴趣类似或同类的商品, 比如抖音快手上基于看过的视频内容推荐相似内容), 也包括个性化的人工客服、个性化的接口服务。
- **用户分析**: 基于用户在平台上的行为特征来分析产品的优缺点、做产品迭代。
- **预警管控**: 基于不同行业不同应用场景来设计预警管控的模型, 实现对潜在风险的预警与预防。比如识别潜在的风险账号, 把账号直接拉黑名单; 比如直接识别出风险用户, 直接做人工的干预管控, 这也是预警管控, 基本是基于实时数据对前方风险去做预防。

② 一直在 toC 类型的互联网公司从事大数据类的工作, 接触到的用户量或行为日志数据都是大几千万、几亿、几十亿、百亿规模的数据处理, 用到的技术栈也是 hive、spark、hbase、es、clickhouse 这些梳理大量数据的开源工具。但不是只有大数据才能做画像。

③ 最近在研究基于微信生态的 SCRM 类产品时发现, 这类产品处理的数据量很小, 不需要很重的大数据生态组件, 但同样可以实现基于特定场景/生态下的客户营销管理, 同样有广阔的应用市



场。对接淘宝、京东等商家后台数据提供 CRM 功能的厂商也是，在画像这块处理的数据量有的用不上大数据组件。

02

画像产品功能


画像产品功能主要包括标签的元数据管理、单用户画像、人群筛选、人群分析等。

1. 标签的元数据管理

■ 画像产品常见功能(1)

DataFun.

标签的元数据管理 - 列表页



元数据管理来说，产品设计形态上可能会有各有不同，基于用户属性、用户行为，来做 123 级目录分类的标签元数据管理。



画像产品常见功能(2)

DataFun.

标签的元数据管理-详情页

在详情页可以查看标签的元数据信息，标签每天的产出量，标签在所属大类下的覆盖率等



在元数据详情页可以查看标签的源数据信息、标签每天的产出量、标签在所属大类下的覆盖率等。

画像产品常见功能(3)

DataFun.

在元数据编辑页面可以对目前平台上的标签信息进行编辑

添加标签

标签Id: A112_02_001 标签名称: 北京

一级大类: 用户属性 二级大类: 城市

标签类型: userid 标签类型: 分类

开发方式: 非算法 是否互斥: 互斥

是否在线使用: 使用中

标签介绍: 用户属性北京城市

取消 确定

标签Id	标签名称	一级大类	二级大类	标签类型	开发方式	是否互斥	是否在线使用	标签介绍
A112_01_001	性别	用户属性	性别	分类	非算法	互斥	使用中	基于广搜算法对用户性别进行统计方式聚类标签
A112_01_002	年龄	用户属性	年龄	分类	非算法	互斥	使用中	基于广搜算法对用户年龄进行统计方式聚类标签
A112_02_001	北京	用户属性	城市	分类	非算法	互斥	使用中	基于广搜算法对用户所在城市进行统计方式聚类标签
A112_02_002	上海	用户属性	城市	分类	非算法	互斥	使用中	基于广搜算法对用户所在城市进行统计方式聚类标签
A112_02_003	杭州	用户属性	城市	分类	非算法	互斥	使用中	基于广搜算法对用户所在城市进行统计方式聚类标签
A112_02_004	西安	用户属性	城市	分类	非算法	互斥	使用中	基于广搜算法对用户所在城市进行统计方式聚类标签
A112_02_005	深圳	用户属性	城市	分类	非算法	互斥	使用中	基于广搜算法对用户所在城市进行统计方式聚类标签
A112_02_006	广州	用户属性	城市	分类	非算法	互斥	使用中	基于广搜算法对用户所在城市进行统计方式聚类标签
A112_02_007	成都	用户属性	城市	分类	非算法	互斥	使用中	基于广搜算法对用户所在城市进行统计方式聚类标签
A112_02_008	天津	用户属性	城市	分类	非算法	互斥	使用中	基于广搜算法对用户所在城市进行统计方式聚类标签

在元数据编辑页面可以对目前平台上的标签信息进行增删等编辑。

2. 单用户画像



画像产品常见功能(4)

DataFun.

姓名: 用户甲

Userid: 10000619

cookieid: 000003

浙江省 杭州市

用户属性	
性别: 男	会员等级: 金卡会员
年龄: 26	操作系统: iPhone 6s
注册时间: 2017-03-02 18:00:00	历史购买次数: 6
历史付费金额: 1500	用户活跃度: 高活跃
RFM: 重要发展用户	购买品类: 多品类购买
购物性别: 男性	是否反馈问题: 否

用户行为	
近30日购买次数: 2次	近30日活跃天数: 12天
近30日购买金额: 200	最近下单距今天数: 18天
高频活跃时间段: 晚上	push周活跃度: 3天
是否短信黑名单: 否	订单优惠券使用率: 33.3%
是否邮件黑名单: 否	首单距今天数: 300天

```

data: {cookieId: "33081546482745740",...}
allTags: [{tagType: "用户属性", tagLevel: "性别", tagId: "男性", tagWeight: ""},...]
0: {tagType: "用户属性", tagLevel: "性别", tagId: "男性", tagWeight: ""}
tagId: "男性"
tagLevel: "性别"
tagType: "用户属性"
tagWeight: ""
1: {tagType: "用户属性", tagLevel: "城市", tagId: "西安", tagWeight: ""}
2: {tagType: "用户属性", tagLevel: "行为特征", tagId: "高投诉用户", tagWeight: ""}
3: {tagType: "用户属性", tagLevel: "RPM价值", tagId: "一般保持用户", tagWeight: ""}
4: {tagType: "用户属性", tagLevel: "会员类型", tagId: "赠送会员", tagWeight: ""}
5: {tagType: "用户属性", tagLevel: "注册状态", tagId: "未注册", tagWeight: ""}
6: {tagType: "用户属性", tagLevel: "历史购买状态", tagId: "未购买过", tagWeight: ""}
7: {tagType: "用户属性", tagLevel: "活跃度", tagId: "高活跃", tagWeight: ""}
8: {tagType: "用户属性", tagLevel: "新老客户", tagId: "新客户", tagWeight: ""}
9: {tagType: "用户行为", tagLevel: "首单营销方式", tagId: "首单新人价商品", tagWeight: ""}
10: {tagType: "用户行为", tagLevel: "渠道黑名单", tagId: "push黑名单", tagWeight: ""}
11: {tagType: "用户行为", tagLevel: "高频活跃时间段", tagId: "晚上", tagWeight: ""}
12: {tagType: "用户属性", tagLevel: "购买状态", tagId: "购买客单价", tagWeight: "78"}
13: {tagType: "用户属性", tagLevel: "购买状态", tagId: "下单次数", tagWeight: "4"}
14: {tagType: "用户属性", tagLevel: "购买状态", tagId: "累计购买金额", tagWeight: "312"}
15: {tagType: "用户属性", tagLevel: "购买状态", tagId: "最近一次购买距今天数", tagWeight: "45"}
    
```

单用户画像，我们给每个人打上标签后，在运营时或通过接口形式输入用户 ID，可查询到这个人的全量标签。

应用场景大致两种：一种是分析场景，即分析师/业务人员基于一个或某几个用户 ID 做具体的查询分析，这种通常是公司内部业务后台作为分析自用；另一种是客户端接口调用，即通过线上服务接口请求方式传入用户 ID 查询标签，这涉及到高并发。这两种应用场景，对数据服务能力要去是不一样的，前者不涉及并发，后者涉及高并发，需要单独部署两套。


3. 人群圈选



画像产品常见功能(5)

DataFun.

人群圈选



基于标签组合及标签的规则定义进行人群圈选，即基于维护的标签元数据信息、组合标签及条件筛选、即席查询符合特征覆盖到的人群数量、保存查询条件下用于下阶段的运营推送。

4. 人群分析

画像产品常见功能(6)

DataFun.

人群分析

基于保存的人群，可以从多个维度透视分析人群特征。分析维度可以通过预制设定来自动生成分析报表，也可以通过下拉框的形式自主筛选






人群分析：可以从多个维度透视分析人群特征。分析维度可以通过预制设定来自动生成分析报表，也可以自主筛选。选择分析人群、选择分析的维度、分析的结果，可以进一步查看对应的用户列表和标签详情。

5. 行为分析

画像产品常见功能(7)



- 1、行为分析模型是基于分析场景对数据的抽象。例如常见的留存分析、事件分析、分布分析、漏斗分析等等，本质上是基于用户行为日志+用户属性数据，来对用户从多个分析维度进行分析。**直白些说就是将分析师常写的分析SQL 固化成产品和数据模型来实现，省去人工介入的时间**
- 2、现阶段还没有做行为日志的采集，一方面需要把日志这块缺漏补起来，另一方面 TO B 的行为分析模型和互联网 TO C 的这些分析模型也不尽相同，**对于TO B经常需要做哪些分析还需要分析师整理提炼出来，来一起把这些常用到的分析固化成分析模型的产品**



行为分析模型是基于分析场景对数据的抽象。例如常见的留存分析、事件分析、分布分析、漏斗分析等等，本质上是基于用户行为日志+用户属性数据，来对用户从多个分析维度进行分析。直白说就是将分析师常写的分析 SQL 固化成产品和数据模型来实现，省去人工介入的时间。

现阶段还没有做行为日志的采集，一方面需要把日志这块缺漏补起来，另一方面 TOB 的行为分析模型和互联网 TOC 的这些分



析模型也不尽相同，对于 TOB 经常需要做哪些分析还需要分析师整理提炼出来，再把常用到的分析固化成产品。

6. 基于标签的 SOP

画像产品常见功能(8)



基于标签的SOP是标准化运营流程，例如SOP在SCRM产品的场景中，基于企业微信给微信用户打的标签，通过设置给这些标签用户制定的运营策略来实现自动推送消息



基于标签的 SOP 是标准化运营流程，例如 SOP 在 SCRM 产品的场景中，基于企业微信给微信用户打的标签，通过设置给这些标签用户制定的运营策略来实现自动推送消息。

03

技术实现方案

1. 画像系统整体数据流程

画像系统中最重要的环节除了理清应用场景外，就是要理清整个系统的数据流向。




从项目全貌来说，我们首先是收集日志和属性数据，从线上业务库抽取业务数据、或从日志服务器抽取日志数据，把抽取的数据放到数据仓库里。然后基于收仓的数据打标签、建模和行为主题的宽表建立。数据仓库层面一般分多层，比如 ods 做基础标签，dws 层做直接推送到服务层的数据。

业务数据库接入的数据、爬虫外部抓取的数据都放在数仓的 ods 层。基于 ods 层数据围绕应用场景进行数据建模后，把数据模型结果写入到 dws 层，然后推送到各服务层需要调用的数据库，以备线上 OLAP 分析、接口服务的调用。

画像系统整体数据流程

DataFun.



2. 画像系统的蓝图


画像系统的技术蓝图包括标签规划、数据开发、应用场景等。画像系统最终上线后，是一套完整的数据模型和应用流程。后续新增的标签或应用场景可以在现有的框架内增加流转起来。



画像系统的蓝图

DataFun.

画像系统最终上线后，是一套完整的数据模型和应用流程。后续新增加的标签或应用场景可以在现有的框架内增加流转起来



- **标签规划:** 由产品经理或业务人员基于公司的业务场景把整个标签体系梳理出来。
- **数据开发:** 由数据开发人员或数仓人员基于梳理好的标签体系开发对应的标签，跑离线标签以及跑实时任务。就数据开发来说，实时数据和离线的大部分标签都是 T+1 的离线标签。离线标签又分为基于统计类型的标签和基于算法性标签，大部分或者 90% 的标签都是统计类型标签，像机器学习的算法标签很少，一方面是开发周期很长，另一方面效果也有限。但是基于某些场景，还是得需要使用机器学习，只是机器学习标签的比重会很小。有时我们做实时数据支持，会通过实时数据流给用户做刻画或者做特征标记，可做线上服务接口调用查询。用户维表是一张大宽表，大宽表基于筛选用户的属性或分析师分析用户的时候用。除了标签跑批、用户维表，还有人群计算、行为数据等的数据开发。



- **应用场景：**开发完数据后，再推送到应用场景，包括人员 360 视图、人群圈选、人群分析、SOP 运营、内容推荐等场景。我们基于应用场景做迭代效果反馈之后，再反馈给标签规划以及数据开发，再优化数据标签以及数据开发的流程，这是整个应用的蓝图。

3. ETL 调度模型示例


ETL 调度模型包括标签的加工计算、数据标签的校验、人群计算、跑一些分析宽表。跑完数据模型后，推荐到线上服务层，比如 Redis、Clickhouse、ES，分到服务层做服务的调用，包括站内的服务调用以及 TOC 的客户端服务调用。

站内的服务调用即公司内部的运营或产品人员用于分析、用于营销；TOC 的客户端服务调用则是浏览页面点击时产生请求，客户端调用涉及到高并发的场景，需要单独处理接口服务。



ETL调度模型示例

DataFun.



4. 技术栈划分

画像系统技术主要包括大数据+应用服务。大数据从存储类型、开发语言、开发内容来了解；应用服务从技术选型与框架、开发内容来了解。

技术栈划分

DataFun.

画像系统技术主要包括 大数据+应用服务

	大数据	应用服务
存储选型	MySQL Hive Es/clickhouse	技术选型与框架
开发语言	HiveSQL Scala Python(爬虫)	JAVA语言、SpringBoot框架
开发内容	用户维表数据 标签数据 用户360视图数据 用户行为数据 es或clickhouse等大数据组件的部署	开发内容 接口服务开发，包括标签管理、360视图画像、人群圈选、个性化内容推荐等

5. 技术栈难点



技术栈难点分两块来说明：

- 第一块是**大数据**，从查询速度来讲，画像相关的查询有很多场景，比如单用户画像查询、基于行为事件的分析、组合标签查询、实时查询等。不同的场景需要考虑到用不同的工具去存储，比如 es 适合关键词检索、redis/hbase 适合单用户查询、clickhouse 适合多维度 OLAP 分析等；从调度时间来考虑，用户基数规模较大的公司一般每天日志量很大，跑标签计算、跑数据服务的时间也会相对的较多。需要做一些优化来减少数据调度时间。
- 第二块是**应用服务**，从后台应用来说，后台应用就指单用户画像、行为时间分析、标签管理等方面的产品端，这块一般没有什么难点，就是后台应用的增删改查，面向的使用者也是企业内部人员；从数据服务角度，指标签画像数据的接口调用，比如线上服务请求某用户的标签数据。如果是热门应用的话，每天画像标签的接口请求就是一个高并发的问题，需要考虑用 redis、hbase 等工具去解决。

04

精彩问答



Q：咨询用户画像跟个人信息保护、数据安全方面的问题，在做技术底层架构的时候，数据安全有些什么措施？

A：就数据安全来说，在采集数据上，不是特别涉密、涉及敏感信息的数据会进行采集。但在标签应用查看权限上，技术上通过接口实现不同权限来控制。比如不同用户分组对应不同的权限，可以查看分组下对应的标签，通过这种方式控制内部的数据安全。

Q：公司已有推荐系统且有标签，公司还想建设标签画像中台。想咨询中台标签画像和标签系统的标签之间的关系应该是什么样的？

A：这个问题可能是局限于公司内部的问题，不是通用性的问题。可能是有的公司比较大，不同的部门牵头做一套自己东西，做的东西有冲突了。

Q：从最初的建立标签体系，比如第二级标签分组，除了梳理行业的竞品、客户的实际业务情况，还有没有其他维度或常见的体系方法论？

A：一般是基于自己公司的业务场景去梳理指标体系。梳理标签体系，一般由各个业务部门人员提需求，以及产品经理出需求。在开发过程中，根据使用情况不断地做迭代。现在市面上也有专门讲标签类目体系的书籍，专门讲如何面向业务去梳理标签体系。



Q：对于离线跟实时的标签，应该如何合理的处理？实时标签应该怎么做？

A：大部分场景基本 90% 多都是基于离线标签去做。实时标签是给用户推送一些实时的东西，但可能不一定基于标签的方式去做。就离线标签来说，我们给用户打上标签，然后再去做一些筛选及推送；实时场景则可能直接通过任务计算好了，并把计算出来的这批用户推送到对应的地方供调用。

今天的分享就到这里，谢谢大家。扫码观看本文视频回放。





网易数据部用户画像实践



分享嘉宾：张长江 网易 大数据技术专家

编辑整理：黄乐平

出品平台：DataFunTalk

导读：网易大数据生态数量级巨大，且产品线丰富，覆盖用户娱乐、电商、教育等领域，并且 APP 活跃度高，积累了多维度的用户行为数据。通过集团数据资产构建全域用户画像，旨在服务于域内众多业务场景，同时也在探索外部商业化方案。今天借此机会，同大家分享下网易在大数据用户画像中的实战应用经验。



今天的介绍会围绕下面三点展开：

- 网易生态数据介绍
- 用户画像中心分类
- 网易用户画像实战案例

01

网易生态数据介绍

整个用户画像实践经验，都依赖于网易易数中台，所以首先给大家了解下网易生态数据情况。

1. 网易数据总览



网易数据总览特征如下：



- 数据量超亿级，每日上亿级账号活跃，可触达同人；
- 服务场景多，生态较为复杂，覆盖多行业产品线，包括游戏、教育、电商、泛娱乐等；
- 优质用户平均标签覆盖率达 70% 以上；
- 提供包括但不限于参与人、流量域、位置域、关系域等主题域解决方案，即能够封装用户画像在主题域的通用化模块。

2. 网易产品线丰富




网易产品线丰富，覆盖从用户娱乐、电商购物、教育、新闻资讯等各个维度用户行为数据，APP 活跃度高，涵盖用户群广。项目组整体目标是通过集团数据资产构建全域资产用户画像，



已应用于网易生态圈内众多业务场景，同时探索产品化及方法论，服务于生态圈外部合作机构，进行商业化操作。

3. 全链路数据中台产品矩阵



全链路数据中台产品矩阵，包括底层日志等数据源层，数据平台加工层，整体标签的离线或实时加工、挖掘算法及监控，以及上层业务应用，如智能分析、增长运营、推荐搜索等一系列业务层应用，组成了网易数据中台产品矩阵。网易易数产品矩阵，为网易用户画像起着极为关键的支撑作用，尤其是数据标准体系、数据治理平台等模块，很好的承载着用户画像落地和质量保障。

02

用户画像中心分类



首先介绍下杭研用户画像整体数据架构及落地情况，主要分为三部分：其一为基础的用户画像，基础标签（如性别、年龄）、行为统计（如活跃）、兴趣偏好及预测等标签；其二为关系库部分，即 IDMapping；其三为主题域部分，即对地域、社交、搜索关键词等相关方面的工作。

1. 网易数据架构



网易整体数据架构底层与各个业务方进行数据交换合作，共同建立公共数据中心，以数仓为蓝本进行架构。

中间层为用户画像中心：

- 用户标签的分类包括基础标签、行为标签、偏好标签以及预测标签等，不同公司分类方法略有不同，如根据更新周期，分为静态标签（性别等）和动态标签（年龄



等)；偏好标签包括用户的长中短期偏好等，预测标签主要应用于广告投放部分，例如游戏达人，高价值用户群等。

- 关系库主要是 IDMapping，目前已经有较多的方案论和解决方案，例如多账号的归一用于后续的业务数据挖掘工作，提升对用户的识别能力。典型场景为两个手机号对应只有其中一个有过注册行为信息，另一个没有注册行为信息，但对于上层而言，应该打通他们作为同一个行为主体。关系库主要包括同机网络（同一设备多个 ID 的关系）、同人网络（同一个人多个设备信息）以及社交关系（人与人之间的关系）等。
- 主题域主要包括地域数据、广告数据、关键词和知识库方向，其中知识库和图谱数据，主要应用于网易域内外内容知识打通。

顶层的应用场景包括增长运营、推荐搜索、广告变现、营销系统、用户反欺诈及内容运营等方面，对业务方提供全方位的服务，不局限于单一应用场景。还有数据规范和数据管理部分，作为数据标准化，沉淀经验方法论。

2. 网易用户画像构建流程



用户画像整体构建流程依托于网易易数中台，搭建起完整的业务数仓体系，融合多方业务数据源。经过多年的探索实践，已经形成完整的用户画像体系，从数据层面到产品层面，逐渐打磨，提供标签管理、监控、报表、算法、开发及权限管理，融合在各业务产品体系。诸如关系图谱形成 API 的接口服务输出各业务方；数据服务包括人群圈选、人群分析等运用于市场及运营团队；特征库方面描述了用户向量化的特征相比标签粒度更为细腻，适用于算法团队迭代开发。在此基础上沉淀了多种数据应用，包括增长运营、广告 DMP、智能风控等方面。

3. 网易用户标签



目前整体总标签数达 1000+，其中不包含单一业务行为数据。

标签分类如下：

- 基础标签，即对用户的自然属性描述，例如性别、年龄、教育背景、生活习惯（早起晚起）、地理位置（POI 信息）、职业状况（所属行业）、经济情况（有车有房）、设备信息（手机、运营商等）、会员信息（各业务方会员等级）、衍生信息。其中衍生标签，如评估是否已婚，在原有的标签体系下没有此类标签，但可以通过对多个标签进行组合生成新的标签，包括是否有小孩、30 岁满足某个条件等。
- 行为标签包括地域、广告、搜索、全域、播放、点击、评论、关注、收藏、购买等维度。



- 偏好标签包括出行购物、手机数码、家装家居、教育公益、文化娱乐、新闻资讯、金融理财、游戏竞技、动漫影视、明星艺人等维度。
- 预测标签包括利用算法等进行预测生成的标签，包括是否出行，是否买车等等。

另外，标签的枚举值也相当重要，业务分析过程中很容易出现枚举值的偏差，不符合实际业务逻辑。除此之外还包括标签间的冲突，例如年龄 15 岁，学历却是博士或者有小孩，策略类标签是标签领域较为有挑战性的地方。



用户标签案例：性别。主要包括三种方案，其一为标签传播，根据用户在各个业务场景，例如母婴商品点击行为标签等进行 item 标记，构建 User-Item 的兴趣网络进行 Graph Embedding，最后进行分类预测用户的性别；其二为利用 NLP 算法对用户



的昵称进行语义分析；其三为利用业务属性自行填写的内容进行判断，此处需要对数据质量进行过滤，排除诸如出生为 1990-01-01 的参数异常值信息。基于上述的三类算法特征结果集进行模型的融合，然后对用户的性别进行预测，同时判断该用户性别的准确率，大部分准确率在 0.6+ 以上可以应用于实际业务场景中。当然除了常见的算法融合，还包括数据融合、特征融合等等。其中需要突破的地方包括特征的稀疏性，因为 IDMapping 打通后的数据覆盖率仅 20% 左右，这个严重影响了模型的整体效果。

4. IDMapping

**IDMapping**



- 1 国家个人信息监管越来越严，用户设备ID采集越来越难，帐号打通面临巨大挑战
- 2 不同业务方对设备ID类型需求不同，如果请求的设备类型与数据源中数据类型不一致，会导致无法获取数据。
- 3 同一用户/设备包含不同的设备ID且ID间没有完善的映射关系，导致无法完整描述一个用户的画像。
- 4 不同情境下，所谓标识用户的“帐号”可能有较大的歧义，需要有所区分。

IDMapping 主要指用户设备的打通，用于识别用户的唯一性，现今采用的手段有两种，其一通过工程层面打通，如 SDK 埋点，优点是准确率较高，缺点是还会存在一人多机等现象，导



致了不能够较好地完整描述一个用户画像；其二指数据层面打通，通过 ID 关系网，采用规则和算法结合的方法，进行同人识别，优点是很好解决一人多机现象，缺点是准确率难以评估。本次分享，主要指数据层面打通。

IDMapping: 思路 and 方案

思路及方案

- 结合各种账户、各种设备型号之间的关系对，以及设备使用规律（时间和频次）等用户数据
- 采用**规则过滤**+**数据挖掘算法**（连通图划分+社区发现）判别账号是否属于同个人

可能遇到的问题	解决思路
用户可能有多个设备	使用过一定次数的设备才和账户关联
设备会过期失效（僵尸设备）	设定一个设备未使用时间衰减函数，对同时拥有多个设备的账号加大衰减力度
异常数据	需要识别出一些场景并过滤： 1. 借用朋友设备 2. 记录设备数据格式错误；有脏数据 3. 刷号等行为

识别结果示意

网数易数

疑似关联账户

- dark...bie3@16...
- dar...bie@qq.c...
- jies...373@126...
- dar...bie2@16...
- dar...bie@foxm...
- 138...247
- dar...bie@163...
- dar...bie1@16...
- aebfqdc...5ac...
- cy2...gnet.com
- yd18461787b1b18...

IDMapping 整体的思路及方案，具体要结合各种账户、设备之间的关系对，以及设备使用规律等用户数据，利用规则过滤+数据挖掘算法（连通图划分及社区发现）判断账号是否属于同人。在 IDMapping 过程中，常遇到的问题及对应解决方案如下：

- 用户有多个设备信息，定义相应的阈值进行关联。当然，社区发现当前应用于营销场景，暂没有用于风控或用户运营等场景，因为会把一些异常的账号关联在一起，且会存在仅登录使用过一次的设备信息。



- 设备过期（一般在 2 年半左右时间），设定衰减系数，对单用户多设备加大衰减力度。
- 当然也会存在一些异常数据信息，通过算法识别出包括但不限于以下场景，诸如借用朋友设备、设备脏数据、刷号等行为轨迹。



IDMapping 的存储方式包括两个 ID 类型（关系对）、最近采集时间、最早采集时间、采集源数据、采集源列表、采集的频次和周期。其中共线关系的部分增加了时间衰减系数，同步递减应用于结果，同时也增加了某些参数的权重部分用于提高业务的可选性和高可性。

5. 地域主题域




地域主题域可以挖掘用户的需求信息，包括是否有车，是否经常去 4S 店，通过 WIFI、设备等信息获取亲戚、同事等关系，通过 IP 可以捕获学校的学生信息，根据作息规律进行统计。当然除此之外，地域主题域还用于反欺诈领域，针对黄牛等用户群进行修改地域参数信息，规避系统检测。

6. 用户画像管理与存储



用户画像管理与存储在网易大数据经历了多次迭代，包括前期字符串的拼接、手工标签命名、明文关联维表，再到现在利用JSONArray格式进行标签类型管理，这种有个比较大的缺点，就是存在冗余严重，正在尝试新的方案设计。

7. 质量校验与保障体系





网易标签包含真实的用户数据及特征用户数据，利用无监督的算法模型预测姓名、年龄、有车、有房等，利用有监督进行提升数据质量，提升标签的整体效果。主要包括三方面的工作：

- 利用实名认证数据，作为高可信的样本集；
- 利用强特征用户数据，通过 GPS\IP 等用户行为数据；
- 利用外部数据，增加高置信用户数据质量。

除此之外，还包括利用一些常见的算法，例如交叉验证准确率和召回率，线上 ABTest、算法离线验证、运营活动验证、真实数据验证等等方案。



质量保障标签管理方法论，包括以下四点：



- 每个标签定义第一责任人，用于快速响应业务需求，同时处理标签异常问题；
- 流程优化，标签的流程较为漫长，需要了解业务、算法、开发的全流程，利用端到端的模式，通过快速响应增加标签规范化的评审工作；
- 测试监控方面，测试在标签上线前对标签规范和质量输出测试报告，预测则是针对规范、枚举值等范围，建立监控预警机制；
- 管理平台化，则是标签生产、加工、处理、应用全流程体系化、标签化、工具产品化，不断迭代升级。

03

网易用户画像实战案例

最后和大家介绍下网易用户画像实战案例。

1. 应用场景丰富



网易用户的多元化数据，能够精准定位用户，覆盖范围广，包括但不限于以下业务目标场景：

- 市场营销：为人群圈选、人群洞察等提升营销价值；
- 推荐搜索：为网易算法团队提供数据输入；
- 增长运营：为用户研究、数据运营等提供数据支撑；
- 广告投放：为广告主提供人群定向投放功能；
- 智能风控：为营销反欺诈，诸如薅羊毛、资金风险、异常用户识别提供特征算法服务。

这里重点讲解下营销反欺诈薅羊毛案例，此类用户资源池有限，通过频繁地切换 IP、WIFI 等设备信息，规避风险。利用用户画像及其特征，切入智能风控，能够提升 6% 的风险用户识别

率，同时结合知识图谱、IP 黑名单、异常设备等方面的数据信息，能够较好地扩大数据价值。

2. 用户画像案例



通过覆盖用户出行、娱乐、设备、购买、地址等维度数据，基于基础标签、事实标签以及预测标签等标签，应用于上述提及的多个业务场景中。通过用户画像，可以知道用户偏好，购买相关等偏好信息。

3. 实时全链路推荐案例



网易用户数据服务实时方案，打通各个业务场景的数据孤岛信息，实时融合用户的数据资产，深度洞察分析用户属性信息，支撑各个业务间数据打通和服务，实现了"采集+计算+调用"的实时全链路体系。例如，在冷启动新客阶段，利用用户画像能力，将离线特征放进 HBase 中进行实时计算，在多业务场景进行交叉，全链路支撑各业务数据打通和服务，为业务方提供二次服务。另外，利用实时用户画像结合知识图谱捕获用户行为轨迹，避免用户流失后造成的无购买、点击等行为，进行二次触达，增加业务转化效率。

4. 总结



网易数据用户画像中台显著提高了数据生产力，逐步沉淀方法论和产品，赋能域内众多业务场景，探索外部商业化解决方案。

今天的分享就到这里，谢谢大家。



网易严选画像建设实践



文章作者：卢若浩 网易严选

内容来源：作者授权

出品平台：DataFunTalk

导读：在数字化转型的浪潮下，企业越来越重视自身数据资产的沉淀和应用。画像作为一种重要的数据资产形式，受到了越来越多的关注。网易严选作为一家自营电商，业务链路长、场景多，所涉及的核心业务实体也多，如用户、商品、供应商、渠道等等。通过画像去洞察这些业务实体对企业精细化运营有着重要的帮助。基于此背景严选打造了具备行业特色的标签和



画像中台。本文的主题为网易严选画像建设实践，主要介绍严选标签和画像中台的工具和方法论。

01

关于标签和画像

1. 什么是标签和画像

标签：

标签是对业务实体某个维度特征的刻画和描述，是一种面向业务的数据组织形式。例如，我们在大众点评上看到某家店是“必吃店”，这就是一种标签，又或者某部电影在豆瓣上的评分，这也是一种标签。

画像：

画像是对业务实体多个维度特征的刻画和描述，是多个标签的集合。例如，在游戏中每个角色都有自己的力量、智力和敏捷属性，这就是角色的画像，这个画像由力量、智力、敏捷这三个标签集合而成。

2. 标签和画像的价值

标签：



- 提供信息：标签的本质还是数据，数据的价值在于提供信息，进而提升决策的科学性和准确性。企业的运营主要围绕业务对象和业务活动，所谓的精细化运营，无非是通过信息，来区分对待业务对象和业务活动，而标签可以很好地承载信息，是精细化运营的重要工具。
- 面向业务：标签是面向业务的一种数据组织形式，可以让业务直接用起来，帮助业务从“看数据”变成“用数据”，真正意义上起到数据驱动业务。

画像：

画像作为标签的集合，可以综合提供多维度的正交信息，帮助我们更准确、形象地洞察实体。

02

为什么要建设标签和画像中台

严选建设标签和画像中台主要是两个目的：解决共性需求（用户价值）和加速数据资产化及价值落地（商业价值）

1. 解决共性需求

目前行业中的标签和画像主要都是用户标签和用户画像，其应用场景主要是精准营销和消费者洞察。



严选的业务场景较多，如消费者洞察、供应商寻源、爆品打造等，涉及到的核心业务实体比较多，如用户、商品、供应商、渠道等等。



这些业务实体都存在建标签、用标签和看画像的需求。比如在营销活动的时候需要基于用户标签去圈用户、看用户画像，在为商品寻找优质供应商的时候需要基于供应商标签去圈供应商、看供应商画像等等。

2. 加速数据资产化及价值落地

前文有提到，标签作为面向业务的数据组织形式，可以更直接、有效地创造数据价值。通过建设标签和画像中台可以更快地构建标签，更全面地管理标签以及更便捷地使用标签。

03

标签和画像中台工具



1. 产品简介

严选标签和画像中台定位为提供从数据管理、标签萃取、洞察分析的全流程数据驱动能力，下图为严选标签和画像中台的产品大图：



2. 功能特性

严选标签和画像中台主要分为数据管理、标签萃取、洞察分析三个功能模块：

① 数据管理

数据管模块目的是统一管理业务实体及其全域数据，为标签萃取提供数据源，核心是以下两个功能：

- 业务实体的管理：包括实体的命名、主键标识等

- 多种数据源的导入和管理：支持 hive、kudu、es、hbase 四种数据存储引擎，不同的标签数据存储引擎主要是为了满足不同的场景

下图为不同存储引擎的适用场景：

存储引擎	优势	适用场景
Hive、Kudu	适合大数据量的批量作业	离线分组和画像的计算
Es	近实时地存储、检索数据	实时分组和画像的计算
Hbase	高性能的线上接口实时查询	标签结果的查询

严选标签数据源包括一方和二方数据，数据经过统一的加工处理后存储在数仓 DM 层的标签数据表中。

- 一方数据：来自于严选域内各个业务过程的数据，包括但不限于行为日志、统计指标、预测模型等。
- 二方数据：来自于网易集团层的共建数据，包括但不限于网易传媒的广告数据、网易云音乐的用户行为数据等。

② 标签萃取

标签萃取模块目的是将数据快速、灵活地萃取为标签。

为了满足更灵活的标签需求，我们将标签划分为基础标签和复合标签。前者可以是任意数据类型，使用起来可以自定义规则



和参数，后者是布尔值类型，规则和参数已经定义好，两者的实现过程及存储方式都有所不同（限于篇幅此处对技术方案不做介绍）。例如，【年龄】是一个基础标签，【年龄介于 20~30】是一个复合标签。

基础标签的萃取方法：

- 关联表字段：通过直接关联数据表中的字段创建标签，这也是标签最主要、直接的萃取方式
- SQL 自定义：基于已有的标签构建计算字段作为标签，例如已有【销售额】【成本】两个标签，可以构建出【利润】标签（利润=销售额-成本）

复合标签的萃取方法：

- 可视化建模：通过可视化界面自由组合海量标签创建新的标签，实现 0 成本标签自助生产，快速满足业务需求。例如，我们要构建一个【有孩子、近 7 天有高消费且未待业的家长】，可以按照下图的规则建模：



基础信息

规则配置

预览/保存

上一步

下一步

规则配置

计算数量

与

包含以下全部特征

育儿情况

育儿情况 = 有孩子

明细集合筛选组

消费明细-订单金额

求和(消费明细-订单金额) > 10000

与

包含以下全部特征

消费明细-订单支付时间

消费明细-订单支付时间 = 近7日

非

排除以下任一特征

职业

职业 = 待业

基础标签

复合标签

我的收藏

请输入关键词

基础属性

用户行为

用户偏好

明细数据

全部

自然属性

社会属性

消费水平

账号/设备属性

标签名称

标签描述

消费水平

初中及以下、高中中专技校、大专、本科、硕士、博士及以上、海外高校

教育水平

有车、无车

有车

已婚、未婚、未知

婚姻状况

格式：1982-3-28

出生日期

如果是某月23日出生，则输入23

生日

专业人士、公务员、其它、学生、待业、私营主、经理、职员、退休

职业

国家

■ 手动、接口打标：除了规则建模以外，还会有些来线下/三方的数据以及一些事件驱动类的打标需求（例如，供应商在完成审核入驻后需要立刻给该供应商打上标），这些情况下需要业务同学手动打标或者业务系统通过接口来打标。

③ 洞察分析

洞察分析模块目的是通过标签圈选实体，通过画像洞察实体。

实体圈选：

实体圈选分为标签圈选、手动上传、分组加工三种方式：

- 标签圈选：通过海量标签的组合来圈选实体
- 手动上传：上传包含实体 ID 的文件作为一个分组



- 分组加工：基于已有的分组做高级计算（交并差计算、分组提取）

画像分析：

画像可分为个体画像和分组画像，个体画像就是个体的标签结果集合，较为简单，此处略过，本节主要介绍画像的具体功能。

多种分析类型：


- 画像的分析类型可分为：单标签属性分布、多标签交叉分析
- 单标签属性分布：某个标签的各个属性值的分布，如人群的性别分布
- 多标签交叉分析：以某个标签为维度分析另一个标签，如不同类目商品的销售额分布

分组对比及 TGI 分析：

- 分组对比是画像常用的一种分析方法。在选取目标组和对照组后，通过对比我们可以看到两个分组的差异性。
- TGI 作为度量差异性的重要指标可以让我们更直观地看到目标组的显著特征 ($TGI = \frac{\text{目标分组中具有某一特征的实体数}}{\text{总体中具有某一特征的实体数}} \times 100\%$)



所占比例/对照组中具有相同特征的实体所占比例]*标准数
100)



画像模板和自定义画像信息：

画像模板是一些固化下来的常用画像分析思路，便于快速浏览画像；而自定义画像信息则为了满足画像分析的个性化需求。

04

标签和画像中台方法论

在有了工具之后就是着手去搭建并应用标签和画像了，本节主要介绍标签体系建设和画像应用的方法论以及严选实践的一些具体案例。



1. 标签体系建设

从 0-1 搭建标签体系有两种方式,分别是自下而上和自上而下,在实操过程中往往这两种方式结合运用。

① 自下而上

自下而上的标签体系建设方式分为产技主导和业务主导,产技主导主要负责标签体系冷启动的问题,业务主导主要负责标签体系的自增长

产技主导:

在标签体系从 0-1 的起步阶段,可能很多业务同学不清楚什么是标签,标签能用来做什么,对他的工作有什么帮助。那么这个时候可以由产技同学主导,选择 1-2 个核心场景切入,明确这个场景中的角色、流程、需求、痛点,思考在这个场景下如何通过标签去辅助业务,以及如何量化标签的价值、预估标签可以产生的价值。

在和业务同学沟通确认后,推动这个场景落地。业务同学在有了实操体验后自然会对标签有一定的认识,会举一反三联想到其他哪些场景也能用到标签(这一步业务同学一定比产技同学反应快得多),进而逐步切入到其他场景,渐渐地从产技主导过渡到业务主导。



案例：例如，在从 0-1 搭建供应商标签体系的时候，可以先主动调研供应商相关的核心业务场景，如供应商寻源，然后明确供应商寻源的具体业务规则，进而推导出哪些标签

会有帮助，如“供应商评级”、“采购降本比例”等等标签，最后推动标签落地。

业务主导：

业务主导指业务方有某个具体的运营策略，需要由标签来辅助完成，这类标签的建设和落地会容易的很多。

案例：例如，营销的同学要挽回高价值的流失人群，那么就需要有用户价值、用户流失概率等签，有了这些标签我们就能圈出这部分用户，再结合这部分用户的画像，就可以输出一些的营销策略。

② 自上而下

业务运转机制服务于商业目标，业务运转机制中两条主线就是业务流程和业务对象的生命周期，我们可以通过这两条线结合具体的商业目标和运营策略来自上而下构建标签体系。

按照业务流程拆解：



首先要明确企业的业务流程，例如零售企业的基本业务流程可以分为：设计研发-生产-营销-仓储-配送-售后，然后基于商业目标推导每个环节的运营策略。

案例：例如，当我们要降低供应链成本的时候，对应到仓储环节就是要降低库存持有成本，然后我们会有一系列的运营策略来管理库存，比如销量的预测、库存的监控、动销情况等等。基于这些具体的策略我们可以推导需要哪些标签，比如在预测商品销量时，我们需要商品的季节标签、历史销量标签等等。

按照业务对象的生命周期拆解：

业务对象的生命周期和业务流程穿插在一起，且可以从多个维度去拆解。以用户为例，我们可以按照 AARRR、AIPL 等生命周期模型拆解。同样的，我们基于商业目标拆解到每个生命周期的具体运营策略，进而推导出需要哪些标签。

案例：例如，对于流失期的用户，具体的运营策略是一系列的召回措施，那么就会用到用户最近一次购买时间、商品兴趣偏好、优惠圈敏感度等等标签。有了这些标签后，我们可以把运营策略做进一步的精细化，例如，有明显品类偏好的用户通过品类的上新/促销活动来召回，对优惠圈敏感度高的用户可以通过优惠券召回。

2. 画像应用



画像是一个火了很久的概念，画像功能看起来很酷炫，但是大家普遍会觉得这个东西没有实际用处，所以画像到底要怎么用呢？


画像应用的核心在于，通过对比发现显著特征并转化成具体的运营策略。常见的画像分析方法有以下几种：

① 分组内特征对比

分组内特征对比指分析单个分组内各个特征的分布情况，这也是目前用到最多的画像分析方法，比如分析某个人群的性别分布、城市分布、偏好商品的分布。

案例：例如我们可以圈选出加购但是还未购买某爆款猫粮的用户并分析该人群的常驻城市分布，然后我们可以基于城市分布去调整这款猫粮的库存分布，通过调拨让猫粮离这些用户更近，这样就可以提升供应链的响应速度

城市 ②




但是，这种方法往往只能了解到一些大致情况，很多时候并不能直接产出运营策略。



② 分组间特征对比

分组间特征对比指对比多个分组（一般是 2 个）的特征情况，这是目前最有用的画像分析方法。分组间特征对比的核心在于 TGI，通过 TGI 发现显著特征。这里我们通过商品画像和用户画像的 2 个案例来说明：

商品画像：我们通过对比“销量前 10% 的商品”和“全量的商品”发现用户更倾向于购买零售价在 0-20、20-40，风格为居家生活、日式的商品。因此在后续商品研发和爆品打造的时候可以主攻这个方向，以及在做首单转化的时候也可以针对这类商品做更大力度的优惠。




用户画像：我们通过对比“严选的超级会员人群”和“严选全量用户人群”发现严选的超会人群具备以下显著特征：性别女、常驻上海市、有车、偏好海淘服饰类等。基于这些显著特征我们可以输出以下两条运营策略：

- **拉新：**在线上、线下的广告投放时更加倾向于具备女性、上海市、有车等特征的用户。



■ **促活和留存：**对于已经开通超级会员的用户，可以给予更多的海淘服饰类的超会折扣或者每月可以免费领取汽车用品等等权益。




③ 分组跨时间维度特征对比


单分组跨时间维度特征对比指对比同一个分组在不同时间的特征情况。例如，我们要测试一下某个营销工具的效果情况，我们可以对比使用营销工具前和使用后的某个人群的 ARPU（单用户平均收入）、近 30 日消费次数等特征的变化，发现使用营销工具后这个人群的 ARPU 值和近 30 日消费次数都有更好的表现，证明这个营销工具是有一定效果的（实际情况中还要排除一些其他因素）。




ARPU ②




TGI ②



近30日消费次数 ②



TGI ②



05

总结

本文首先介绍了标签和画像是业务实体维度特征的刻画和描述，标签和画像的价值在于提供信息、面向业务。然后介绍了严选为什么要建设标签和画像中台：解决共性需求、加速数据资产化和价值落地。进一步介绍了严选标签和画像中台工具的具体能力：数据管理、标签萃取和洞察分析。最后介绍了标签体系建设（自下而上和自上而下）和画像应用（多种特征对比方式）的方法论，并结合了严选的实践案例。

当然，在实际的落地过程中还有很多其他困难要克服，例如如何更全面地收集数据、如何保障标签的准确性、如何保障数据及服务链路的稳定性等等。今天的分享就到这里，谢谢大家。



数据驱动消费者精细化运营产品和生态



数据驱动消费者精细化 运营产品和生态

王成栋 京东 产品总监



分享嘉宾：王成栋 京东 产品总监

编辑整理：刘博文

出品平台：DataFunTalk

导读：互联网下半场，随着互联网渗透率提升，人口红利消失，传统的以流量为中心的营销方式难以支撑品牌在电商平台的高速增长，新形势下，品牌该如何寻找新的增长动力？以大数据和 AI 算法驱动的消费者精细化运营，是京东平台为品牌提供的新答案。在本次分享中，将介绍京东在构建品牌消费者精细化运营平台的过程中，相关行业思考、技术应用和产品形态，为听众解码品牌在互联网下半场的新增长动力。



围绕以下三方面进行介绍：

- 互联网下半场的营销生态
- 消费者精细化运营重新定义营销
- 京东消费者精细化运营平台的三次进阶

01


互联网下半场的营销生态

1. 伴随互联网成长的在线营销生态

在过去 20 年期间，中国互联网基本上可以分为两个时代，一个是 PC 时代，一个 Mobile 时代。简单可以看下图所示的三条轴，前两条轴代表在营销环境下整个信息传播的一些媒介形式变化和这种商业流动的形式变化。随着移动端的出现，人们在移动互联网上花费的时间越来越多，从信息流动层面上，媒体形式越来越多样化、碎片化；从商品流动这个层面上，出现很多新的电商形态，比如说去中心化的社交电商，依托于新媒体形式的直播电商等；伴随信息和商品流动形式的改变，在线营销生态也相应发生改变，从 2012 年左右兴起的 AdTech 到近几年的 MarTech，在 AdTech 时代，DSP、DMP 和 Ad Exchange 等类型的独立公司出现，很多



大厂也在做这类产品的建设，这段时间行业在集中的精力攻克的一个事情，是怎么样通过数据的应用去直接提升广告的效果。随着互联网进入下半场，营销生态逐步进入到 MarTech 时代，随之又产生了一系列新的产品形态，我们本次分享试图探讨这些演进背后的逻辑。



2. 互联网下半场的营销挑战

互联网下半场，可以归结为两个特征，一是互联网市场人口和流量的红利逐渐消失，二是随着整个互联网渗透率提高，量变带来的质变，互联网成为商业社会的基础设施。这两个因素叠加，我们能看看到很有意思的现象，虽然表面上增速趋缓，但是创新和变化依然活跃，互联网行业在不停开辟新的战场，比如下沉市场的各种产品和服务形态出现，电商的线上线下一体化，还有就是国际化，我们中国的先进的这些产品和技术去向国外输出，以及一



个大的趋势就是从 toC 互联网，向 toB 产业互联网的发展。简单的总结一下，今天的互联网，虽然我们号称属于下半场，但是它依然变化很多很快，在这样的一个时点下，对于品牌的在线商业营销带来以下三方面挑战。

① 流量红利消失带来营销效果提升难

以前出现一个新 app，或者一个新渠道，我们去做一波投放，销售、转化就会有一个明显的提升，但在今天的环境下，大家都聚集在一些头部媒体上，怎样去进一步的提高效果，是一个比较有挑战的事情。

② 如何快速应对变化

互联网上的新媒体形态和新商业形态依然在快速变化，比如短视频、直播电商，在这种歌情况下，品牌一方面要去应对效果提升难的挑战，另一方面，还需要去快速的去应对这些变化，否则的话就要落后更多。

③ 原营销方法论不再适用

从营销 4P 要素的角度看，品牌提供商品（Product），设定价格（Price）后，通过推广渠道（Promotion）和销售渠道（Place）进行消费者触达，曾经互联网只是对 Promotion 和 Place 的一个补充。当下，互联网成为商业社会的新基础设施，我们所有的品



牌消费者都连接到互联网上，4P 已经完全融入到互联网中。这样的话原来的营销方法论不再适用，我们需要一个全新的营销方法论去帮助应对现在的互联网新环境，这个从未有过的新环境。从这个角度上来讲，整个互联网市场无论是平台方，还是说其中的各个品牌企业都面临着这个挑战：在这样的一个范式转换的时刻，我们该如何应对。京东作为一个平台，平台上有很多品牌商家在上面做生意，做营销，我们怎么样去利用我们的技术、数据和能力的优势来帮助品牌去应对这个挑战，这是我们思考的起点。



02

消费者精细化运营重新定义营销




这部分是我们初步思考的一个结论，希望通过我们的能力向品牌提供消费者精细化运营的能力，通过重新定义营销的方式来帮助品牌去更好地获得成长。

1. 寻找变化中的不变量

首先，回到我们现在所处的环境，整个互联网从媒介层面上来讲，它的碎片化和多元化依然非常严重，并且新的形式无论是媒介上还是商业上是一直在层出不穷，不停变化。面对这样一个变化的环境，我们应该怎么样去更好的去做好营销，是一个很大的问题。我们可以想象一个场景，某个晚上在没有指南针的情况下，要找到方向，我们要怎么做？我们肯定不会去研究那些在不同季节里出现的星座，我们最快的捷径是找到在任何夜晚都不变的那颗星，也就是北极星。回到营销也是一样的，整个环境在不停的变化，在变化过程中，我们需要抓住不变量，然后围绕不变量去更好的设计我们的营销策略，这可能是一个更有效的方法。在营销里面，不管互联网怎么变，在互联网的另一端，消费者和用户其实都是同一拨人，也许他们上网的方式，购买的渠道，购买的方式会发生的变化，但是他们本身是不变的。我们如果能够去捕捉到他们，对他们有持续的关注，那我们就可能找到一个新的方式去更好的做营销增长。



寻找变化中的不变量



Q：如何应对三重变化的下半场带来的营销挑战？

A：在一年四季变换的夜空中，如何找到方向，不是去关注漫天变化的繁星，而是始终找到那颗不变的北极星

Q：那营销的北极星是什么？

A：碎片化和多样化的互联网的另一端，始终是那群消费者

2020 年终·大会
DATAFUNTALK

2. 重新定义营销


怎么样去重新定义营销？我们希望在互联网成为商业社会的基础设施后，营销能升级为品牌对消费者的持续运营。它具有以下的特征，首先它是真正以消费者为中心的运营。其实营销的传统理念也是以消费者为中心，但是由于数据条件和技术条件的限制，传统营销不能真正的跟消费者产生直接的联系，以及关注消费者的利益。而在互联网环境下，我们是可以实现这种真正以消费者为中心的跟踪和持续沟通。通过对消费者做数字化管理和干预实现真正的精细化运营，以及通过对用户的持续关注实现真正的品效无界营销。我们希望这种消费者的精细化运营，能够给新时代营销提供新的解法和打法。

3. 数字化+智能化双引擎驱动消费者精细化运营



如何实现消费者精细化运营，本质上需要两个核心的驱动引擎：
一个是数据化引擎，一个是智能化引擎。

数据化引擎，是把真实世界里的消费者做一个数字化映射，这离不开整个网络对消费者提供的服务，以及对沉淀下来的消费者特征做的挖掘和补充。在这些数据的基础上构建智能的分析算法和用户转化算法，帮助我们理解消费者，针对不同消费者，制定不同的沟通策略和转化策略，优化营销效果，以及通过科学的方式去评估营销效果。所以在这个系统里，核心的是数据化+智能化这两个引擎。



4. 构建兼顾营销的品牌消费者运营模型

为了构建整个双引擎体系，我们需要做以下三方面的工作。第一方面是构建一个兼顾营销的消费者运营模型，这将提供一个新的可以遵循的方法论路径。第二方面是构建一个消费者运营的一站



式平台。第三个是在生态层面上构建一个共同增长的运营平台。
接下来对这三个方面做一个简单的展开。

① 构建一个兼顾营销目标的品牌消费者运营模型


首先，回归本质，营销的目标是什么？从大的层面来讲，营销目标可以定义为两个方面，一个是销量提升，一个是品牌建设。销量的提升，也就是建立品牌的动能，让品牌直接走向消费者，让消费者购买这个品牌，是我们把产品推到消费者面前。品牌建设是建立品牌的势能，也就是建立消费者对品牌的认知和喜好，这样消费者会主动的关注了解我们的品牌，在产生需要的时候主动购买我们的品牌，这样一推一拉的结合才是最终要达到治标治本的方案。

以这个为目标，首先需要有一个消费者运营模型，并基于这个模型去推演后面的一些体系化的运营方法论。增长黑客是现在一个非常火热的概念，增长黑客 AARRR 模型是其中的核心模型，它更适用于 APP 层面或者网站应用层面的用户的增长，因为它更偏向于效果类的视角。怎样做一个能兼顾品效结合的营销消费者运营模型，是我们首先需要解决的问题，这也是我们整个营销方法论的基础。



② 构建一个消费者运营的一站式平台

消费者运营是一个非常体系化的事情，它会贯穿洞察现状，分析原因，制定策略，执行策略，评估效果到优化提升的全流程。以上的工作，是一个很长的链条，会联动整个链条上各种各样的系统。而完成这些不同工作的产品和能力可能是散落在不同部门或者不同的生态角色里，从这个角度来讲，我们就非常有必要提供一个一站式工具，能够去简化操作和降低使用成本，否则这个方法论在落地时就会遇到很大的挑战。



③ 构建共同增长的消费者运营生态

在京东平台上，存在很多角色，比如消费者、品牌商家、服务商等。我们一定要保证在整个生态里，新方法论能够实现共同增长或者共赢，这样才能保证生态比较平稳的落地。从消费者的角度来说，通过消费者运营的一些举措，我们能够跟品牌一起为消费者提升购物体验，让消费者能够多快好省的找到商品。但同时也需要特别关注消费者的数据安全、隐私安全问题，让消费者既保障了自己的数据安全，又能提升购物体验。从品牌的角度来说，我们给品牌提供一个新的武器，让品牌能够依托互联网更好增长生意，在流量红利消失的现状下实现品牌销量和消费者多重的增长。从服务商的角度来说，我们推行一种新的营销思路和方法，需要服务商给品牌做方法论的导入和相应的解决方案的打造，最终通过平台的建设让整个生态获得共同增长。



03

京东消费者精细化运营平台的三次进阶

接下来对京东的消费者精细化运营平台的三次重要进阶以及我们相应做了哪些的工作，跟大家做一些分享。

1. 进阶一：构建京东生态内的消费者运营能力

第一个阶段：借助我们的产品和工具帮助品牌构建在京东生态内的消费者运营能力。下图是简单罗列的京东生态上各种营销触点，可以分成全域、公域和私域。通过和媒体的京 X 合作，基本上实现了对中国互联网网民的百分之百覆盖，比如我们跟腾讯合作的京腾计划，跟头条合作的京条计划等等。京 X 计划覆盖了很多种类型的媒体。通过这些触点，为品牌构建了一个全域的流量场和用户场。同样，我们也为品牌构建了公域和私域场。在这三个不



同层次的用户场里，怎样让品牌开展品效结合的消费者运营，进而帮助品牌实现增长，是我们希望第一阶段通过产品达到的目标。



① 品牌 4A 消费者运营模型

针对第一个问题，我们提出了 4A 消费者资产运营模型。首先，我们从品牌的角度，根据京东生态内消费者跟品牌之间的互动关系，将消费者状态切分为四个阶段，分别是认知、吸引、行动和拥护。前两个人群认知和吸引帮助品牌提升品牌力。后两个人群行动和拥护的人群帮助品牌提升销售力。通过这个简化模型，品牌不仅能看到购买自己商品的用户，而且能看到跟品牌产生主动和被动接触的用户。我们实际上完成了一个转换，即原来电商的效果类营销更集中在收割层面，通过 4A 模型拓展到了品牌的消费者心智打造，拓展到消费者的长期培育，依托于此，我们可以探索真正的品效结合。



② 京东营销 360-全方位消费者运营，4E 营销方法论

在 4A 的消费者运营模型基础上，我们推出了京东营销 360 的全方位消费者运营的 4E 营销方法论。4E 其实对应的是在不同的阶段需要做哪些重点的工作，在这些重点工作背后，我们会开发相应的数据产品和技术能力来支撑这个阶段的效果最终达成，从而实现数据驱动闭环消费者运营提效。



③ 推出一站式消费者运营平台-数坊

基于以上这些消费者运营模型和方法论，第一阶段我们推出整个京东面向品牌侧的一站式消费者运营平台——数坊。从底层来讲，基于京东全渠道触点行为，统一用户 ID、用户全渠道行为标签以及品牌一方数据等底层数据，构建了品牌的 4A 消费者资产，围绕着 4A 消费者资产，我们建设了相应的 4E 能力。在开发营销策略环节，我们会构建两种能力，针对品牌整体消费者的洞察分析能力和针对于人货场的分析能力，通过这些能力帮助品牌实现对消费者的深度洞察，支持开发营销策略。在执行环节，通过目标人群挖掘和构建全链路自动化营销的能力，帮助我们精准锁定目标人群，提升营销转化效果。在效果评估层面上，结合 4A 模型从品、效两个层面来评估营销效果。最后通过一些跨渠道优化和智能投放优化的实时调整来改善营销效果。



在最终的能力展示层面上来讲，我们会提供两种能力。一种是标准化的产品能力，通过提供一些简单应用的 UI 界面，让业务人员可以更方便的进行全流程的操作。同时我们开放 DataLab，将底层能力进行封装，让有数据科学能力的品牌参与进来，做更高高度定制化的自定义分析，从而更深入地挖掘数据。



④ 数据+算法驱动的消费者深度洞察

接下来简单讲下，我们如何通过数据和算法的结合，对消费者进行的深入洞察。从人的层面上，我们会通过底层的算法分析模型，帮助我们看到消费者不同维度的特征分析与洞察，帮助品牌更好的定位目标人群；在人和场层面上，这些模型可以帮品牌发现哪些触点对流转贡献是更高的。针对这些触点，购物路径是怎么样，哪些关键触点更值得品牌去做投入；在人和货层面上，通过



人和货品的关系洞察，针对不同的消费者群，匹配不同的货品策略，借助这些货品来更好的运营消费者。



⑤ DataLab - 定制化数据应用能力

DataLab 我们开放的定制化数据分析和应用能力，通过对品牌开放我们底层的引擎，使很多有数据科学能力的品牌能够运用这个能力。我们把很多平台底层成熟的 AI 算法模型集成进一个简单易用的点选式建模页面，使品牌的数据分析师可以对数据做定制化挖掘和分析。我们也更进一步提供了在线代码编辑环境，为品牌的数据科学家提供了更高自由度的数据处理能力。这样在标准化能力基础上，通过这种定制化能力的开放，让品牌能够更加灵活的将数据应用到自身的消费者运营中。



2. 进阶二：GOAL 方法论-为消费者运营寻找指示器

第二个阶段，我们推出了 4A 模型以后，品牌经常会问，应该将那些消费者拉进 4A 循环呢？新的消费者进了 4A 循环以后，如何进一步运营，有哪些可以遵循的规则和明确的方向呢？针对这些问题，我们今年推出了能够给品牌提供有效指引的 GOAL 方法论，以帮助品牌更有目标性的进行消费者运营。GOAL，代表四个不同的增长方向。第一个增长方向我们定义为靶群，可以理解为营销中的目标人群。在电商环境下，基于丰富的用户标签（不局限于传统的性别，年龄的用户标签去做用户区分）把消费者做更精细化切分，定义不同的核心人群作为我们需要做运营的人群。在每个需要运营的人群中，我们提炼三个增长方向，分别是渗透增长，价值增长和忠诚增长，分别对应的是让这些人来买我、多买我、只买我。相应的在每个方向上我们提供了很多运营分析指标，



来帮我们看我们的品牌相对于平台,相对于其他品牌存在的差距,以及怎么样更好的和一些工具联动起来,做相应的用户增长。



① 寻找增量靶群

在 GOAL 方法论中，一个核心理念是去寻找增量靶群。随着品牌越来越多，很容易出现大家都去盯着一些同质化用户群去做竞争，这会导致品牌营销成本不断升高。是否能够利用电商丰富的数据发现蓝海人群，通过蓝海人群有效的运营来降低拉新成本，提升营销 ROI 呢？为了帮助品牌更好的寻找增量靶群，我们做了一个靶群挖掘的功能。基于底层维度丰富的标签帮助品牌识别出潜在的消费者族群特征，再通过客群放大能力，帮助品牌进行靶群拓展。通过这个功能，我们计算机去帮助品牌，发掘蓝海人群。



② 靶群全链路自动化触达

当我们细分靶群以后，怎样有效地提升靶群的渗透也是非常关键的环节。这里我们也打造了针对靶群的营销自动化和全链路触达的功能——数坊的营销画布工具。针对品牌关注的靶群，通过制定营销链路，比如前期心智打造的广告、提升转化的优惠券和提升召回的短信营销方式，做一个全链路的串联。通过全链路的方式实现对消费者多波次的触达，来实现持续的消费者运营。




3. 进阶三：从京东生态到品牌全域消费者运营

第三个阶段，从企业的角度来讲，品牌拥有丰富的第一方消费者数据，我们能否帮助品牌建立自己的消费者运营能力，实现品牌第一方数据+生态方数据的全域消费者运营？


① 品牌第一方消费者数据的应用痛点

从品牌的角度来讲，品牌的第一方消费者数据的应用痛点首先在于缺乏一个成熟和好用的工具，其次是消费者数据维度单一，最后是针对消费者激活渠道单一。针对这三个痛点，我们可以通过数坊来帮助企业针对性解决。首先，我们希望能够复制数坊的产品和技术，为企业搭建自己的消费者运营中心。第二，通过数坊的第一方数据融合能力，丰富企业对自有用户的理解，提升运营能力。第三通过数坊连接企业生态和京东的全域触达生态，让企业有更多渠道去实现消费者的全域激活。



② 京东数坊企业版 - Audience Engine

我们近期推出了京东数坊的企业版产品，叫做 Audience Engine。我们复制京东数坊的能力，使企业去做他自己第一方的用户数据治理，在此基础上构建一个他自己的全域用户的运营能力。在这个平台上，我们为企业构建了私域打通能力，第三方广告渠道对接能力，实现了营销自动化能力。



③ 连接京东生态的品牌自有消费者数据价值激活

通过 Audience Engine 跟数坊的紧密联动，借助京东生态的能力，企业激活自身数据价值，构建全渠道消费者运营能力。从效果评估层面上，帮助品牌评估自有流量的投放效果，实现品效结合的效果评估；然后通过京东数据跟企业数据融合，帮助企业深入理解和洞察自己的消费者，以及进一步实现全渠道的营销触达。我们通过这些技术来帮助企业构建新的营销能力以应对互联网新形势的挑战。



连接京东生态的品牌自有消费者数据价值激活

企业的Audience Engine与京东数坊连接，助力企业实现全渠道数据一体化管理；
借助京东大数据丰富品牌对用户的洞察理解，拓展营销场景，打造以消费者为核心的全渠道运营模式，建立全域运营体系，全面提升品牌全域用户运营能力和品牌建设能力。

全渠道运营模式

效果评估	深度洞察	全渠道营销
通过一方消费者的京东站内转化数据，对运营效果进行更有效的评估	基于线上线下、站内站外丰富的消费者数据，洞察消费者特征及行为规律，深挖消费者痛点；提升洞察的深度和广度，精细化运营	优化运营策略，拓展营销场景，实现全渠道营销。对站外投放人群进行站内再营销收割，提升转化；对线下人群进行线上营销，促进转化；线上线下多触点精准触达潜客，拉新促活.....

2020 年终·大会
DATAFUNTALK

最后，回到消费运营生态角度，作为一个平台，我们一直在努力进步，以帮助平台上的各方都能获益，通过产品数据与技术的建设，创建一个共赢和共同增长的生态。

今天的分享就到这里，谢谢大家。扫码观看本文视频回放。





百信银行用户-产品-企业经营多维分析实践

百信银行 AIBANK | DataFunSummit

2021

百信银行多维分析体系 建设实践



罗徽 百信银行 BI 负责人

分享嘉宾：罗徽 百信银行 BI 负责人

编辑整理：小屋 叮当惊喜社

出品平台：DataFunSummit

导读：大家好，我是百信银行大数据部 BI 团队的罗徽，很高兴今天有机会跟大家一起分享讨论。今天我分享的主题是百信银行多维分析体系建设实践。主要围绕以下内容展开：① 百信银行业务背景；② 多维分析解决方案；③ 场景化阶梯式数据分析产品建设。

01

百信银行业务背景



第一部分百信银行的业务背景，主要介绍百信银行的业务模式及基于这种模式下多维分析的数据诉求。

1. 百信银行业务模式

百信银行——首家国有控股的互联网银行

百信银行，全称为“中信百信银行股份有限公司”，是由国务院特批、银保监会主导成立的全国首家独立法人直销银行，也是首家国有控股的互联网银行，业务纯线上，可在全国展开。



百信银行，全称为“中信百信银行股份有限公司”，是 2017 年由国务院特批、银保监会主导、中信银行和百度联合发起成立的全国首家独立法人直销银行，也是首家国有控股的互联网银行，业务纯线上，可以在全国展开。

百信银行依托智能科技，广泛链接生态场景，业务聚焦于 2C+2B 普惠长尾客户群，以消费金融和产业金融为主赛道，依托股东生态，以开放银行模式链接生态场景。主要的业务包括消费金融、产业数字金融、财富管理及银行金融同业。百信银行与车生态、大健康、内容娱乐、新消费及现代农业等生态场景产生广泛的用户、数据、产品、服务交互，并与金融机构有同业交易。



作为一家纯线上的互联网银行，百信银行实现了百分之百的线上化运营，以及百分之百的线上账户能力和全功能账户体系。这种纯线上的运营模式更需要数据来提升运营及经营的决策效率。

官网：<https://www.aibank.com/about.html>

2. 多维分析数据诉求

百信银行多维分析数据诉求

准

全

易



根据与业务的沟通及数据方面的合作，我们将业务对多维分析的数据诉求抽象为三点：准、全、易。

准，首先要保证指标的业财口径统一，同时也要保证指标的业务分析及监管的审计数据口径统一。另外，准也包含了多维分析在交叉验证的可靠性和可解释性，数据准确是一切多维分析可以展开的基础。



全，从指标资产来说，业务方需要我们提供的指标能够覆盖核心场景，而核心场景需要覆盖全链路的分析过程。从分析体系来说，包含了框架的全面性和闭环迭代的全面性。

易，数据分析面向不同类型的分析使用者需要提供差异化的内容、粒度和展现形式。抽象出来的数据分析使用者大概有以下三大类：战略决策层、策略层及运营一线，包括产品、用户和活动运营。这三类不同的群体对分析的使用诉求、使用习惯及数据内容有不同的偏好。

百信银行多维分析阶梯式服务设计思路



接下来围绕准、全、易三点展开多维分析阶梯式服务设计思路：

最基本的解决“准”——作为大数据部的分析团队，我们起到承上启下的作用，采用以应用带治的思路在搭建指标体系的同时，联动数仓、数据工程团队和数据治理团队搭好基建，从底层保证准的供给。



针对“全”的诉求——第一，针对指标体系，以及围绕指标维度体系搭建，形成经营指标和画像指标两套体系，从数据资产的角度保证供给指标体系的全面性。第二，针对分析体系，围绕企业经营、产品和用户分析搭建全链路的分析体系。

针对“易”的诉求——从不同群体的使用角度，提供阶梯式的分析产品，包括：统一联动分析视图、自动化预警&归因及预置维度自助分析等。

02


多维分析解决方案

第二部分进入多维分析解决方案，建设指标体系和分析体系。

1. 指标体系

百信银行经营分析指标体系搭建思路

通过**拆分**业务目标，**挖掘**潜在数据应用场景，**构建**业务分析模型。





以信贷场景经营分析指标体系的搭建为例：

首先回答“业务要什么”的问题——需要结合战略和策略，参与分析业务目标的拆解并进行结构化抽象。例如从经营角度分析，对核心指标：利息收入进行拆解，包括生息资产余额（主要是贷款余额），收益率和期限。接下来，围绕增加利息收入的手段进行拆解，分别是提升规模和损益，最后对前两者进行指标（群）的建构，引出下面“怎么做”的探索。


基于对业务目标和实现手段的拆解，进一步回答“怎么做”——即围绕着利息收入的统计和增加利息收入手段，进行问题的建构和解构。首先用杜邦分析法构建分析模块，将拆解出的规模类和损益类进行一级指标建构，规模类可进一步分为资产规模、资产质量和客户规模，损益类则拆解为成本子类、收入子类和回款子类。建立完度量集后，结合实际的业务场景构建维度。维度分为通用型和分析型，后面会详细介绍。

通过将分析度量模块（指标集）按照维度集打散成为分析原子集，重构支持分析原子集的场景，最终实现场景式自助分析及沉淀业务分析经验的可视化图谱。交付能力分两大类：一类是支持业务拖拉拽的自助分析，另一类是一目了然的自动化分析视图。



百信银行经营分析指标体系（以信贷为例）

通过与业务深度合作，抽象业务分析逻辑，基于目标拆分过程及场景，实现**指标分群分层，维度分类**。



百信银行 | DataFunSummit

接下来介绍指标的分群、分层和维度建构。万变不离其宗，一定要以与业务深度合作为基础，基于业务分析的逻辑抽象拆解业务目标的过程及场景。以下以信贷经营分析场景为例展开介绍。

分群，核心指标分为规模和收益两大群体。分层，一级指标贴合业务最关心的 KPI 指标，定义规模类的为贷款余额；二级指标围绕贷款余额拆解成业务关联度最高的直接指标，涉及到放款类、还款类；三级指标下沉到业务的具体流程指标，例如信贷的通用流程：授信类-用信类-放款类-逾期类-不良类-核销类。

指标体系分为规模类、计数类和比率类等，根据分析的需要，需要关联维度。维度分为通用型和分析型。通用型维度是产品本身属性附带的，在常规分析中不可或缺的，如部门，渠道。分析型维度是随着运营的精细化，基于事先的分析去沉淀合理的高价值



分析的标签维度，沉淀到通用型分析上，提高其解释性和问题识别度，如用户分群分层规则。

这一套指标维度构建思路对后续引导需求，发现分析的主线是非常重要的，也为后面的归因体系打下根基，可以保证问题的聚焦性及故事场景的连贯性，保证解答质的强相关及链路的闭环。在工作中会有各种各样的分析场景，有的分析场景非常聚焦，比如已经有明确的分析场景模块，场景模块内有明确的分析目标及分析主线，这种情况很有利于指标范围集和分析维度集的建立。但往往很多分析场景是不够聚焦的。

我们之前遇到过一个需求，业务提出 200 多个指标需求，但究竟想分析什么，需要先给到数据再探查。这样的需求对于资源的消耗及解答质的高效聚焦是有待优化的。当我们接到需求时，需要保证需求的合理性和高价值性，需要考虑结合业务场景梳理指标的范围层怎样建构，基于范围层怎样去实现与分析体系的高效联动性。首先，剥离指标修饰词和维度，挖掘出核心的原子指标，然后与业务深度沟通分析模型的主场景，根据场景对指标进行分群、分层。当对分群、分层清晰后进行探索性分析，寻找高价值的分析维度，并与业务保持高频交流，来探查终极目标是什么，以及围绕终极目标的一级目标和二级衍生目标是什么。经过这一轮分析聚焦的一级指标不到 5 个，围绕这些核心指标再进行二级、三级及四级的指标建构和维度建构，最终成功交付项目。



Tips：解答质：所谓解答质就是指目前可提供明确答案的程度。

《麦肯锡教我的思考武器》这本书中所提到的，有价值的工作包含两个要素：一是议题度（找到该问题的答案必要性多高）；二是解答质（对于该议题度目前可提供的明确答案的程度），议题度和解答质都高的工作也才是有价值的工作。

问答

Q：经营分析指标体系，核心指标的使用过程中，例如通过评分卡或专家意见或一些机器学习发现哪些二级指标特别有价值？

A：对于核心指标的定义分两类：

一类是无争议的定义，比如 KPI，是结合公司战略，跟业务团队充分沟通后定的。围绕着这些指标的二级指标定义更多是基于规则的下钻型分析指标。

另外一类是其他运营优化类的核心指标定义，对于这类指标的二级指标以及二级指标的关键参数，需要根据实际情况选择合适的实现方法。一般会考虑适配分析场景的核心分析维度群，评估核心场景中数据积累的量 and 质，及业务稳定性。具体来说，百信银行在 3 年的发展过程中，业务在非常灵活的迭代，适配于国家政策在不断进行创新性的尝试。所以，不一定采用机器学习法，目前更多的是统计分析加专家意见法。比如在设定产品盈利指标的参数，会根据过往历史表现从风险、复购两大维度，综合考虑产




品类、损益类指标群的历史表现，结合行业发展分析提供从乐观到悲观预期的不同指标测算参数，再进行下一阶段的验证、迭代。

上述描述是从宏观角度进行阐述，具体根据实际情况分析确定。

百信银行经营分析指标体系（以信贷为例）

核心评价类指标体系基本确定的基础上，如何从短中长期反应业务发展，需要不断验证、细化指标、维度体系。



接接下来结合业务场景，谈谈指标的维度建构。

例如金融业非常关心的提升 ROA，通俗讲是“养大”客户，核心指标是“复贷率”。“复贷”客户无论从成本收益率、运营的难易程度，还是风险的控制角度，一般是表现更优的。下面以“复贷”为例，展开指标的维度建构。

(1) 从时间维度分析，除了常用的统计时间外，以放款批次和 MOB 的时间维度分析也是信贷领域常用的。例如，以 MOB 看复贷的用户数，户均放款额，户均贷款余额，这是比较粗的看全盘的经营表现效果。当我们从统计时间的角度看，可以下钻到看累



计 LTD、QTD、MTD 的表现。累计 LTD 更偏重经营分析、财务和战略层面，QTD 更关注所持资金健康度，MTD 是运营同学更关注的中短期活动效果和运营效果。


(2) 从阶段维度分为未结清复贷和结清复贷。通过探索性分析发现，结清复贷在 7 天和 30 天有明显的表现差异，得出 7 天结清复贷和 30 天结清复贷两个时间窗口维度，锁定触达和运营客户的关键时间点。未结清复贷更偏重怎么去提高客户的粘滞度。

(3) 通用维度即指标的自带属性，如产品、渠道、所属部门等。

Tips: MOB: Month On Book, 在账月份, 例如 MOB0: 放款日至当月月底, MOB1: 放款后第二个完整月份。

百信银行画像指标体系搭建思路

回答4W1H, 助力千人千面精细化运营。



百信银行 | DataFunSummit

现在分享横切的思路，以百信银行用户画像指标体系为例展开。采取的是抽象 CRM 的思路，对用户进行全生命周期的客户关怀，



希望成为客户可靠友好的金融伙伴,在用户需要的时候进行触达,在用户不需要的时候不去打扰。

将用户生命周期拆解成 AARRR 模型：

A——获客阶段。从与用户建立第一次联系起，希望基于用户画像指标体系 KYC 进行差异化场景获客。结合用户意愿、价值、风险等采用差异化的内容、权益、节奏进行互动。

A——用户注册开户。根据画像来迭代风险模型，让风险和增长能更好地平衡。

R——用信。当用户进入授信未用信阶段，通过第一道风控流程后，我们希望在合适的时间、地点，以合适的内容和权益，按照用户本人的特征进行差异化的刺激，在用户需要时实现授信和用信。复用信，更强调对客户理解及对客户不同周期的判断，提高客单价和用户粘性，同时兼顾风险控制。

R——进入休眠、流失和促活阶段。无论是因为个人原因，或银行费率、竞品等原因造成用户流失，我们都希望知道用户是出于什么原因流失，进而思考如何挽留，如何在用户需要时再次为用户提供服务。



R——生日/节日慰问。其他时候，我们希望为客户提供更人性化服务，提供节日、生日等的问候，从而真正实现千人千面的精细化运营。

Tips: KYC——Know your customer.

Q&A

Q: 在经营分析中老师分析了从 200+ 个指标缩减到不到 5 个指标，并精细化这 5 个指标的案例，更合理的引导业务构建了一套更合理的指标体系。那从用户画像角度，用户对产品使用偏好中，怎样更好地找到用户偏好？怎样增加用户对某一款产品的黏性？

A: 用户画像的服务场景广泛。战略层面，例如品宣的定位、产品创设的定位及品牌投放的人群、位置及时间等。策略层面，先看清楚核心，经营用户画像，怎样合理的将用户分群、分层。运营层面，用户画像更强调千人千面，不同的人给不同权益及优化用户体验。

以围绕提升“复贷率”，提升 ROA 为例进行画像分析，选择哪些指标维度或者特征呢？通过预分析发现，7 天和 30 天结清复贷是明显的两个节点。类似于根据思维主线-预分析-验证是否式合理的分析维度后，将具有明确业务区分度的维度作为维度标签放到大盘中进行对比分析，识别进一步差异化特征，如人口轮廓属性、



行为偏好，风险偏好的差异，之后再用 lookalike 的方式寻找相似人群。

百信银行用户/产品画像指标体系（以信贷为例）



接下来以信贷为例分享如何建设用户/产品画像指标体系。

总体上讲，刚才是分享客户历程，但也贯穿了整个业务流程链。

在搭建用户画像指标库时，一共分为两大类：静态属性画像库和动态属性画像库。

静态属性画像库围绕人口的基本轮廓属性，例性别、年龄、行业、收入水平等。


动态属性画像库对各类行为、业务表现和客户风险进行刻画。业务表现是以用户生命周期抽象出动态画像模块，按照前面讲到的指标体系搭建思路，将指标分群、分级并进行维度建构，描述用户不同阶段的表现。



用户画像和产品画像进行联动，希望达到互推荐的功能。产品画像主要围绕利率、期限、风险、用途及产品体验进行搭建。

2. 分析体系

百信银行用户-产品-经营多维分析体系设计思路



当有了上面的资产后，可以结合不同发展阶段的分析思路进行场景建构。

第一阶段，采用描述性分析回答“发生了什么？”，例如支持业务看清大盘，进行核心指标的监测，并支持对比分析。

第二阶段，基于描述性分析进行诊断分析，回答“为什么会发生？”。当大盘和核心指标发生异动时，我们希望实现自动化监控预警，目前百信银行在逐步实现这一阶段。另外，基于业务逻辑沉淀和业务分析策略的沉淀，开始搭建场景化的自动化归因分析。



第三阶段，采用专家意见+算法的方式进行预测分析，回答“将会发生什么？”。对核心指标和用户偏好进行自动化预测。

第四阶段，采用细分人群差异化策略迭代，回答“什么正在发生？”。作为一家年轻的线上直销银行，迭代的业务需要灵活的数据分析支持。所以除了进行描述、诊断和预测分析，还需要支持业务进行细分人群的定位、细分人群的差异化策略及细分实验的效果比对和异动归因，进而判断什么事正在发生，并据此迭代核心指标，更准确描述大盘的现状和更有效支持运营动作。例如初期的用户核心指标为持仓客户数量，当业务发展到一定程度，我们发现持仓客户的分布中很高的比例是持仓低于某额度且不活跃的客户。结合业务分析和发展目标，把核心指标修改为在一定时间区间范围内符合某额度之上的客户数量。

第五阶段，通过数据资产运营阶段达到赋能决策的终极目标。希望围绕核心 KPI 逐层展开特定场景深度合作，从业务理解 and 数据分析上真正提高决策的效率和质量。

03

数据分析产品建设

接下来结合百信银行数据产品建设实践，通过用户-产品-企业经营分析场景探讨上述分析思路的落地。



1. 用户-产品-企业经营分析场景抽象

百信银行用户-产品-经营多维分析场景抽象



我们将用户-产品-经营多维分析场景抽象为横向三层，纵向四块的立方体模型。

横切的三层按逐层递进的思路分为经营层、产品层、用户层。每层支持统一颗粒度的分析，各层间联动上下钻。例如在大盘上看到问题时，可以下钻到产品和渠道探查归因，再下钻一层探查用户与产品的互动表现，从而实现三层联动。


纵向分四块的抽象模式，借鉴了麦肯锡的分析思路：先通过大盘分析看全局，再看变化、构成和比较。结合上面提到的分层横切的思路，形成纵横切割的分析原子对象集。用这样的思路拆解场景，下钻产品和业务链路，乃至客群。



需要注意的是，这些不可能覆盖全量分析场景，我们服务的思路是去报表化，即尽量减少 BI 团队一事一议的定制化报表开发，而是抽象、整合需求，通过打散业务指标维度，赋能业务轻松自助建构分析场景，比如我行的方式是支持自助拖拉拽生成报表或图形。对于常规通用型分析场景，我们会抽象出分析故事线，通过图形可视化提高分析效率，并逐步实现自动化异常提示，并一键生成自动下钻的联动分析。数据资产方面，将指标口径、看板内容版本迭代信息都在门户页清晰呈现。

2. 阶梯式数据分析产品实践案例

百信银行经营-产品-用户多维分析体系实践



下面分享一个经营-产品-用户多维分析实例。

首先看大盘。抽象为四大模块：整体经营状况、损益、风险和定价。每个分析模块锁定核心指标，搭配前面提到的通用维度，时



间维度和分析维度，沉淀分析思路，形成一目了然的描述型分析仪表盘。

下钻到产品&合作方层级进行诊断分析。此处采用趋势分析，贡献度分析，识别并呈现环比正负向贡献及权重，便捷直观。

进一步下钻到用户层级。在这层拆分用户的行为链路，从进件-授信-用信-还款及各环节转化率，结合用户分层分群与产品、渠道进行联动分析。

最后回归大盘分析，实现局部分分析和整体分析的闭环联动。将经营-产品-用户的上下钻自助的分析场景基于业务分析经验沉淀为自动化描述+诊断归因数据分析产品。

百信银行产品-用户营多维分析体系实践

运营优化：产品交叉营销，产品衔接

服务方式：场景挖掘——分析故事线分层建构——统一联动分析视图看整体表现——一键下钻分析单产品流动/留存分析



接下来分享一个财富场景的产品-用户运营联动的案例，目标是探索产品交叉营销策略。



首先还是看大盘，看趋势。当看到明显异常时，可下钻到产品分析。结合时间维度颗粒度收放（月-周-天-小时），探查不同颗粒度的趋势，得出部分产品非常典型的波动规律。之后分析资金流向行内还是行外，流向行内的比例和流向产品；若流向行外的话要结合外部情况进一步分析。基于此分析，业务优化了产品节假日的权益设计，收获了明显的 AUM 提升。

百信银行多维分析体系实践——自动化预警&归因



自下而上统一的数据供给和数据质量保障为数据分析保驾护航。通过公共数据层、数据萃取层和数据多维分析层逐层建构、融入公共维度和分析维度。同时完善质量校验规则库，从非空、逻辑、唯一性、码值等角度在调度任务中部署规则，在每个表生成时进行校验，进行数据质量保障。数据应用层则是沉淀业务分析规则库，实现自动化分析联动、预警及归因并支持自助分析。



百信银行产品-用户营多维分析体系实践——自助分析



百信银行 | DataFunSummit
AIBANK

上图展示的是自助分析场景，预置分析指标、维度，简单拖拉拽即可形成可视化的报表或图形。

以用代治实践

初始化→资产化

事实表管理/新增事实表-引入

序号	*字段/指标名称	字段编码	字段类型	*数据类型	*字段名称	字段注释
1	物理字段	id	string	维度	物理id	物理id
2	物理字段	transaction_id	string	维度	交易id	交易id
3	物理字段	product_code	string	维度	产品代码	产品代码
4	物理字段	customer_id	string	维度	客户id	客户id
5	物理字段	name	string	维度	姓名	姓名
6	物理字段	phone	string	维度	手机号	手机号
7	逻辑字段			指标	按申请操作数	按申请操作数，按申请日期
8	逻辑字段			指标	按申请操作数	按申请操作数，按申请日期
9	物理字段	credit_amount	decimal(18,2)	指标	按申请操作数	按申请操作数，按申请日期


百信银行 | DataFunSummit
AIBANK

前面探讨的是数据分析内容和产品的建构,按照项目管理的思路,交付之后转运维,一方面根据业务场景迭代数据分析内容,另一方面引入数据治理团队,专注于指标资产化运维,基于合理权限设置将指标和维度进行规范化管理。



3. 总结&思考

用户-产品-企业经营多维分析+产品化应用体系



最后，以数据的“广度”和“深度”为横纵轴，将多维分析阶梯式数据服务方案抽象为金字塔+五边形的组合。横轴“广度”即数据覆盖度，纵轴“深度”即数据与业务，与智能科技的融合度。

金字塔最底层是数据模型+资产化，是实现数据口径统一化的基础。覆盖自有数和三方数据，经营指标和画像指标，通用维度和分析维度。

向上一层是可视化分析层，包含统一联动视图和自助分析视图。

第三层是运营&经营分析层，深度沉淀业务分析思路实现自动化下钻分析和自动化预警和归因，尽量实现“隐性”的分析思路“显性”化，智能化。

精细化运营层搭建动、静态画像库以及画像质量&价值监控体系。



顶层为决策支持层，形成分层建构体系化“准”“全”“易”。

一些思考



下面分享一些我的思考：

1. 数据分析综合了业务理解和数据开发，复合型的角色和能力要求。“脚踏实地”是基础，既要理解数据又要理解业务。我在面试时会非常关注分析师是不是了解数据的来龙去脉，是不是了解业务的背景，今天拿到的数据是不是今天业务实际发生的等等，这些都决定后续数据分析的可靠性、可解释性和方向性。
2. “抬头看路”。数据分析以数据结果为重要依据但不完全依赖。关注外界环境，行业生态乃至国家政策对于洞察都是有益的。
3. “方案落地”。及时抽象有价值的分析思路、沉淀为数据产品，最合适可行的方案 > 最优方案，快速验证方案及思路的业务价值



并基于此识别/挖掘更大价值。强调识别需求及提供高解答质数据方案的能力，而非盲目做大。

4. “释放价值”。低调做事，做扎实，并在适当的时候影响高层和其他团队。在工作中，跨团队 demo 以前的产品时，经常会听到“我怎么从来不知道有这样的思路，这样的服务方案？”。所适当宣传，碰撞思路，有助于更高效的迭代创新，释放数据价值。

今天的分享就到这里，谢谢大家。扫码观看本文视频回放。





如何搭建数据指标体系

一个数据人的自留地 | DataFunSummit
SHU JU REN CLUB

如何搭建数据指标体系

徐尧 止观科技 首席技术顾问



分享嘉宾：徐尧 止观科技 首席技术顾问

编辑整理：朱佳佳 北京航空航天大学

出品平台：DataFunTalk

导读：随着经济增速放缓，科学、有效地引领业务持续增长，已成为企业发展的首要任务。如何有效地利用数据指标体系，将决策方向从“业务经验驱动”向“数据量化驱动”转型，成为企业的关注要点。好的指标体系能够监控业务变化，当业务出现问题时，数据人员可以通过指标体系进行问题回溯和下钻来准确定位到问题，反馈给业务解决相应的问题。今天会和大家分享一下如何搭建数据指标体系。



主要内容包括以下几大方面：

- 指标体系的用途
- 如何搭建指标体系
- 指标体系的应用

01

指标体系的用途

本节主要回答两个问题，一是为什么需要数据指标体系，二是数据指标体系对于工作有何帮助。

1. 为什么需要数据指标体系？

■ 核心指标变化了，如何抵御来自老板的“灵魂三问”？



“

1、为什么变化？

“

2、和哪些因素有关？

“

3、如何解决？



现实中，数据相关人员常常要回答与公司业务相关的核心指标是什么，比如商品交易总额 GMV，月活 MAU，新增付费用户等。如果核心指标变化了，我们需要知道为什么变化，受哪些因素影响，怎么解决。

通过诊断、倒推的方式去解决上诉问题，不能较快的对这些问题给出答案，比较耗费时间，且容易遗漏信息，不能保证分析的颗粒度足够细。

2. 数据指标体系对工作有何帮助？

如果有了指标体系，可以：



自动拆解指标



主动发现问题



及时监测效果

一个数据人的自留地 | DataFunSummit
— SHU JU REN CLUB —

如果有了数据指标体系，它能够发挥以下作用：

- 自动拆解指标：在搭建数据指标体系的过程中，按照整个链路和流程进行拆解，将拆解逻辑贯穿在整个指标体系搭建的过程当中；



- 主动发现问题：有了数据指标体系，我们可以清晰的看到各种指标的上升或者下降，能够通过多个维度完全量的流程来帮我们分析，也可以帮助我们主动发现问题；
- 及时检测效果：构建的指标体系是从头至尾的，在这个过程中任何环节出现了问题，都可以观察到原因所在。

02

如何搭建指标体系

前面描述了搭建数据指标体系的作用，下面分享下如何搭建指标体系，包括构建指标体系的具体步骤，以及搭建过程中的一些注意事项。

搭建指标体系的方法

OSM模型

O是Object（目标），是指希望实现的业务目标

S是Stratedy（策略），代表为了达成目标采取的具体行动策略

M是Measure（度量），用来衡量策略是否有效，目标是否达成

这里的搭建指标体系的方法，就是 OSM 模型：



- O 是 Object（目标），也就是我们希望实现的业务目标。它可以是公司层面的，也可以是针对某条业务线的。
- S 是 Strategy（策略），是为了实现以上目标，我们会采取的具体的行动策略。
- M 是 Measure（度量），用来衡量我们的策略是否有效，以及目标是否达成。

搭建指标体系有四个步骤：

- 第 1 步：确认核心指标（北极星指标）
- 第 2 步：梳理为了实现该指标，有哪些有关的要素或节点
- 第 3 步：写上上述环节对应关注的指标
- 第 4 步：指标宣贯、存档、落地

下面具体讲解这四步。

1. 确定核心指标（北极星指标），对应 OSM 模型中的 O



【O】：确定核心指标



- “North Star Metric” 北极星指标，又叫做“OMTM” One metric that matters, 唯一重要的指标。
- 这个全公司上上下下，向着同一个方向前进指标一旦确立，就像北极星一样，高高闪耀在天空中，指引着。
- 所以他是公司中核心且可以主动影响的指标

一个数据人的自留地 | DataFunSummit
— SHU JU REN CLUB —

北极星指标是公司中最核心且可以主动影响业务的指标，即我们在工作中说的主要矛盾，冲着它发力能够取得更好的效果。比如说电商可能最关注总销售额，知识付费平台可能最关心问题回答数，网约车公司可能最关心月活用户数等等。

如下情况下需要制定北极星指标：

- 第一，它是一个相对独立的业务，而不是一个大业务中相对小的一个分支；
- 第二，它是一个无单一 KPI 的场景，而不是有明确的 KPI；
- 第三，它针对非单一岗位。

如何找到核心指标？这里举一个网约车司机的核心指标的例子。

网约车的主要目的是赚钱，他的核心指标怎么确定呢？



首先，我们可以将网约车司机的收入做一个拆分，这其中包括业务费用、订单奖励、附加费及其他费用。网约车收入计算公式如下：

$$\text{收入} = \text{业务费用} * 100\% * 0.5\text{元} + \text{订单奖励} * 100\% + \text{附加费} * 100\% + \text{其他费用} * 100\%$$

接着，确定哪些变量会影响各项指标。其中，业务费用等于订单量乘以客单价，订单量指的是同样时间内可以接多少单，客单价指的是同样车型情况下的客单价。而订单量又等于接单时长乘以单均时长。订单奖励等于订单完成率乘以各段奖金。附加费就是极端条件的乘客加价。

然后，确定可以影响哪些变量。对于网约车司机而言，“在不增加工作时长的情况下提高收入”的关键是：接更多的单和接更贵的单。对于司机来说，影响平台派单的核心指标是订单量和好评率。而司机可以主动影响的就是好评率。

最终，就可以确定网约车司机的核心指标是好评率。其实，司机可以有很多方式来增加收入，比如换一个更好的车，或者去一些需求量大的地方去跑，或者每天工作时间更长，但如果可以找到一个核心指标，我们可以花很少的时间取得更好的效果。

2. 梳理为了实现核心指标，需要哪些关键要素或节点，对应 OSM 模型中的 S



S：找到核心指标的关键路径

UJM模型

User Journey Map模型，用户旅程地图。

是指设计该业务时，必须要梳理的用户（使用者）的生命旅程。

换言之：就是拆解用户所处的每一个旅程阶段、了解每个阶段中用户的行为、明确每个阶段中产品的目标、发现各阶段中产品与用户的接触点、最终从接触点里找到产品的痛点和机会点。

一个数据人的自留地 | DataFunSummit
SHU JU REN CLUB

在梳理指标体系过程中，要把和核心指标相关的路径梳理清楚，这其中会用到 UJM 模型，全称 User Journey Map，用户旅程地图。在梳理的过程中有三个注意事项。

第一，不能流水账式的梳理，应当是以一些有产出的指标为节点；

例如：对于长视频（优爱腾）而言



路径（流程）以有产出的指标为节点

一个数据人的自留地 | DataFunSummit
SHU JU REN CLUB



第二，路径的起点和终点都要围绕着核心指标展开。例如对于全站 APP 来说，核心指标是播放人数和人均的播放时长，购买行为对于播放行为来说不是最重要的，则可以隐去，因为我们的路径的起始点是围绕着核心指标也就是播放行为来展开的；

例如：对于长视频（优爱腾）而言

若对于全站而言，核心指标是 **播放人数、人均播放时长**



第三，梳理路径的时候，仅以单一的视角展开，不要做跳转。如对于淘宝业务梳理而言，卖家视角和买家视角不能同时存在。



例如：对于淘宝而言，核心指标是GMV

梳理的路径如下



梳理路径时仅以单一视角展开

3. 写出各环节对应的关键指标度量，对应 OSM 模型中的 M

M：确认每个行为下的实际度量（指标）



一般梳理关注的指标有人数、次数、转化率，和购买行为相关的钱和订单量，还有一些功能性指标如视频的播放量、B 站的一键三连等。再加上不同的维度。



M：确认每个行为下的实际度量（指标）

加上常用维度

	增长指标		活跃度指标	变现指标
一级指标	新注册用户数		登录用户数	营业额 客单量
二级指标	分渠道访问量/ 访问用户量 分渠道新访问量/ 访问用户数 活动拉新	注册流程转化率	周期性用户活跃度 用户留存度 核心功能使用频次	分客户规模新签数量/金额 分客户规模续签数量/金额 分规模客单价
三级指标	访问时长 每次会话浏览 页面数 跳出率 渠道留存率	注册流程流失用户数 新注册用户活跃度 新注册用户留存度	核心流程转化率 核心转化步骤流失率 新手任务完成率 新手任务完成耗时 用户生命周期 用户流失率	ARPU 客户生命周期价值 销售效率 毛利率 利润率

4. 指标宣贯、存档、落地

OSM：指标体系到行动策略



指标体系建立完成后需要制定具体的行动策略，即采取哪些措施去影响这些指标。



03

指标体系的应用

本节介绍指标体系如何发挥作用，即如何回答核心指标为什么发生变化？和哪些因素有关？如何解决？

1. 如何回答为什么发生变化？



通过涉及到的流程，往前追踪来确定为什么发生变化。如播放时长减少了，首先可以往前去追踪上游谁影响了播放时长，还可以按照维度来进行分析，比如有可能是搜索量少了，或者是今天的日活少了等等。

2. 如何回答和哪些因素有关？



2、和哪些动作有关？



由于搭建指标时把可能影响关键指标的行动策略已经列出，可以看到该指标和哪些动作或者哪些因素相关，然后根据原先的行动策略去追踪。比如播放时长减少，是不是有什么内容影响观看，会不会是产品有什么问题。

3. 如何解决？


3、如何解决？





一旦某一个指标发生了变化，就可以根据搭建指标体系所列出的行动策略去解决。

指标体系的应用



一个数据人的自留地
SHU JU REN CLUB

DataFunSummit

实际应用中，通过指标体系提出具体的产品运营策略，实现精细化的运营，在运营的过程中，做实验验证结果，进而完善指标体系。所以指标体系是一个反复迭代、不断优化和调整的过程。

04

总结

建立数据指标体系的目的是获取全局性的、有体系性的信息，进而通过这些信息去驱动业务的发展，达成组织目标。一套好的指标体系，能够帮助我们描述现状、洞察原因、预判未来。指标体



系最大的价值就是帮助大家高效利用时间，把时间花在解决问题上，而不是寻找问题上，从而提高团队整体的人效。

05

精彩问答

Q：以司机角度，如果所有司机都冲着“好评率”这一核心指标发力，会不会有一些负面影响？

A：首先，如果所有人都这么做，整体效率会提升，是应该认可这个效果的。其次，就像天道酬勤一样，不是所有人都能做到。假设所有人都做到了，可能会有新的核心指标出现，这是一个动态调整、不断迭代的过程。

Q：产品或者业务同学在数据指标体系建立的过程中如何参与？

A：产品或业务同学要有这种数据赋能团队意识，根据数据指标体系的方法论影响数据团队沉淀出一套指标体系出来，而不是简单的提出问题。因为数据指标体系的搭建不是单独的数据或者业务团队能够做出来的，而是两者配合的过程。所以数据团队要努力了解业务，业务团队要赋能数据，共同搭建数据指标体系。

Q：数据指标体系在业务部门如何推广？



A：如果没有成熟的数据指标体系产品，就需要与业务部门去沟通，了解他们的痛点，重新搭建一个数据指标体系。如果已有产品，则可以把指标梳理出来，发给业务人员，以小的试点去影响他们，如果取得了一些效果以后，再试着去把它给全链路的拓展开。

Q：什么角色主导数据指标体系搭建？

A：没有定义一定要什么团队来做。这涉及到数据权限归属的问题，对于产品同学如果有这个需求且有权限的话，就需要去做。不管是业务的分析还是数据部门的分析，都需要去帮助业务梳理指标体系。

Q：指标体系和标签体系的区别和联系？

A：指标体系更多的作用是分析，标签体系没有这个作用，指标体系是对业务整体结构的描述，会对业务的理解更深。标签作用是维度，比如购物性别。

今天的分享就到这里，谢谢大家。扫码观看本文视频回放。





如何建设好的数据指标体系

 快手 | DataFunSummit

2021

快手如何搭建一个好的数据指标体系？



钱英男 快手 数据产品总监

分享嘉宾：钱英男 快手 数据产品总监

编辑整理：王亚季

出品平台：DataFunTalk

导读：本篇文章源自钱英男老师在『快手大数据 | 数据内容建设交流会』上的演讲，相关视频回放可用快手 APP 搜索“快手大数据”观看。

一个好的数据指标体系可以助力业务快速的解构业务、理解业务、发现业务问题，快速定位原因，并且找到最合适的解决方案。因此学习搭建一个好的数据指标体系是数据助力业务决策的灵魂。



本文会从四个方向来进行相对应的展开和论述：首先我们来看下，为什么需要一个好的数据指标体系，好的数据指标体系和大家日常看见的这些数据指标到底有什么区别？然后看下，到底什么是一个好的数据指标体系，它的基准是什么？在有了目标和基准之后，我们会聊聊如何进行一个好的数据指标体系的建设；最后，会做一个简单的回顾，以及未来工作的延展。

01

为什么需要一个好的数据指标体系?

01 为什么需要数据指标体系？

Boss

GMV下降了，是什么原因？

小六

GMV

10,000

日环比-10% ↓ 周同比-15% ↓

DAU

10,000

日环比-10% ↓ 周同比-15% ↓

加购数量

10,000

日环比-10% ↓ 周同比-15% ↓

收藏数量

10,000

日环比-10% ↓ 周同比-15% ↓

满意度

5%

日环比-10% ↓ 周同比-15% ↓

关注店铺用户数

10,000

日环比-10% ↓ 周同比-15% ↓

Boss

下单转化率下降了，是什么原因？

小快

GMV

10,000

日环比-10% ↓ 周同比-15% ↓

UV

20,000

日环比-10% ↓ 周同比-15% ↓

转化率

5%

日环比-10% ↓ 周同比-15% ↓

客单价

10

日环比-10% ↓ 周同比-15% ↓

到店转化率

20%

日环比-10% ↓ 周同比-15% ↓

到店下单转化率

25%

日环比-10% ↓ 周同比-15% ↓

到店转化率

20%

日环比-10% ↓ 周同比-15% ↓

到店下单转化率

60%

日环比-10% ↓ 周同比-15% ↓

到店转化率

40%

日环比-10% ↓ 周同比-15% ↓

到店下单转化率

40%

日环比-10% ↓ 周同比-15% ↓

快手中学

KUAI SHOU SCHOOL

×

快手大数据

KUAI SHOU DATA

数据内容建设交流会

DataFunTalk

首先我们来看下为什么我们需要一个好的数据指标体系。这边给大家看一个故事，估计大家都会比较有体感：大家有没有在半夜收到过老板的信息，问为什么业务上的核心指标 GMV 下降了？然后这里边我们产品同学小六就会赶紧把电脑打开，但是他所有



能获取的信息就只有一个 Dashboard，里边只有一个 GMV 核心指标，环比同比同时下降，这个时候他怎么回答老板的问题？结果基本靠猜，是不是竞对做了一些活动？是不是某个主播停播了？另外一种可能性的情况是小六同学手里边有一百多张报表，这一百多张报表里边，有四百多个指标，然后每一个指标都在下降，那在这种情况下，也没有办法回答老板的问题，为什么这个核心指标下降，到底是 DAU 下降了，还是用户满意度下降了，还是转化效率下降了等等？

另外一种情况是老板同样提了这样一个问题，然后另外一个产品同学小快不紧不慢的拿出了一张这样的报表体系，他说：“老板，我认为 GMV 下降会跟整个业务流程都有相关性，我们从业务角度进行了这样的拆解，发现在流量入口，和最后的人均消费来看的话，其实并没有下降，主要下降来源其实来源于列表页转化效率的下降。再往下拆解，发现高价的商品的曝光占比和低价的曝光占比并不太平衡。高价商品的一个曝光占比比较高，但是它的转化效率却是低的，所以从这个角度来讲，我认为可能在列表页来里面的不同价格的商品的分发策略或者曝光策略需要进行优化，然后通过 A/B test 去看一下我们这个策略调整的效果是什么样子的”。



01 为什么需要数据指标体系？

- 01 整体理解业务
- 02 全面发现问题
- 03 快速定位原因
- 04 落地解决方案



小快



快手中学



快手大数据

数据内容建设交流会

DataFunTalk

那大家觉得说针对于这两个数据指标的组织体系，哪一种更能够帮助到业务呢？第二种吧。那我们来看一下，为什么第二种大家都会觉得比较好，如果解构这张报表来讲的话，我们会发现什么问题？首先我们会针对这个核心的 GMV 的指标去做一个全面业务流程的拆解，我会把它拆解到相对应的 IPV（商品流量入口规模），付费转化效率，APPU 值，它涉及到整个业务的一个全链路，帮助我去更好的理解业务。那第二个方向来讲的话，我会针对于这个全链路业务进行下钻分析，看到底是哪些因素下降影响因素会比较大，所以能够帮助业务去全方位的发现业务上的问题。最后一个角度，我们不仅要去进行业务流程上的拆解，我们还可以做下钻分析，去拆分到最后相对应影响核心指标的因素到底是什么，从而能够定位到业务的问题是什么，并且提供到相对应比较合适的一个解决方案。所以说一个好的数据指标体系是帮助业



务去做决策的灵魂，它能够帮助业务全面的理解业务，能够全方位的定位问题，能够快速定位原因，并且给到对应的解决方案。

02

什么样的指标体系是一个好的数据指标体系？



在了解了好的数据指标体系的必要性之后，我们来看一下究竟什么样的指标体系是一个好的数据指标体系。大家在做一些数据分析的时候，我们都会看到列出来的一些标准：数据指标必须是准确的，是能够周期性统计，必须是一个比率等等。但是如果回归本质，从为什么需要一个好的数据指标体系出发来思考的话，其实一个好的数据指标体系建设就需要能回答两个问题：

第一个问题就是数据指标体系是不是有助于业务的发展。



往下拆解的话，有两个标准：

数据指标符合业务目标：好的数据指标的是需要符合业务的价值观的和符合业务核心目标的。数据指标是为了让公司，业务，或者项目的成员围绕着一个可量化的目标展开一系列的工作的。如果数据指标没有贴合业务核心目标的话，那么给公司，业务或者项目带来的会是巨大的损失。比如说快手的信任电商的业务追求的价值点是最有温度、最值得信任的社区。不单纯追逐 GMV，而是追求是信任项目的订单覆盖率：包括信任卡，退款不退货，假一赔十，退货补运费等的订单的覆盖率。比如说快手的五一活动，核心目标不在于 DAU 的绝对量级，而是如何进行资源的精细化调配，来沉淀 ROI 打正的经验和方法论，这种情况下核心指标定成为 ROI 会更加合适。

数据指标可衡量业务真实情况：好的数据指标体系是需要可以全方位衡量业务真实的情况的，而不仅仅只看到业务上面某一个方面：比如快手的核心指标不仅仅包含 DAU，还有用户使用时长，互动情况等等。因为我们不仅仅需要关心用户来不来，还需要关心用户来的消费的怎么样，互动的多不多。只有用户不仅来，而且用的时间长，并且行为层次深入的话，才有可能为平台的健康带来更多的可能性。

第二个问题就是所选择的指标是否具备可操作性。



往下拆解的话，也有两个标准：

数据指标可衡量：如果能从时间纵向对比、或者从其他维度比如用户群体、产品、地域等不同角度进行横向比较，可以更好地观察业务的发展趋势，定位问题，找到原因，以及改善业务中需要改善的环节。

- **KPI 达标率：**如果你的核心指标是 KPI 指标，那就直接根据 KPI 达标率来判断即可。这个应该是最常见的一种方式。
- **竞品对标：**如果你能从靠谱渠道搜集到竞品相关数据，那以竞品为参照物进行判断。
- **环比对比：**查看环比数据，如果业务走势呈明显周期性，选择一个历史数据较为不错的数据进行对比。
- **同比对比：**查看同比数据，预估每个周期增长多少个百分点，与上一周期数据进行对比，看是否达标。

数据指标的设定会改变行为：能够确保拆解出来的指标是具备有可操作性的，可以落地的，可以执行的。这个指标体系是可以执行的，或者是可以事先改善的。具体的讲，我们不能仅仅看最后的一个结果指标，我们还需要把这个结果指标拆分到中间指标上。在中间过程如果任何一个指标出现了问题，第一是能够提前判定这个业务的健康度是什么样子的，是不是出现问题了。第二个好



处在于这些中间过程的指标可以拆分到负责的团队里边，定位到负责人。业务上面如果出现问题的话，可以第一时间负责人，之后进行下一步的优化措施的拆解。在这里边也给大家举个例子：GMV 我们拆分到 IPV 乘以付费转化效率再乘以相对应的 APPU（人均付费值），这个是行业内非常常见的一个拆解方式，从用户的角度去进行拆分，那这种情况下的 IPV 就有由对应的搜索团队或者是推荐团队负责，他需要去优化整个页面的一个规模或者说到访用户的规模，付费转化效率由产品团队负责，去进行相对应的一些产品优化，减少摩擦点，能够提升我们付费转化效率；APPU 值这一块更多的是由运营的团队去负责，因为运营团队需要去做一些活动，或者是通过一些优惠券的方式能够促进用户买了再买，购了再购。

03

如何去建设一个好的数据指标体系？



03 如何建设好的数据指标体系-OSM方法论



那看完了好的数据指标体系的一个标准之后，我们来一起看一下怎么能够去建设一个好的数据指标体系。通用的建设数据指标体系的方法论是 OSM 理论：

- O-代表了公司/业务/产品/项目核心的价值点和以及核心目的是什么，搞清楚业务方向的目标是可以确保后续的指标体系拆解是贴合业务核心价值的，和贴业务核心目的的。
- S-代表了为了达成上述目标采取的策略和抓手，围绕着核心目标进行拆解出来相对应的业务策略之间是可以相比较的，快速定位问题。
- M-是针对 S 的抓手用于衡量策略的有效性，通过适合的量化的数值针对策略的有效性进行评估。



03 如何建设好的数据指标体系-确定目标、策略



我们举一个日常电商直播业务的例子，看一下具体的这个方法论具体是怎么操作的，首先来看一下对于电商直播业务的 O，一般都会是由业务同学直接去给到，如果业务同学没有给到的话，大家可以从公司制定的财报里边，或者说相对应的业务制定的每月或每个季度的 OKR 里找到，那针对于电商直播业务来讲，它核心的指标就是提升营收（GMV）。

然后在这个目标 Objective 的方向上，我们可以使用 UJM（User Journey Map）去拆解相对应的这个业务策略（Strategy）。UJM 的逻辑是从业务的核心目标出发，拆解整个业务流程上我们为用户提供价值点，以及这些价值点触达用户的整体路径都有哪些。

UJM 的方法论可以保证：

- 第一：所有业务策略类的拆解不重不漏，所有业务策略相关的触点都会在里面；



- 第二：UJM 的拆解可以反向论证整个业务策略是不是真的能够为用户去带来相对应的价值，从而达成最终的业务目标。

所以拿电商这个例子我们来看一下：为了完成这个相对应的一个营收目标（GMV），我们触达用户所有的行为路径。

- 第一步，用户在整个直播广场页面或者搜索 banner 位去查到相对应的一个直播列表或者相对应的一个信息，那这种情况下，用户触点就是直播广场的流量位或者是搜索位。这个步骤上对应的业务策略是需要去优化流量位的一些内容，或者是优化搜索位置的匹配效率，让用户能够快速看到相对应他想看到的内容。
- 第二步，用户选择了可能感兴趣的内容之后，去进行相对应的内容的观看，从而产生兴趣点。这个兴趣可能是对主播本人，有可能是对商品本身，那在这个角度来讲，业务主要抓手就是直播内容，主播或者是商品，对应的业务策略就应该是打造主播个人的人设，或者提升商品的性价比，从而让观众能够产生兴趣。
- 第三步，如果用户感兴趣，他就会点击相对应的小黄车，进行付费的操作，对应的业务策略应该是减少摩擦，减少操作步骤，能够提升用户在付费页面的转化效率。



- 第四步，用户完成购买之后，可能会有一些社交诉求。比如说他在这个直播间买了性价比特别高的货，特别想把它分享给他的好友，那这种情况下，业务上面可以提供分享晒单或返现的策略，促进用户去进行相对应的分享，让更多的人完成直播间的购买行为。
- 最后一步，用户离开直播间的时候，业务上会给用户提供一个关注主播的机会，把这个用户和主播的信任关系或关注关系沉淀下来，进而促进用户去进行之后的复购，从而提升我们最后的 GMV 规模。

03 如何建设好的数据指标体系-找到度量

- 从业务策略类型拆分不同的衡量指标



在梳理了用户行为路径上的业务策略后，我们可以按照为用户提供的价值划分为四个象限：是节省时间还是消磨时间；是为了用户提供的价值来自于产品本身，还是来自于『连接』其他资源。



- 比如说为用户提供工具类型业务策略，一般是为了让用户节省时间，快速的定位到所需要的信息或者完成某一种任务，那么这种策略核心的价值就在于提升效率，一般的衡量指标是：使用量，目标达成率， 频次；以上面电商的例子来讲的话，就是第一步中的流量推荐位，以及搜索功能是不是能够让用户快速的定位到它所感兴趣的直播内容，那这种情况下做优化流量位的内容和搜索匹配优化我的衡量标准就是它的效率，曝光，点击，转化效率。
- 比如说为了用户提供消遣的内容,让用户可以消磨时间，那么这种策略的核心价值就在于为了用户提供丰富的高质量的内容，不管是短视频， 直播， 或者活动玩法。那么这种策略的核心的价值就在于为用户提供内容的量与质，一般衡量指标是：消费人数， 消费广度， 消费市场，以及用户与内容的互动，用来衡量用户对于内容的喜爱。比如 B 站的弹幕就是一种用户对于内容认可的更高层次的情感表达。
- 比如说为了用户提供与供应商和商品的链接,促进用户交易，那么这种策略的核心价值就在于为用户提供好的购物体验，能够提升付费页面转化效率， 提升购买的总规模，客单价以及复购率。上文中的电商直播的例子里面，衡量小黄车和付费流程效果的核心指标就在于页面的转化效率高不高。



- 比如说为了用户提供与其他人的情感连接，促进用户和用户之间的关系沉淀，进而让用户对于平台或者对于业务更有依赖性，促进用户的活跃和互动，一般的衡量指标是：内容的发布量，用户和用户之间的互动量，沉淀下来的关系对数。譬如说快手是一个社区平台，那就是用户和创作者之间的一个链接；像微信，是用户和用户之间的一个情感的连接，那衡量这种连接的紧密性主要是人与人之间的互动量，点评赞数量，沉淀的关系的数量。以上文电商的例子来说，衡量指标就是分享给好友的用户数，次数，以及沉淀的关系对数。

春节战役指标体系实战：



03 如何建设好的数据指标体系-春节活动案例

- | 挑战 | 必要性 |
|-----------------|---------------------------------------|
| ➤ 涉及多方 | ➤ 拉齐目标，推进团队之间的协作 |
| ➤ 玩法复杂 | ➤ 好的指标体系可以帮助大家明确优化点的优先级 |
| ➤ 资源多倍抢占，如何提升效率 | ➤ 需要体系化的指标体系，快速帮助业务确定问题点，找到原因，提升活动ROI |



快手中学
KUAISHOU SCHOOL



快手大数据
KUAISHOU DATA

数据内容
建设交流会

DataFunTalk

在看完 OSM 方法论，以及也拿了一个实际的例子给大家讲了一下 OSM 方法论如何落地的。我们来看一下在快手的一个实际活



动的案例，为什么去拿活动去举这个例子，因为活动和日常的的业务场景是十分不同的，它有很多的挑战：

第一，活动涉及方特别多，少则一个小型活动百十来人，像春节战役来讲的话，可能会涉及到几百人的团队协作，那在这种情况下来讲的话，能够协调这么多人团结在一起去做一个项目，是有很多的挑战的。

第二，在一个长期的活动的过程中，为了能够把用户留存下来，我们会为用户提供非常丰富和非常复杂的玩法。对于这么多的玩法，那到底应该把重点的资源投在哪些玩法上，对于项目的负责人是一个非常大的一个挑战。

第三，快手在做活动的时候，友商也在做活动，因为一年里面重点可以做活动的相关日期其实就那么几个：比如双十一，618 等等。所以在这种情况下来讲，对于外部资源位的一个抢占是非常激烈的，大家都知道今年的 618 各个电商平台在抢占外部资源的时候今年的成本是去年成本的六倍。所以如何提升外部投放的转化效率，对于活动来说也是一个很大的挑战。

综上，正是因为这些挑战，我们更应该去建设一个活动的数据指标体系。为什么呢？



第一，因为涉及方比较多，有一个核心的北极星的指标去牵引着大家往同样一个方向去走，从而去协调大家的一个工作，提升沟通的效率是非常重要的。

第二，平台的资源的调配需要一套数据化的一个衡量标准，把资源调整给到留存效果更好的玩法上面。

第三，对于外部资源抢占的挑战，我们更需要一个体系化的指标来指导业务把有限的资源投到那些相对应转化效率比较高的资源位置上。

03 如何建设好的数据指标体系-春节活动案例



我们真正进入实操之前先理解一下活动，整个行业内活动的类型其实无非几种：

第一种，活动核心目标其实是为了能够去做相对应的用户增长的，就是为了提升用户的一个规模而花钱去做一个活动。



第二种，活动核心目标的是去做相对应的电商的一个消费转化，比如说像阿里的双十一，京东的 618 等等。

第三种，更偏向于品牌营销的活动，去打造和宣传平台的调性，比如说像网易年度总结或者 b 站的新年晚会等等。其目的主要是为了让用户对平台有认知，然后去消费平台里面的内容。

那从这三个方向的目标出发，来抽象活动的本质：在短时间内快速的聚集外部以及内部的流量，把所有的流量通过丰富的玩法，优质的内容以及多种多样的权益，把用户聚集到一起，通过这些抓手能够让大家不停地留存在这里边，之后形成一个庞大的用户群体池，进而为下游价值引流，进而达成用户增长，电商成交，或者内容消费的核心目标。

03 如何建设好的数据指标体系-活动案例-丰富的玩法-用户活跃



快手春节活动刚好涵盖了刚才所说的行业三种不同的活动类型：



首先是为了提升用户的活跃度，快手为用户提供了很多种不同的玩法，譬如说像第一个飞行棋，它是整个春节战役一条玩法的主线，它通过一条类似于《大富翁》的玩法，把整个用户的路径串联起来。让用户能够不停地在这个主链路上去进行其他多样的挑战，为其他分类玩法引流。在分类型的玩法比较典型的就集卡，就是类似于支付宝的集五福，通过集齐爱情牛，运气牛，事业牛等卡片，可以在除夕开启大奖，从而让用户在前期能够不停地在这个平台上去进行活跃。另外一种分类玩法是组队 pk，用户通过拉新用户进来完成任务，形成队伍进而两队 pk，获胜的队伍可以获得红包或者电商优惠券。


03 如何建设好的数据指标体系-活动案例-多种权益-电商收益



从引导电商成交这个角度来说，我们会在用户完成任务玩法之后，为用户分发不同的一些电商权益比如零元购，这里边会促进用户进行成交转化。



03 如何建设好的数据指标体系-活动案例-优质内容-内容消费



数据内容
建设交流会

DataFunTalk

从促进快手内容消费的目标出发，平台联合创作者为用户发放宠粉红包。快币的成本一部分是由平台承担，一部分是由创作者去承担。宠粉红包玩法是创作者在发短视频的时候，同时准备一些快币。用户观看视频内容的话，就可以随机得到快币，从而刺激用户内容的消费。同时，快手也邀请 top 级别的明星，在每一天晚上 8 点的时候进行相对应一些头部内容的直播，为用户提供更好的内容体验。



03 如何建设好的数据指标体系-活动案例

业务目标-Objective

提升用户活跃度 (DAU)，内容消费 (播放VV)，电商消费 (引导GMV)

用户参与路径 渠道触达 → 活动分发 → 玩法互动 → 完成任务 → 获得奖励 → 产生消费

抓手	外部渠道	活动主会场	集卡	集卡	内部/三方卡券	春晚直播
	内部渠道	活动分会场	组队PK	组队PK	红包	黄金档
业务策略			飞行棋	飞行棋	代币	除夕0元购
			达人福袋	达人福袋	道具	引导关注
	选择投放渠道	提升产品点击效率	提升参与用户规模	任务内容个性化投放	控制奖励发放成本	引导内容消费
	选择个性化素材	提升分发内容曝光	提升玩法收益规模	任务奖励个性化下发	卡券奖励个性化下发	引导电商消费
	指定人群强触达	规模&转化效率	控制成本预算	任务难度数量控制	控制商业化奖励曝光	引导创作者收益

策略分类

节省时间

提供丰富的内容、提供情感链接

促进交易

促进消费



数据内容建设交流会

DataFunTalk

春节活动的核心目标 O 以及对应的数据指标就会划分为三个部分：

- 第一个提升用户的一个活跃度，核心指标就是 DAU。
- 第二个促进内容消费，那核心的衡量指标，就是播放 VV 次数。
- 最后一个方向是电商消费引导成交 (GMV)。

活动过程中，用户整体行为路径链路会拆分几个部分，以及对应的策略拆解：

外内渠道触达/活动内容分发：活动的内容的触达；用户到达活动主会场页面或者是活动分会场。

- 业务策略：投放策略的优化，在不同的渠道，不同的用户群投放它可能相对应感兴趣的一个内容，从而促进用户能够快



速的达到活动页面，然后从而提升活动渠道曝光点击的转化效率

- 衡量指标：渠道转化效率，以及活动页面到访频次

活动玩法互动/完成任务/获得奖励：譬如用户去参加飞行棋集卡或者是说组队 pk，促进用户去完成相对应的任务。一旦用户完成任务，即获得奖励，包括电商，商业化的优惠券，以及现金，红包，代币等等，反向刺激用户更多的参与到这些玩法互动里面去。

- 业务策略 1：优化我们这些相对应的玩法，让这个玩法更有趣，从而去提升用户的一个参与规模，去进行整个期间的用户池的蓄水；控制一下整个玩法分发奖励的成本，进而提升活动的 ROI
- 衡量指标 1：参与的用户数，完成任务的用户数，跨品类参与用户数
- 业务策略 2：在情感链接这个角度来讲的话，优化创作者内容分发机制，能够让用户和作产生更多的互动，沉淀情感连接
- 衡量指标 2：点评赞数量，沉淀关系对数

产生消费：春节当天晚上刺激用户去进行产生相对应的电商消费或者是内容消费。



- 业务策略：比如进行电商权益的个性化的分发，有些年轻女性用户可能更多的想要一些美妆的一些优惠券，那对于男性用户来讲的话，可能更多的想要 3c 类型的优惠券，从而提升我们相对应的电商的转化效率
- 衡量指标：电商券发放量，领取量，引导消费电商引导转化 GMV



从春节活动来讲，通过这样的一个数据指标体系，我们达成什么样的一个效果呢？

- 第一，价值在渠道引流：我们会发现说转化效率最高的渠道是快手的极速版和快手主站双端互拉。最后我们主要通过双端互拉的这个渠道达成了 DAU 当时的一个峰值，助力业务拿到了比较好的业务价值。



- 第二，价值体现在玩法互动的 ROI：我们使用数据表现去衡量组队 PK 玩法的 ROI，通过实时调整这个组队 pk 的任务的难度，达成了组队 pk 这个玩法的 ROI 的正向收益，这个在平台做活动的情況上比较难得。

04

总结



在介绍完了快手整个春节战役的实战之后的话，我们来做一个总结。我们是从为什么需要一个好的指标体系出发的。一个好的数据指标体系是能够帮助业务去理解业务，全面发现问题，快速定位原因以及落地解决方案的一个灵魂。



那从这个灵魂往下来拆来讲的话，一个好的数据指标体系是要需要回答两个问题，它是不是有助于业务发展，以及说这个指标体系拆解是不是可具备、可落地、可实操的可能性。

之后，我们给大家介绍了 OSM 的理论，如何去确定 O，它是需要贴近业务模式以及价值点的，关于 S 和 M，我们是从目标角度出发，去拆解到相对应的业务策略，以及从业务分类的角度去找到适合可量化指标。

最后，数据指标体系其实只是数据赋能业务的万里长征的第一步。未来如果希望更加泛化地去支持到更多的业务场景，其实是需要去做一些产品化的沉淀的，把一些固化下来的指标体系或者分析框架沉淀下来，去赋能更多的业务人员，可以使用相对应的数据产品，帮助他们去做相对应的业务决策。进一步提升他们决策的效率，同时降低使用数据的一个门槛。这个对于一个公司开展数据驱动文化最大的一个助力。那从这个角度来讲的话，如果大家感兴趣，我们下一次的专题可以讲一讲如何从一个好的数据指标体系出发去沉淀内容数据产品建设。

今天的分享就到这里，谢谢大家。扫码观看本文视频回放。





数据安全工具建设经验分享

一个数据人的自留地 | DataFunSummit
— SHU JU REN CLUB —

数据安全工具建设经验分享

马小阳 产品经理



分享嘉宾：马小阳 产品经理

编辑整理：陈妃君 深圳大学

出品平台：DataFunTalk

导读：近年来，在信息技术支撑下，数字经济驱动着全球各经济体的经济总量不断增加，“数据安全”也已上升到我国国家安全战略高度。政府部门和企业持续加大在数据治理、数据存储、数据保护、数据加密等方面的重视程度和投资力度。今天我将基于在业务场景中遇到的数据安全治理问题，帮助大家理解“数据安全”概念，并向大家分享在数据安全治理过程中所采用的工具手段和思路。

今天的介绍会围绕下面四点展开：

- 安全概念
- 安全目标
- 工具框架
- 安全治理

01


安全概念

首先和大家介绍一下本文分享范围内的安全概念，了解什么是数据安全、数据全生命周期，以及安全 4A/5A 理论。

1. 数据安全的定义

什么是数据安全

公司安全→信息安全→数据安全的关系和定义



- 国际标准化组织（ISO）对计算机系统安全的定义是：为保护计算机硬件、软件和数据不因偶然和恶意的原因遭到破坏、更改和泄露的技术和机制
- 我的理解，一句话总结：数据安全就是保障数据从采集到销毁全生命周期中的一切操作符合国家和公司的安全法规

DataFunSummit

(1) 数据安全在公司安全中的位置




其实在一个公司里面，安全的概念非常的广泛，例如公司内部会将整个公司的安全分为几个领域：政治安全、声誉安全、法规安全、公共安全、财务安全、金融安全、信息安全、业务安全、内容安全。我们看到数据安全属于信息安全的一个子模块。

(2) 数据安全的概念

针对数据安全，我们要解决的问题是，在整个数据生命周期中，从采集到销毁过程中所面临的全部数据安全挑战。换句话说，数据安全就是保障数据从采集到销毁的全生命周期中的一切操作符合国家和社会的安全法规。

2. 数据全生命周期的定义

什么是数据全生命周期



数据全生命周期是指数据从采集到销毁的全过程，通常包含以下几个阶段：

- 数据采集：数据从客户端（APP/网页）中以日志的形式进行收集的过程
- 数据传输：数据通过高速通道（kafka）快速集成到服务器存储介质中的过程
- 数据存储：包含各类硬件存储介质和一系列数仓建模规范
- 数据加工：数据提取/转换/合并/去重等操作的过程
- 数据交换：数据从各类冷/热存储引擎中搬来搬去的过程
- 数据治理：通过产品技术手段规范数据的完整性、准确性、时效性等特性的过程
- 数据应用：数据应用到分析、展示、算法画像等领域的过程
- 数据销毁：数据删除销毁的过程

DataFunSummit

数据全生命周期是指数据从采集到销毁的全过程，通常包括以下几个阶段：




- **数据采集**：数据从客户端（APP/网页）中以日志的形式进行收集的过程；
- **数据传输**：数据通过高速通道（kafka）快速集成到服务器存储介质中的过程；
- **数据存储**：包括各类硬件存储介质和一系列数仓建模规范；
- **数据加工**：数据提取/转化/合并/去重等操作过程；
- **数据交换**：数据从各类冷/热存储引擎中搬来搬去的过程；
- **数据治理**：通过产品技术手段规范数据的完整性、准确性、时效性等特性的过程；
- **数据应用**：数据应用到分析、展示、算法画像等领域的过程；
- **数据销毁**：数据删除销毁的过程。

3. 安全 4A/5A 理论的定义



什么是安全4A/5A理论

身份认证 (Authentication)：你是谁，以及怎么证明你是你
授权 (Authorization)：允许/拒绝你对某个对象进行访问/操作
访问控制 (Access Control)：控制措施以及是否放行的执行者
行为审计 (Auditable)：数据血缘可以追溯，用户行为可以审计
资产保护 (Asset Protection)：对数据资产进行立法保护、预防监控等



DataFunSummit

行业中比较认可的分类方法为身份认证、授权及访问控制、行为审计、资产保护这4A。通过以上4A理论，可以将数据全生命周期中涉及到的安全问题拆分为这四个业务场景，如果将四个业务问题管控好，结合铺展到位的数据安全建设工具和第三方监察审计部门对数据资产进行监察，整个过程会形成一个完整的数据安全保护闭环。

02


安全目标

1. 数据安全范畴和边界



数据安全范畴和边界

以安全4A标准作为横轴，数据全生命周期作为竖轴，几乎所有数据安全团队所做的工作都会被包含在这个生态系统中




DataFunSummit

目前绝大多数做数据安全相关工作的人，主要集中在账号管理-数据采集传输和安全审计-应用消费层面（例如数据人物画像、分析工具、数据加工生产等），其中在授权管理模块会花费 70%~80% 的精力。

2. 数据安全建设目标

数据安全建设目标

如上，数据安全其实是一个很广的范畴，那怎样才叫做做好数据安全了呢，大致上会经历3个阶段：“不信任外网” → “不信任内网” → “0信任”



TIPS: 纵观国内情况，绝大部分公司做好严格的外网隔离其实都已经不易，因此，实事求是的讲，现阶段，能做到“防君子不防小人”或许是一个性价比比较高的目标，而至于黑客攻防、内奸防范，不要过度纠结。

DataFunSummit



上图中的数据安全建设目标是参考亚马逊的定义，即数据安全会经历三个阶段：不信任外网→不信任内网→0 信任，其含义为：

- **不信任外网**：公司的资产和数据只对内部员工开放，外部员工没有经过公司身份认证无法访问公司的数据；
- **不信任内网**：对于公司内部的数据会进行分级分类，根据公司内部员工的职责、岗位和分类去细分权限；
- **0 信任**：数据在不经数据所有人或产权人授权的情况下，无人能够拿到这个数据。

目前绝大部分公司能做好外网隔离，即不信任外网，已是非常不容易，也是性价比最高的建设目标。

03

工具框架

接下来将从身份认证、权限管控、资产保护以及综合实践来介绍数据安全的工具框架。


1. 身份认证

身份认证包含账号和认证两个部分。以下通过这两部分的设计和实践，分别阐述其搭建思维和方法。



(1) 账号设计

身份认证-账号设计



- 身份认证包含账号和认证两个部分
- 其中账号就是管控对象的身份，比如每个人都有电话、邮箱等，可以作为在登录微信或者QQ时候的账号，账号是保障数据安全的最基本前提
- 账号通常包含三类，分别是自然人账号、应用/服务账号和组织账号

DataFunSummit

在做身份认证之前，最基础的工作便是完成账号设计，搭建账号系统。我们可以将账号进行分类，包括自然人账号，组织账号，角色账号，部门账号，应用账号，还有一些比较小众的其他账号，以便实现安全管控的前提——准确无误的识别出访问主体。数据安全第一个条件就是要建立起清晰可信准确的账号体系。

账号通常分为三类：

- **自然人账号**：包含岗位、职级、合同类型以及其他属性等基本信息的账号，可以清晰地区分出公司内不同类型的员工。
- **组织账号**：通过组织身份或者业务线形态对系统进行访问，组织内部通常是多种详细分工角色的集合，需要在底层建设时就搭建好框架。



- **应用/服务账号：**通过 APP/服务进行数据访问，也通过该账号来进行后续的消费和应用。

身份认证-账号实践

对于特定系统，为了保障安全，是不允许用户自己去自行注册的，只能通过BD或者管理员去创建账号，比如：

- 商家CRM系统，创建商家账号，用于商家货品上单和管理
- 经营参谋，创建分类账号，针对不同类型的账号制定分类授权策略
- 测试系统，创建测试账号，用于系统测试


DataFunSummit

当我们设计好账号，搭建好系统，便可以进入实践步骤。在安全中心中，有账号申请模块，即账号注册工具，其功能为：在信息安全部以及 IT 支持部门，录入信息，生成 SSO，完成基础服务支持。

(2) 认证设计



身份认证-认证设计



- 身份认证包含账号和认证两个部分
- 其中认证就是证明“你妈确实是你妈”的过程
- 认证通常交给公司内部统一的单点登录系统（SSO）去负责
- 用户身份认证通常有账号密码认证、电话/邮件验证码认证、第三方认证等

DataFunSummit

身份认证的第二个部分是认证。认证方式有密码认证、微信/支付宝第三方认证、电话/邮件验证码认证等方式。这些认证方式的底层结构都和上图流程图类似，分三个系统：SSO、应用系统、权限系统：

- **应用系统**：用户通过一个应用系统登录，应用系统会分别与SSO和权限系统交互，获取用户信息和数据权限信息，并将有权限的数据内容返回给用户。
- **SSO**：单点登录系统的加密存储用户信息数据库，主要存储用户的账号密码等用户信息。
- **权限系统**：用于查看申请数据内容的用户是否有请求该数据内容的权限，会给应用系统返回鉴定结果。



身份认证-认证实践

为了安全，认证系统通常又细分为面向内部员工的SSO，面向第三方合作商的BSSO，面向外部用户的CSSO，比如，在实际操作实践中，有时候需要第三方BD登录商家后台去帮助商家处理问题，为了安全，BD通过BSSO认证系统登录商家后台比直接拿商家账号密码去登录要安全的多，且更容易审计追责

登录成功提醒

商家名称

商家账号

员工

您将进入商家后台，任何操作将会被记录

某些操作需要手机验证码，请在发送后向商家索取

严禁未经商家同意修改任何数据

同一个浏览器只能登录一个商家账号，登录新账号会将已登录的账号自动退出

知道了，进入

算了，不进入

DataFunSummit

在实践中，可以通过合理设置 SSO 实现“0 信任”的方式，来解决例如第三方 BD 需登录商家后台去帮助商家处理问题存在的潜在安全问题。

具体的可以设置多方 SSO：内部员工 SSO、第三方合作商 BSSO、外部用户 CSSO。然后第三方 BD 通过 BSSO 认证系统登录并申请外部用户的短信认证，以此取代传统使用商家的账号密码去登录的方式，做到“0 信任”，降低安全风险。


2. 权限管控

当我们要对一个业务系统进行访问和操作时，要经过权限管控环节，在该环节声明用户与权限的关系。将介绍它的几个迭代模型和实践示例。



权限管控-设计

权限管控核心是声明人和权限的关系，纵观行业发展，权限管控模型先后经历了以ACL模型为代表的1.0时代和以RBAC模型为代表的2.0时代，现在正式迈入以ABAC模型为核心的3.0时代。



- ACL模型：即Access Control List，直接维护列表中用户与资源的关系从而达到权限管控的目的
- RBAC模型：即Role-Based Access Control，基于角色的访问控制，将用户添加到角色列表从而间接获得对应的权限
- ABAC模型，即Attribute-Based Authorization，基于属性的授权，通过事先定义好的规则属性来控制用户的权限范围


DataFunSummit

权限管控模型先后经历了三个时期：ACL 模型、RBAC 模型、ABAC 模型：

- ACL 模型：即 Access Control List，直接维护列表中用户与资源的关系从而达到权限管控的目的。缺点是随着业务体量的增加，职级岗位复杂度提高，数据量增加，该模型的效率低下。
- RBAC 模型：即 Role-Based Access Control，基于角色的访问控制，将用户添加到角色列表从而间接获得对应的权限。将角色和权限建立权限关系，用户和权限形成间接的关系，在 ACL 模型的基础上，提高了效率。
- ABAC 模型：即 Attribute-Based Access Control，基于属性的授权，通过事先定义好的规则属性来控制用户的权限范围。

与 RBAC 模型相比，其定义空间更大，可以抽象出更具体和差异化的控制条件，建立属性与权限的权限关系。

权限管控-实践



左图是基于权限模型设计的权限产品DEMO，核心思路来源于ABAC模型的改良，我命名为TRFAC模型，即基于“对象-资源-条件-行为”的权限控制，描述了“XX对象（人/应用/组织/角色等）对XX资源（页面/菜单/按钮/数据等）在XX条件/因素（城市=北京等）下拥有XX行为类型（增删改查等）的权限”


DataFunSummit

上图是一个基于 ABAC 权限模型改良的 TRFAC 模型设计的权限产品 DEMO，包含获权方和资源列表。获权方可以是用户、用户组、角色、部门、应用和其他，还可以增加一些附属条件。该模型基于“对象-资源-条件-行为”的权限控制，描述了“xx 对象（人/应用/组织/角色等）对 xx 资源（页面/菜单/按钮/数据等）在 xx 条件/因素（城市=北京等）下拥有 xx 行为类型（增删改查等）的权限”。



权限管控-实践

基于TRFAC权限模型，接入权限中心的应用系统的鉴权逻辑如下图：



DataFunSummit

上图即为 TRFAC 模型权限系统健全的流程，需方和供方分别使用业务系统和权限中心以 API 为桥梁接口进行交互，互相传输请求和返回结果。


3. 资产保护

为防止有权限的用户将数据不合规的泄露和传播，需要建立资产保护体系，以下介绍资产保护模块的设计思路和实践示例。



■ 资产保护-设计

账号和认证保证了我知道谁来访问我的数据，权限保证了他能够访问到什么数据，那资产保护就是在给他安装了一个监控的同时，还配置了一个门卫，时刻盯着他以防他干坏事。



DataFunSummit

在整个资产保护模块中，主要分为事前预防-事中监控-事后审计三部分。

(1) 事前预防

工具主要包含：

- 离职转岗交接平台：80%的数据安全 case 都发生在离职转岗环节，设计专门的针对角色、权限、任务、各类型资产的交接回收平台能极大降低风险发生的可能性。
- 敏感数据识别：有利于我们及时发现诸如电话、身份证号等敏感数据，及时对识别出的数据做出标记和升级，就能堵住可能的泄露风险。其实现方法主要是底层算法逻辑结合前端界面，然后根据目标数据库进行敏感数据识别。



- 敏感数据脱敏展示/下载: 针对特定用户查看/下载数据时进行数据脱敏。

(2) 事中监控

■ 资产保护-事中监控

事中监控主要是针对高风险人群（比如待离职人员、外包账号、实习生等）和高风险行为（比如敏感数据下载、敏感数据查询等）配置监控规则，从而达到及时感知风险进而阻止风险的目的。



DataFunSummit


在事中监控环节，是在事前预防的敏感数据识别和敏感数据脱敏展示/下载配置好的基础上，进行监控。针对高风险人群（比如待离职人员、外包账号、实习生等）和高风险行为（敏感数据下载和查询）配置监控规则，设置阈值，感知风险并阻止风险。

(3) 事后审计



资产保护-事后审计

安全风险一旦发生，第一时间找到风险源，追查风险责任人便成了堵住安全漏洞的必要措施，因此设计审计日志查询工具可以解决这个问题



DataFunSummit

事中监控一旦检测到风险或者安全风险已经发生，通过设计审计日志查询工具对风险进行追责以及及时堵住安全漏洞。


4. 综合实践

上面介绍了身份认证、权限管控和资产保护，在现实业务中往往是复杂的综合性业务问题，因此以下将介绍从数据的采集、存储、生产、加工、治理，到数据的应用、分析、服务，即加工层到应用层的框架模型。



综合实践-管控体系

在实际业务场景中，往往不是单一的账号、认证、权限等管控需求，而是综合了账号、认证、权限、隔离等交叉需求的综合场景，比如加工层的阿里dataworks“账号-工作空间-项目空间”的三级划分结构，又比如应用层SaaS系统中超级餐饮连锁企业使用的CRM系统



DataFunSummit

在实际业务场景中，往往不是单一的账号、认证、权限等管控需求，而是综合了账号、认证、权限、隔离等交叉需求的综合场景，比如加工层的“账号-工作空间-项目空间”的三级划分结构。又比如应用层 SaaS 系统中超级餐饮连锁企业使用的 CRM 系统。

综合实践-加工层

- 工作空间是面向不同岗位角色（分析师、产品、RD等），集成各类分场景工具，提供相应的分析、加工和应用服务能力的虚拟综合工作场所，用户可以按照自己的岗位属性选择相应场景的工具和数据开展工作
- 项目组是工作空间的组成单元，划分了数据存储、计算资源，整合了权限、数据资产，将相同发任务的人员集合一个组，共同进行数据生产加工和治理；项目组内根究需求还可以进一步细分出权限和角色分配



DataFunSummit

加工层，也叫作工作空间-项目组体系：





- 工作空间：面向不同岗位角色（分析师、产品、RD 等），集成各类分场景工具，提供相应的分析、加工和应用服务能力的虚拟综合工作场所，用户可以按照自己的岗位属性选择相应场景的工具和数据开展工作；
- 项目组：工作空间的组成单元，划分了数据存储、计算资源，整合了权限、数据资产，将相同发任务的人员集合一个组，共同进行数据生产、加工和治理；项目组内根据需求还可以进一步细分出角色和权限分配。

当遇到不同业务线，具有不同的组织架构划分，有时候细化出不同的角色时，我们就需要采用应用层，是工作空间制下，由业务线组织决策分类管控的体系。

综合实践-应用层

应用层的一个典型特点是组织层级复杂，角色多样，比如类似于麦当劳这种国际超级餐饮企业，从“全球总部-大区总部-区域总代-门店”划分出多级组织体系，同时，又有直营和加盟等不同的组织性质，所以数据中台为了满足这类业务团队关于组织账号和权限的需求时，就需要考虑组织-角色的多级体系，同时，同一个角色，在不同组织所拥有的权限也是不一样的。



DataFunSummit

应用层的一个典型特点就是组织层级复杂，角色多样，比如类似于麦当劳这种国际超级餐饮企业，从“全球总部-大区总部-区域总



代-门店”划分出多级组织体系，同时又有直营和加盟等不同组织性质，所以数据中台为了满足这类业务团队关于组织账号和权限的需求时，就需要考虑组织-角色的多级体系。同时，一个角色在不同组织所拥有的权限也是不一样的。

04

安全治理

1. 核心理念

■ 核心理念

- 灵魂三问：你为什么要做数据安全建设？你为谁做数据安全建设？你做数据安全有什么价值？
- 数据安全的终极目标为：保障数据流通的安全性，促进数据的共享和流通，让数据为业务赋能！



DataFunSummit

灵魂三问：你为什么要做数据安全建设？你为谁做数据安全建设？你做数据安全有什么价值？

回答：数据安全不仅是在保护数据不泄露，其终极目标是在保障数据流通的安全性，促进数据的共享和流通，让数据为业务赋能！




2. 实施策略

安全治理的重要性不言而喻，其实施策略主要分为下列几步：标准立法、工具支持、运营第三方数据安全治理。

(1) 标准立法

实施策略-标准立法

联合公司信息安全部发布覆盖全公司范围的《数据安全标准》文件，作为安全指导总则，帮助数据安全治理工作落地实施。



DataFunSummit

安全治理的第一步为标准立法，需要借助国家的安全法规和企业建立的相应的安全规范，满足数据全生命周期各个环节的标准和数据应用环节的标准。

(2) 工具支持



■ 实施策略-工具支持



整合分散产品，集合权限服务、流程服务、离职转岗服务、安全审计服务、数据流通服务几大方面能力的工具平台，提供综合化安全管控治理服务。

DataFunSummit

其次安全中心会提供一整套包括权限服务、资产交接、流程服务、安全监察、数据流通等工具。整合分散产品，集合权限服务、流程服务、离职转岗服务、安全审计服务、数据流通服务几大方面能力的工具平台，提供综合化安全管控治理服务。


关于数据流通目前有两种方案，各有利弊：

- A 方案：只提供工具和平台，各个业务可以注册使用不同部分，将其数据上传对外，但是平台不会管理其交易。
- B 方案：作为平台方，将各个业务线的数据统一收口到平台，由平台方进行综合规范和治理，业务方如有数据需求，再将数据授权。

(3) 运营第三方数据安全治理

实施策略- 运营第三方数据安全治理

数据安全中心运营目标整体分为三个：一是培养和建立用户心智，完成组织保障；二是推动各业务团队将所属数据纳入数据市场，统一取数流程；三是制定标准和定责追溯的SOP，提升安全治理能力。



DataFunSummit

最后一个模块为运营第三方数据安全治理，主要分为四大块：组织保障、落地路径、运营策略和基础保障。

我们可以将数据安全中心运营目标整体分为三个：

- 培养和建立用户心智，完成组织保障；
- 推动各业务团队将所属数据纳入数据市场，统一取数流程；
- 制定标准和定责追溯的 SOP，提升安全治理能力。

05

精彩问答

Q：安全分级，到底是在业务侧达标还是在平台上达标？



A：问题的本质就在于，数据从业务进行采集、产生、传导到平台的过程当中，到底由谁来判定达没达标？其实如果我们不做好血缘的串联，各种数据来源，从字段再到表级的串联的话，意味着你只要产生一个具体的实体数据，你的安全达标就会失效。你在业务侧达标，当你右侧的数据被引用到下游某个业务表，其实业务表比方打的是 C4，在下游业务表它有权限打成 C1。

Q：数据资产保护和数据资产管理是怎么定义边界的？

A：保护指的是安全，管理指的是治理。很多公司将安全和治理放在不同的团队，也有的公司没有治理团队，只有加工层和应用层团队。个人认为，数据治理适合加工和应用团队同等重要的第三个组，数据治理的范畴包括口径治理、规范性治理、安全治理和资源资产治理。安全是属于治理的一部分，数据安全是数据治理的一个分支。

Q：BI 展示脱敏是实时处理的吗？

A：在 BI 系统里，我们从数据库获取数据到展示分析的过程，大多数是通过离线调取实现的，管理员会选定其脱敏范围，比如 BI 系统下某个数据源某个库的某张表，然后配置脱敏方式，就会在数据通过调度系统时，进行脱敏。例如采用 SQL 语句进行查询，在提交计算之后，后台系统就进行扫描其代码是否含有敏感数据，如果有，则会触发审计和监控。主要两种实现方式：①定制化的



硬编码，应用于比较高明的数据；②配置系统，允许业务去配一些轻量级系统去触发审计和监控。

今天的分享就到这里，谢谢大家。扫码观看本文视频回放。





如何提升数据化管理效率

快手 | DataFun.

如何提升数据化管理效率

谷维 快手 数据产品



分享嘉宾：谷维 快手 数据产品

编辑整理：马胜利

出品平台：DataFunTalk

导读：随着大数据时代的到来，数据对于每个企业，每个人来说都是极其重要的，淘宝通过数据可以给每个客户精准推荐商品，抖音通过数据可以记录每个用户的使用习惯。但同时，数据时代的到来，也让众多企业领导者开始思考，面对数以亿计的数据，如何才能通过数据化管理提升工作效率？这成为了困扰企业管理者的一大难题。



今天的分享会围绕下面四点展开：

- 一个用户的困扰
- 为什么管理需要数据
- 如何提升数据化管理效率
- 应用案例

01

一个用户的困扰

■ 一个用户的困扰



如果你是一位数据分析师，想必你一定遇到过这种情况，当你把分析报告交给领导时，领导会说：“你怎么这个时候才给我，不就是取个数嘛？”“这个数据应该不对吧，这是你取错了吧？”辛辛苦苦



苦做出来的数据，最终换来的却是领导各种的抱怨。作为一个数据人，你可能会跟领导解释说：“老板，这个指标是通过数据仓库加工处理完后汇总统计的，提出异常数据，更加科学有效。其次，报告中月度指标统计周期是近 30 日，用于趋势分析。与 OKR 考核的自然月指标统计周期不同，因此会有差异。”你会花费大量时间沟通，以此打消领导的疑虑。当领导了解后，可能会说：“嗯，这个报告很用心，但不是我想要的。看完报告，我不知道接下来要怎么做。”于是你便去了解业务，最终发现，大多数业务同学看到数据后不会结合业务动作解读数据，也不太熟悉产品的功能应该如何去使用。

诸如此类现象，是做为数据小弟、小妹们在工作中不得不面对和解决的问题。很多时候，我们心中都会发起疑问“管理真的需要数据吗？我们的价值是什么？”

02

为什么管理需要数据



为什么管理需要数据？



管理的意义在于有效开展企业或业务活动、满足客户需求，提高效率。数据就是通过量化管理的方式为管理的效果和效率提供一个科学判断的依据。也就是说数据是一个量化的标准。通过这种量化的标准，给更多的人去使用，让更多的人通过这种方式和方法，提升他们的工作效率。所以管理需要数据作为工具。

03

如何提升数据化管理效率

数据分析和数据产品是提升管理效率的两个重要的能力。接下来，从数据分析和数据产品两个角度介绍一下，如何提升数据化管理效率？

1. 数据分析：要从业务中来，到业务中去



1、数据分析：要从业务中来，到业务中去



首先，刚才提到的数据分析师的例子中，其实反馈出一个问题，就是最终得到的结果并不是用户所需要的，对于这个问题的原因，其实并不是用了什么样的分析方法，是业务用户不能接受的，而是说没有真正的站在业务的角度去理解业务的目标是什么，为了这个业务目标，业务用户是怎么去做的，分几个步骤，每个步骤具体要怎么去执行，以及业务做完后的效果是怎样的。只有将业务目标进行拆解，数据量化才会更贴近业务，分析结论对业务也会更具指导性。量化管理的过程，就是业务理解、业务拆解，最终判断业务的结果是好还是坏的过程。


好坏评估的标准就是根据业务的动作核心，拆解出来的指标，通过不同的维度交叉分析，找到业务做的好与不好的原因，并最终为了更好的开展接下来的工作，提供可以落地的解决方案。最终，通过数据实现“计划-执行-行动-验证”的闭环。



数据分析擅长对快速及时业务问答进行反馈，这种小闭环自循环的流程做得是非常好的，在某些层面上，我们其实可以认为它是一个定制化的服务，但这种小闭环跑得很通畅的服务也是会有它解决不了的问题。

2. 数据产品：要抽象功能模块

2、数据产品：要抽象功能模块



当数据分析师面对多个角色解决非常复杂的业务场景时，数据分析的解题方法、解题思路，甚至是得出的结论，都是多样化的，短期的效率非常高，但长期来看，对于服务更多规模模型的用户来讲，效率并没有有效地提升。而这正需要数据产品来解决。数据产品通过了解不同业务的诉求，将数据分析的各种各样的方式和方法进行系统化和抽象化，针对不同的用户提供一套系统性的解决方案。



3、数据产品：一套解决方案-内容数据产品建设画布



DataFunSummit

这种解决方案，可以通过内容数据产品建设画布解决，共有十个步骤，其中前四个步骤其实是基于数据分析的核心思想：从业务中来，到业务中去。

接下来从整体看一下，面向不同的用户，不同场景的角色，我们的组合是什么样的方式。

4、数据产品：内容数据产品服务矩阵



DataFunSummit



自上而下来看，最顶层是决策者，最底层是一线人员，要解决的是价值转化的问题，也就是效率问题。

针对决策者，我们要提供定制化的服务。与数据分析回答领导“天问”的专题分析不同，数据产品需满足决策者随时随地发现行业趋势、监控核心指标的诉求。因此，我们会为决策者提供移动端和大屏等产品。

针对中间层的各级管理者，承接了领导的问题，需求更多元化，也更量化，对效率要求也非常高。所以我们采取了集装箱式的服务模式，根据不同场景用户的诉求，将不同产品的一些工具进行组合，最终以数据门户的方式做统一的呈现。

决策者-1d 和核心的数据分析的人员会去关注问题发生的原因，以及未来将有可能是什么样的表现，关注的是归因和预测。数据产品的归因功能可快速提高定位原因效率。

部门的管理者和分析师主要将问题进行更细的拆解，分析原因、调整策略。数据产品将细化业务场景，快速寻找匹配的产品功能，提供产品组合服务。

一线人员承接具体执行的工作。他们最关注的是拆解给“我”的目标是什么？我是否能完成这个目标？如果无法完成，我接下来该怎么做？他们希望快速看到数据结果、自助分析查找原因，甚至有的时候都不知道自己要看什么样的数据。所以针对一线人员，




需要提供批量复制的产品能力，比如提供多维分析功能，让他们去做数据的探查；提供自主取数功能，便于快速的做一个小的决策。

所以无论是数据分析还是数据产品，包括产品服务的组合，其实帮助业务解决的是业务发生了什么，为什么发生和怎么样去解决问题。从分析的角度上来讲，自上而下是一个大决策和小监控的过程；而从数据产品的角度来讲，自上而下是大监控和小决策的过程。

04

应用案例

接下来分享一个某二手车 2C 业务数据产品化的案例。





做为互联网垂直领域的二手车交易平台，其主要特点是为买家和卖家提供撮合交易平台。其商业模式在某种程度上是一个互联网+汽车+金融+新零售的交叉行业。业务流程涉及多角色、多环节，仅平台交易流程就涉及 12 个核心部门。领域交叉性、交易链条长、系统复杂性等问题，为数据化管理带来很大难度。

某二手车2C业务数据分析体系



我们首先需要去看二手车企业在当时的环境下，目标是什么？目标就是要实现盈亏平衡。围绕着盈亏平衡，数据分析有五大核心模块：

- **第一块宏观策略：**面向决策者，提供宏观的一些判断，比如竞争对手发生了什么，市场行业是什么样的表现，新的业务模式值不值得去做等等。
- **第二块目标管理：**就是根据整体的目标去做一个阶段性的拆解，未来一年的目标是什么，每个季度、每个月的目标是什



么，每个月怎么做目标拆解，每个大区 and 每个城市是什么样的表现，效果如何？接下来应该如何去调整目标、优化策略，让业务增长变得更健康。

- **第三块经营分析：**商家、车型、品类、供给者、消费者、销售、线索等精细化运营的数据挖掘与分析。比如：钱从哪儿来，各个类型的车是怎样表现的，花费有哪些，销售人员的花费是什么，给用户的折价怎样管控等等；车的库存周转如何，单店经营的如何，收售之间的联动转化如何？以及公司级重大专项的营收表现。
- **第四块人效管理：**人员效率怎样，人员是不是饱和了，什么时候该招人，什么时候该缩编，KPI 考核标准是什么，人员成长体系和激励政策是什么，都需要通过数据分析和商业分析来提供有效的支持。
- **最后一块是产品。**如何提升效率，我们要去找在数据中最懂业务的人，也就是数据产品，来将经营分析核心的思路沉淀成数据产品；将目标管理、收售联动、供应链转化、商品品类、门店经营系统化、产品化。



数据分析和产品人员沟通的重要依据就是指标体系。

业务分析人员要给产品讲解业务的目标，也就是“降低运营成本、提升运营效率、提高利润水平”。围绕着核心战略，我们要进行人、货、场的拆解；从收售联动的角度去建立指标体系，将业务过程、结果、效率通过指标的形式，量化拆解到每一个子部门，以及每一个业务人员上。通过这些指标表现，判断策略落地执行的效果，从而起到量化管理的作用，最终实现业务的精细化运营。

05

总结

最后做一个总结，不管是数据分析还是数据产品，都应深入业务、面向业务去解决业务痛点。业务人员帮助我们去沉淀策略打法、丰富业务场景。同时，数据分析和数据产品之间也是相辅相成的



关系。分析可以帮助产品去系统地理解业务和沉淀分析的方法，而产品可以帮助分析去抽象通用的能力。他们都有共同的目标，那就是解决业务痛点、快速赋能业务、提高整体效率。

■ 总结



今天的分享就到这里，谢谢大家。



网易数据治理工具-资产 360 产品实践

网易 NETEASE | DataFun.

网易数据治理工具- 资产360产品实践

云娜 网易 数据产品



分享嘉宾：云娜 网易 数据产品

编辑整理：冯敬舜 神策

出品平台：DataFun

导读：大家好，下面由我来给大家分享数据治理工具的产品实践。整个分享我将从下面这四个方面进行介绍，分别是网易内部业务线过往的数据治理回顾，当前面临的数据治理痛点，针对痛点，数据治理平台整体的产品策略以及未来的规划。



目录

CONTENTS

01 过往数据治理回顾

02 当前的治理痛点

03 产品整体策略

04 未来规划



一个数据人的自留地
SHU JU REN CLUB

DataFunSummit

01

过往数据治理回顾

01

过往数据治理回顾

- 严选/传媒/音乐 数据治理专项
- 初步取得的成效



一个数据人的自留地
SHU JU REN CLUB

DataFunSummit

首先，对于内部业务线，包括严选、传媒和音乐，都做过数据治理专项活动，也取得了初步的成效。



■ 专项治理背景回顾

- 随着业务的发展，严选、传媒和音乐的计算、存储达到瓶颈，难以判断需要继续扩容增加资源，或对劣质数据进行治理以降低资源危机，但如何定义劣质资源，怎么进行治理成为亟待解决的问题。
- 同时，数据的生产链路长，缺乏数据加工的统一标准，团队内有哪些数据，负责人是谁，通过哪些任务产出，数据有没有被有效使用，数据的存在是否有意义，数据团队都难以准确回答。



对于进行数据治理专项活动的背景，一方面随着业务的发展，内部业务线的计算和存储达到瓶颈，但业务方很难判断，是应该继续扩容增加资源，还是对劣质数据进行治理来降低资源危机，但在这个过程中，如何定义劣质数据，定义了劣质资源后，要怎么对其进行治理，都是亟待确定和解决的问题；另一方面，数据本身的加工链路长，数据的加工处理没有统一的标准，整个团队内到底有哪些数据，数据的负责人是谁，这些数据是通过哪些任务产出的，这些数据有没有被有效的使用，数据的存在是否有意义，这些都是管理者比较关心的问题，但数据团队都很难回答。



对于各个业务线面临的共同问题，在专项治理活动中，我们给出了针对性的策略。首先将表和任务具体化到责任人，由责任人进行资产梳理，对于没有人认领的资产，比如没有负责人、负责人离职或者负责人为项目等情况，那么就由各个业务线指定专门的治理负责人进行专项治理；然后对于存储资源，首先对无用数据进行规则定义，明确到底达到什么指标可以作为无用数据，比如近 90 天访问次数均为 0 等，确定好无用数据的规则后，将项目内无用数据扫描出来，业务方对无用数据进行二次确认，产品上提供操作入口快速下线，同时提供下线列表或累计下线数据等，进行闭环分析；对于计算资源，会对离线任务、自助查询任务消耗的成本进行分析，包括任务的执行时长、预估消耗的费用、消耗的 CU 等内容，便于业务进行优化，也给任务的下线治理提供依据，成本分析会默认保留近半年的数据，在对任务进行优化后，也可以进行对比分析；最后，对于存储和计算优化后，治理



效果要可量化和评估，比如确认下线的存储有多少，对任务优化后节约的资源有多少，便于管理者和治理负责人对治理成果进行评估。



对于治理效率量化可评估这一策略，我们内部有一套自己的成本度量体系。基于底层的表信息、计算任务信息和任务/表之间的血缘信息，汇总为计算、存储的元数据仓库，结合网易内部自己的账单体系，体系中对计算和存储均进行了定价，从而将调度任务、自助查询每次执行消耗的计算成本预估出来，对于存储成本，一方面包含数据表本身的存储成本，另一方面产出该表的计算任务也会分摊该数据表的成本，最终得到数据表总的存储成本。将计算和存储成本转化为费用，更加一目了然的对治理效果进行量化评估。



1-产品功能落地

1-任务/表具体化到责任人

2-无用数据下线功能

3-表生命周期设置

4-计算任务成本分析

上述专项治理中提到的策略，在数据治理工具平台均进行了产品功能的落地，通过平台化的功能，进一步提高治理效率。对任务/表具体化到责任人策略，平台提供项目内所有表的列表，支持查询、转交责任人等功能；对于无用数据下线功能，平台基于对无用数据的规则定义进行扫描，提供对无用数据下线的入口，确认下线后，默认会将数据表移到灰度空间保存一定时间，到期之后，平台才真正对数据进行删除；对于数据表的生命周期管理，提供功能入口，针对内外部表均可设置，并且对于外部表，支持可选是否删除目录文件；对于计算任务的成本分析，对项目内所有调度和 Query 任务进行扫描，分析任务成本，默认保留近半年的成本记录，便于对任务优化前后进行对比分析。



在治理效果衡量体系中，提供待治理和已治理的负责人红黑榜单，便于管理员和个人进行查看，对于产生的费用和下线的存储等内容，从项目和个人角度，提供资产大盘，更加清晰的了解治理的效果。



同时，为了更好地触达负责人进行数据治理，建立了邮件和内部工具的通知机制，通知内容分为了两个视角，一方面是治理负责人，可以



了解当前自己还有哪些数据需要进行治理，治理后可以给项目节省多少年费用；另一方面是项目的管理员/负责人，可以知道当前项目下一共还有多少数据需要治理，治理后总共可以节省多少年费用，也可以知道整个项目中治理做的好的负责人 Top5，以及还有那些人占据的成本最多，可以以此为依据，催促负责人进行治理工作。

初步取得的成效

- 2020年：为云音乐、严选分别优化了47.6%和61.0%的表；
- 为传媒节省了38%计算资源，约合人民币1.5万。

治理项	云音乐优化数量	优化占比	严选优化数量	优化占比	传媒优化数量	优化占比
Hive表数量	6.4K	47.6%	5.1W	61.0%	2.1W	18.2%
数据存储量	1.2PB逻辑	9.0%	1.05PB逻辑	27.1%	----	----
任务与资源	----	----	----	----	48个	38%

• 指标说明：下线Hive数：面向业务的近30日无任何读操作的Hive表数量；优化数据量：上述表对应HDFS逻辑存储量

在专项治理活动中，通过上述的多种策略，初步取得了治理成效。2020年，为云音乐和严选分别优化了 47.6% 和 61% 的表，也为传媒业务线节省了约 38% 的计算资源，数据治理各个业务线的专项活动策略得到了业务方的肯定。

02

当前的数据治理痛点



第一章主要讲解了内部业务线数据治理专项活动采取的策略以及初步取得的成效,接下来重点阐述当前数据治理仍然面临的痛点和那些怎么也填不完的数据"坑"。



当前的业务数据治理，主要面临这样几个关键的痛点：首先业务数据本身没有规范化创建和管理，比如外部表定义目录不规范，有些分区



目录 location 的是表的目录，在对表生命周期进行管理时，若选择删除目录，那么文件就会有被误删的风险；数据开发团队人员更换频繁，面对众多的业务需求，疲态应对，处于只开发不治理的循环中，数据治理的动力不足，项目内遗留大量的历史数据；还有就是当计算和存储等资源达到瓶颈后，被领导催着进行治理，缺乏长效的数据治理机制，导致阶段性治理和资源告急循环往复；然后是治理的效果量化指标粗糙，哪些负责人下线了哪些数据，为项目节省了多少存储，具体节省了多少费用，没有有效的可评估的数据，这也衍生了治理者的消极心态。

1-依旧填不完的数据“坑”



依然存在的成本问题

- ◆ 传媒有72%的表30天内都没有访问，占据了6P存储空间
- ◆ 严选有近39.0%的表30天内都没有访问，占据了2.7P存储空间
- ◆ 音乐有50%的表30天内都没有访问，占据了近7P存储空间

虽然在上一章也有讲到，数据治理专项活动取得了初步的成效，但依然还存有很多成本问题需要持续进行治理，包括严选、传媒和云音乐都各自有一定比重的表处于待下线状态，占据了相当一部分的存储空间。



2-依旧填不完的数据“坑”



前路漫漫 道阻且长

> 存储成本

数据量持续增加，源源不断的带来存储成本

> 计算成本

队列资源持续紧张，任务优化迫在眉睫

> 数据质量

加工链路长，任何一个环节都可能带来质量问题

> 模型规范

基于ODS、DWD层生成的报表数量居高不下，模型复用率低

> 数据安全

管理员成员繁杂，权限太大如何控制，闲置的权限如何回收

> 数据价值

数据服务API、BI报表等下游应用系统，引用表的存储和计算成本如何估量，如何通过下游应用量化数据价值

数据治理这条道路，真的可以用前路漫漫，道阻且长来形容了。针对成本，包括计算和存储成本，数据量持续在增加，源源不断的带来存储成本，队列的资源也持续紧张，任务优化也亟待解决；对于质量，数据的加工链路长，任何一个环节都可能带来质量问题；对于规范，基于 ODS、DWD 层直接制作的报表数量居高不下，模型的复用率低；对于安全，项目内的管理员数量众多，太多人有比较高的权限，权限太大应该要怎么控制，以及离职等人员闲置下来的权限应该怎么收回；对于价值，API、BI 等这些下游应用系统，引用表和计算成本要如何进行估量，怎么根据下游应用来量化数据价值。这些都是在数据治理过程中需要持续关注和解决的问题。

03

产品整体策略



第二章讲到了当前面临的数据治理痛点，以及从成本、质量、规范、安全和价值各个方面都有亟待解决的问题。本章将针对上述面临的问题，提出治理方案，并将数据治理过程进行体系化建设，整体形成闭环。





数据治理本就是一个阶段化的工作，做不到一口能吃个"胖子"，达不到一开始就能把治理工作做到极致，数据治理整体可以分为这样三个阶段：治理的范围、治理的价值和体系化的治理。首先要让决策者能够看见和关注，对数据治理的范围进行系统性的梳理，明确需要进行数据治理的范围；其次需要有一套抓手，能够让真正做治理工作的负责人看到问题，并且有可量化的体系，对治理成效可评估；最后将治理过程中的策略能够落地到产品功能上，通过短期业务线的宣传运营和长期的闭环机制，整体达到体系化的治理。



下面针对上述提到的阶梯化治理的各个过程进行详细的介绍。初阶段是明确治理范围，整个是围绕数据的全生命周期展开的，在数据生产阶段，需要对需求进行分析，明确业务口径，对数据进行规范采集、任务开发和监控运维；在数据消费阶段，涉及到快速的查找数据，对数据的分析和对数据质量的探查；在数据管理过程中，包含权限和成



本管理等。整个流程涉及到成本、标准、质量、安全和价值，各个阶段都会面临对数据的治理工作。




明确了数据治理范围后，然后是对于数据治理价值的量化。基于数据的全生命周期，包含了成本、质量、安全、标准和价值五个方面，针对每个方面，都要有可量化的指标项，对于成本，包括计算和存储成本的费用量化，对无用数据的下线治理等；对于价值，需要能够评估每个数据模型、数据报告和 API 的价值；对于质量，会包含监控任务覆盖了多少稽核规则，涵盖了多少强弱规则；对于标准，需要对指标和模型进行规范化定义；对于安全，会包含数据安全登记和数据权限的治理等工作。



3-体系化的数据治理

资产治理产品的定位：面向公司的 **大数据资产健康评估体系与优化工具平台**，用大数据治理大数据



数据治理不是一个临时性要做的工作，从数据生命周期的全过程到治理体系的健康运行，需要一个长效的治理机制来保证，最后就是体系化的数据治理。最开始是发现问题，包含成本、标准、质量、安全和价值五个方面，明确需要进行治理的内容；然后基于需要治理的内容配套专题的治理工具，比如对无用数据的推荐下线，对表生命周期的管理，对计算任务的优化等；最后在治理工作过程中，持续有治理抓手，包括推送整个项目、个人的资产账单，数据治理的红黑榜，并将资产健康分和个人的任务优先级或资源申请等挂钩，然后内部也举办了数据治理大赛、业务线专项治理活动等来持续运营产品功能。整体通过发现问题-->解决手段-->持续运营和持续沉淀形成资产治理的闭环。

04

未来规划



第三章主要基于之前提到的数据治理痛点，给出了治理的整体策略方案，下面讲一下数据治理工具的未来规划。





关于资产治理产品的架构，绘制了一个房子图，如图所示，数据资产治理平台的使命是降本提效、省钱省力，愿景是能够打造成一款全流程、自动化、可落地、高质量的大数据评估和优化工具，成为数据治理的利刃。在这个过程中，以资产健康分为主要抓手，涵盖成本、质量、安全、标准和价值，各个模块均包含需要治理的内容，并且针对资产健康分的不同等级，也会和任务的优先级、申请资源等权限挂钩。同时配合通知机制，从管理员和用户个人不同角度，对资产治理工作进行触达，调动治理的积极性，提供便捷的治理入口，形成体系化的治理体系。

今天的分享就到这里，谢谢大家。



数据中台的底层逻辑

一个数据人的自留地 | DataFun.
SHU JU REN CLUB

数据中台的底层逻辑

赵壮实 数据产品经理



分享嘉宾：赵壮实 数据产品经理

编辑整理：王宇 武汉大学

出品平台：DataFunTalk

导读：2015 年以来，“数据中台”已经成为了一个爆款词汇，也经历了 2020 年阿里“拆中台”的问题，今天主要从科普和企业实践两个角度来介绍一下数据中台。本次分享题目为《数据中台底层逻辑》，主要介绍：

- 什么是数据中台
- 为什么需要数据中台
- 数据中台的原则



- 数据中台实践

01

什么是数据中台

2015 年，马云老师去芬兰一家游戏公司 supercell 考察，这家公司人数不到 200 人，但是却成为 2015 年全球营收最高的游戏公司。它曾推出《部落冲突》（Clash of Clans）、《海岛英雄》（Bomb Beach）、《卡通农场》（Hay Day）和《皇室战争》（Clash Royale）。为什么人数不到 200 的 supercell，在 2015 年可以成为全球营收最高的游戏公司呢？通过组织能力的发现，它的组织架构和一般的组织架构不同，传统的组织架构是从 CEO 到市场、经营、运营、产品、技术等部门的形式，但是 supercell 呈现的是一个从中台发散再到各个部门的形式。国内也有类似的模式，如字节后来建立了自己的数据中台、增长中台、营销中台等等，以中台式来支持一个 APP 工厂进行快速地迭代、试验和审核。



■ 什么是数据中台

为什么人数不到200的supercell，在2015年成为全球营收最高的游戏公司？
因为每个团队充分自治，而公司会提供强大的游戏基础能力（中台）。



一个数据人的自留地 | DataFun.
SHU JU REN CLUB

阿里数据生态的变化经历了 13 年之久。最早可以追溯至 2007 年，阿里的“遵义会议”后，确定了阿里是一家数据公司。2014 年，阿里确定数据上云，此时的阿里，无论是从思想储备还是技术储备上，都已经达到了数据中台储备的要求。2015 年，马老师去芬兰 supercell 公司考察，年底便成立了阿里中台事业群。到了 2020 年，出现了一种“中台是毒药还是救命稻草”的争论观点，逍遥子在阿里内网说中台没有达到预期，希望“中台变薄”。大家可能会觉得中台被妖魔化了，也不太被需要了，但我更想说的是，我们当初建立中台的时候，其实是根据企业自身的目标和原则来建设的，自然不会因为中台的污名化就将其舍弃。




阿里数据中台，13年之变



那什么是数据中台呢？从阿里的视角来看，开始的数据开发是烟囱式的，比如淘宝、天猫、1688，但这种开发不能支撑整体的数据运维，后来就变成了由共享数据，从商品、品类、价格、用户、交易、评价等以中台为所有业务线进行数据支撑的方式。

什么是数据中台



阿里的数据中台的定义是：方法论 + 组织 + 工具



- 方法论：OneID+OneModel+OneService
- 组织：从 IT 支撑到业务赋能的数据、技术、产品相匹配的人才结构，包含数据产品经理、数据研发、数据科学家等多角色
- 工具：采集、构建、管理、服务等

广义上，数据中台是指通过数据技术，对海量数据进行采集、计算、存储、加工，同时统一标准和口径。

我从网上找了一些阿里的中台图，事实上中台并没有一个准确、统一的概念。但是从图中可以发现，OneData 和 OneService 是一直存在的。从我的经验和对中台的理解来说，OneData 覆盖的范围包括数据源的统一整理、数据开发和生产、数据模型创建和指标口径的统一。OnePlatForm 是以产品形态中台式的建立提供工具给业务方使用。OneSevice 更多的是提供 API 接口，将血缘、引擎、API 综合式的从中台提供能力给到业务方的各个平台，包括数据平台、交易类平台等。




什么是数据中台



一个数据人的自留地 | DataFun.

什么是数据中台



一个数据人的自留地 | DataFun.



什么是数据中台



02

为什么需要数据中台

为什么需要数据中台？数据中台主要是解决以下 5 个问题：

- **指标口径不一致。**阿里在建设的中台之前有三万多个指标，这些指标存在命名相同定义不同的问题。例如 DAU (Day Active User)，Day 的定义可以是 0-24 时的自然日，也可以是类似 2 点-2 点这种 ETL 开始数据调度的日期，像一些海外新项目，不同的地区属于不同的时区，也会有不同的时间。所以 DAU 对于不同的岗位视角或者业务视角，Day 的定义也有所不同。又如 Active 的定义，可能以下载一个 app 为口径，可能是注册下载，可能是注册手机号之后的行为，可能是打开 app 等等为口径，这种就会造成口径不一致的现象。



- **数据重复建设。**数据重复建设主要包括两种情况，一种是数据中台类型和业务型小中台会出现很多数据重复性建设的问题，另外一种是在业务线上不同岗位的人，比如数据 PM 和商分会进行重复性的数据建设，从商分的工作习惯来说，他们会进行很多多口径实验，对数据产出、更新迭代以及维度指标的要求比较丰富，而数据产品不能立刻满足他们的需求，所以便导致了这种常见的重复性建设问题。
- **取数效率低。**一般大厂都有几万张的表，不同的表从 ODS 层到 APP 层各分布在不同的层级，这样便造成了信息的不透明不对等，从而导致取数效率低。比如想要取一张 ODS 层的表，然后再到一张 APP 层的表，二者的容纳项可能有非常大的差异，所以就造成了取数效率低下的问题。
- **数据质量差。**由于多烟囱、多岗位、多部门式情况的存在，导致数据无法全链路勾连，不能成为全链路中的一个血缘，因此必然会产生数据质量差的问题。
- **建设成本高。**上述问题导致了数据在计算、存储上建设成本高的问题，可能不同部门的人都需要从头到尾了解研发流程的每一个细节，其中的坑每个人都会踩一遍，浪费研发人员的时间精力成本。而且在没有规范管理标准的情况下，也会存在数据表层次力度不清晰的问题，为数据存储带来巨大的成本负担。



基于此，数据中台是一个比较好解决这些问题的策略。

下面是一个数据中台解决问题的例子，对于大型公司来说，一般形成了数据中台、业务数据支持、业务前台三者之间的勾连关系。

- 数据中台可以解决一些问题，包括数据来源一致问题，例如日志型数据、DB 型数据、文件上传型数据和 SDK 数据；建设口径一致问题，例如可以通过一些建模型的产品工具、指标元数据管理产品来保证建设口径一致；同时可以通过技术引擎和存储管理的迭代来降低存储成本。
- 中间层是业务数据支持，它可以保证业务口径的一致，例如保证原生指标、派生指标、衍生指标达到业务口径的一致性以及流程的顺利运转；计算逻辑一致，例如渠道指标和维度达到计算逻辑的一致；提升取数效率，通过 SQL、看板还是分析效率型工具来实现取数效率的提升。
- 业务前台虽然不直接参与数据建设，但是可以从数据指标搭建、提升分析效率两方面提高数据的使用情况，同时可以从 B 端或者 C 端视角对整体的数据链路形成反馈。



案例：数据中台如何解决



03

数据中台的原则

不是所有的企业都适合建设中台，如果企业具有下述三点特征，可以尝试建设数据中台：

- 企业有较多数据应用的场景（3+）。3+以上会出现重复性数据建设的问题。例如一家新零售或者电商公司，它有许多不同的部门，可能包括 2C、2B 甚至 2G，通过建设数据中台，可以实现用户表、区域表、用户画像标签的打通，比较适合数据状态性的建设。
- 企业有效率、质量和成本的压力。数据中台是解决数据计算、引擎、存储压力的有效方式，如果公司有效率、质量成本压力，是适合建设数据中台的。



- 企业面临经营困难/高速增长/数字化转型，需要通过数据实现精益运营。传统的 OA 或 CSM 系统不能实现数据打通，而且数据量比较有限，数据中台可以通过 Hadoop、MapReduce 来运营更大量级的数据。

数据中台的组织原则：

- 原则一：五指成拳，核心资源给到核心项目。数据中台不太适合业务上的赛马逻辑，因为它本质上是一个不产生效益的职能型部门。业务上一般是 RD、算法、工具、数据十八般武艺都会一点，而中台同学，尤其是 RD，需要对资源、引擎、数据、算法专业分门类研究得细致入微，所以它不应该采用赛马逻辑，而是核心资源给到核心项目，采取每个同学在自己的方向上精进的逻辑和原则。简单来说就是自己不要卷起来。
- 原则二：通用平台而非 BP 制。BP 制容易向某一个业务倾斜，导致中台不能复用，而中台强调通用性。
- 原则三：不能急功近利，朝令夕改。作为中台的领导者或是策略的制定者，不能急功近利、朝令夕改。由于中台职能型的性质以及员工的分门别类，中台其实是一个“慢工出细活”、“老火炖鸡汤”的一个部门，可以以半年或一年为粒度，在技术和产品上做一些引领性的东西，达到赋能业务的目标。



数据中台：组织原则



数据中台的方法论原则：

- onedata，“一个生产”。从数据源，到数据建模，到指标维度口径，对数据进行打通形成的全链路就是 onedata。
- onemeta，“一个资产”。数据建设完成后，如何进行数据管理、数据地图，方便各个业务线进行数据查找；数据作为一个不停计算的资源，如何进行管理；数据如何进行下线。这些维度都是 onemeta 的覆盖范围。
- onesevice，“一个服务”。即把不同的引擎技术能力通过 API 的形式为业务赋能。Onesevice 是数据中台正在探索、实验的项目，不同的公司在 onesevice 的进展上有所差异，但是 onedata 和 onemeta 是比较成熟的。



■ 数据中台：方法论原则



原则一：onedata “一个生产”
原则二：onemeta “一个资产”
原则三：one service “一个服务”

数据中台的技术原则：

数据中台的建设一般包括四个模块，通常是“三横一纵”的架构。“三横”自下而上分别为数据接入、数据开发和数据应用。数据接入包括日志接入和业务数据接入。数据开发分为离线/实时数仓开发、数据测试、数据监控与质量监测。数据应用是最上层，例如 A/B 测试产品。“一纵”是数据管理产品，包括元数据管理、资源管理、资产管理、数据治理和数据安全。



数据中台：技术原则



04

数据中台实践

数据中台建设中 onedata 比较复杂，存在一些通用性的痛点，可以从来源、口径、规范三个方面来看。

来源：导致来源和计算逻辑不清。

口径：包括口径相同、口径不同、口径描述不清晰三种情况。口径即谁创建的？谁以什么逻辑创建的？谁以什么逻辑在什么时候创建的？

规范：


- 口径相同，命名不同，例如，电商和销售领域有订单核销券和订单关闭券两个定义，不同的业务线二者的定义是相同的，



都是下单之后订单被接收且没有退单的情况,但是容易误认为两个指标是不同的。

- 口径不同,生产者不同,例如,口径是不同部门建设的,还是相同部门不同岗位的人建设的? 口径生产者不同,逻辑就会难以追溯。
- 口径不同,描述事件相同,例如,描述的都是消费券,但是消费券是否被核销没有被注明,也会造成口径不同。
- 口径描述不清晰。例如 DAU 指标,如果没有对 Day、Active 和 User 进行准确的描述,也会造成口径问题。

■ 数据中台实践：onedata的困境



针对 onedata 的困境,对问题进行抽象,分别从来源、口径和规范层面进行修复。

来源：划分业务线——主题——指标维度



口径：维度与指标的业务描述和使用场景

规范：

- 命名规范：eg 原子指标和派生指标
- 组织与生产规范：生产流程、审核流程、授权流程、治理流程


下面举例说明 onedata 的实践。

来源：业务板块为电商业务；电商通常分为人、货、场，或者是用户域、交易域、商品域，该案例的数据域即交易域；业务过程是支付；修饰类型是专场/商品，时间周期分为实时、离线和维度指标（日、月、季、年等），此处为实时；修饰词为单个专场和单个商品；此处的原子指标是销售件数，派生指标为近 7 天所有专场的爆款率，度量为支付件数。需要注意的是，在指标管理里面可以区分原生指标和派生指标，因为它的输出是业务线上的看板数据，但是对于平台 BI 类分析型产品，不建议有原生指标、派生指标、衍生指标这种概念，容易造成指标膨胀，建议通过用户宣导来进行维度的分组或过滤，直接提供原子指标和清晰的维度，方便用户理解。维度即专场商品，属性为商品 ID 和专场 ID。



数据中台实践：onedata的实践

1.来源：划分业务线-主题-指标维度




一个数据人的自留地 | DataFun. SHU JU REN CLUB

命名规范：派生指标=原生指标+时间周期+其它修饰词，例如会员有黄金、白金、黑金等修饰词，就会产生派生指标。

数据中台实践：onedata的实践

3.命名规范：eg原子指标和派生指标



一个数据人的自留地 | DataFun. SHU JU REN CLUB


组织与生产规范：业务方提出需求，然后进行业务调研、需求分析和数据探查，需求一般来自于业务线上的运营、产品和分析师；确认需求指标和指标口径之后，对指标的规范进行定义，构建一致性维度、一致性度量和指标，这个过程通常由业务线上的数据



PM 或数据接口人实现；需求受理之后，进行模型明细设计，构建一致性维度和事实表，同时构建统一指标汇总表；进而完成代码开发、部署、运维和数据应用，最后可以应用于报表、OLAP 分析应用或者自主查询分析，这个过程由数据中台的数据 PM 来完成。

数据中台实践：onedata 的实践

3.组织与生产规范：生产流程、审核流程、授权流程、治理流程



05

总结

- 数据中台是通过数据技术对海量数据进行采集/计算/存储/加工，同时统一标准和口径的部门。
- 如果你有指标口径不一致，数据重复建设、取数效率低、数据质量差、建设成本高等问题，数据中台是解决这些问题的良药。



- 数据中台仍旧适合至少 3 条业务线/有降本增效需求/长期有耐心的公司。
- 数据中台的组织三原则/方法论原则和技术原则。（集中资源/非 bp/不急功近利）

最后，建议数据中台还是要为业务部门提供价值，核心问题就是效率、质量和成本的问题。

今天的分享就到这里，谢谢大家。扫码观看本文视频回放。





数据产品+数据中台双引擎模式实践



分享嘉宾：顾平@网易数帆

编辑整理：Hoh

出品平台：DataFunTalk

导读：作为一个“平台+品牌”双模式并存的电商品牌，网易严选（下文简称严选）的数据数据链路天然很长，这给数据化决策和数据化运营带来了不一样的挑战，严选如何打造数据支撑体系支撑业务发展？在 6 月 19 日的“网易数帆技术沙龙”上，网易数帆大数据产品专家顾平分享了网易严选数据产品建设实践心得，以及支撑数据产品建设的一些难点难题的解决策略。自 2017 年开始，顾平作为数据产品负责



人参与了从 0 到 1 建设整个严选据产品体系和数据中台，历经 3 年时间打磨，严选数据产品和数据中台已经非常成熟。

严选的模式，从供应端商品的设计、研发、生产一直到最后的消费端，整个链路都有数据，严选通过商品数据运营平台、营销数据运营平台、移动数据工作台和供应链数据运作平台等 4 种数据产品驱动全链路的业务。需要注意的是，数据产品下面一定要有数据中台中台去支撑，否则我们没办法做到数据产品的高效研发和数据质量，这是一种双引擎的模式，数据产品和数据中台，是数据双引擎。

01

数据产品：聚焦商品、营销与供应

网易定义的数据产品，是一类既反映分析思路又能与业务系统联动的决策型产品。数据产品最基础是实现可视化，在这个基础上还要去实现决策建议，比如说监控诊断，最终可能要去驱动决策，比如说这个数据产品里面的一份数据，可以直接同步到业务系统里面，生成采购单。对于数据中台来说，主要是提供高效的高质量的数据服务，来支撑上面的数据产品和业务系统。

严选组织架构主要有商品中心、营销中心和供应链中心，数据产品也是围绕这三大中心，针对不同的用户去开发的。针对营销中心的数据产品，叫伏羲-营销数据运营平台，负责消费者的数字化运营。针对



供应链中心，我们有一个叫河洛-供应链数据运作平台，负责数字化供应。针对商品中心，有大麦-商品数据运营平台，面向我们商品中心里面各个商品 BU。中间这一块是负责数字化管理的移动数据工作台，它的核心目标用户是管理层，但也开放给所有的业务部门。它是一个移动端产品，使用非常方便。



严选做的第一款数据产品是做移动数据工作台。因为数据中台或者数据产品最好是自上而下来做，让领导意识到数据的重要性，让他看到可以优化决策，他才能帮助推广数据产品，支持数据团队去做更多的东西。其实严选移动数据工作台最重度的用户就是严选 CEO，他的访问量是第二名的两倍多。

严选移动数据工作台是基于 H5，在严选 APP 这个壳的基础上面去增加了一些入口，有针对商品、销售、用户、流量等核心数据，也包括了 KPI 的实现情况，整个业务的监控都会在这里面。



结合严选 APP 做的好处是非常直观。这里面还有一个流量地图，开启之后，在 APP 界面中的每一个模块上面都会有一个半透明浮层，展示各个模块素材的点击量、转化率以及对销售的贡献，非常直观，业务都非常喜欢用这样的东西。


供应链数据运作平台的理念是需求驱动供应。因为严选连接了消费和制造商，对于供应链数据运作平台，核心就是把严选侧的销售计划、需求计划共享给供应商，严选专门为供应商制作了一个平台（业务系统），我们把数据输出到那个系统里面去，使得所有的供应商都能在那里共享到我们的数据，知道我们的计划是怎么样的，可以提前去生产排程。

供应链数据运作平台如果要定一个核心 KPI，那就是库转，我们应该让库转在一个合理的范围内，所以它核心要解决的问题是商品在什么时间点采多少量，它需要有需求计划之类的东西，还有一些规则，比如安全库存是多少，这个商品如果让制造商去开发了，他的开发周期是多少，这些数据我们都需要知道，才能够定义出一个商品应该在什么时间点采多少量，**这里面更多的是业务知识和规则。**

关于监控诊断，这是我们面向商品中心的大麦产品中的监控诊断，我们可以直接展示出哪些商品慢动销了，哪些库存高了，销量下跌了，有多少商品涉及到这些问题，这些异常情况都可以直接展现出来。如果业务方还要想要继续了解这里面到底是什么原因造成的，我们可以



有这种类似于拓扑图的分析，让它直接去定位原因，所以它既是个工具，同时也沉淀了知识。



02

数据中台：围绕高效、高质量构建

严选对于数据中台的定义，是高效的高质量的赋能数据前台的一系列的数
据系统和数据服务的组合。如下是我们数据中台全景图，最上面
那层黄的是数据应用层（即数据前台），包括了前面讲的数据产品和
业务系统，因为业务系统也会用我们的数据。



还有有数 BI，分析师用有数 BI 生产出来的一些报表，也是属于数据应用的范围。但是有数 BI 这个平台本身是一个敏捷分析的工具，所以我们把它放到了数据中台体系里面。绿色的部分是数据服务，它的核心服务对象是数据产品和业务系统。下面是围绕数仓的管理体系。蓝色区域整块都是基于网易有数去实现的数据中台体系。

高效高质量的实践，首先看高效分析，严选是基于有数 BI 实现的。

大家在做数据产品的时候会发现一个问题，做了一个数据产品给业务用，结果数据需求接踵而来，研发都来不及，这个时候我们需要有一个高效交付的方案，让分析师或者业务方能够自助地完成这些事情，我们把数仓建设好，分析师或业务自己来使用数据。严选的模式是分析师做报告，业务方提需求，所以在 BI 这块，底下是我们的数仓，分析师用数仓里面的数据，在有数上面去做报表出来，提供给业务人员。现在整个严选有数（网易有数·BI 在严选的私有部署）的用户有 900 多人，每天的 UV 要达到 400 多，有 8 万个图表。




具体而言，当我们的分析师收到需求的时候，他会通过有数大数据开发及管理平台提供的指标地图去找这个指标，已经实现了，就拿来直接用，如果还没有，他就提需求给我们的数据开发，然后来定义这个指标（指标定义的流程后文再讲）。数据开发去会利用我们有数的大数据开发及管理平台去进行一个主题域建设。**建设过程其实做需求的过程，这是一个螺旋式上升的过程。**

通过这个平台数据开发很容易就把需求给做出来，然后分析师用有数 BI 去进行可视化建模，他不需要写代码，本质上它设计的是面向业务的，可以快速完成一个模型，然后通过类似于制作 PPT 的方式去探索和实现数据的可视化。BI 主要是用来高效分析的，核心的价值就在于能够非常高效地迭代，通常上午来的需求下午就能出报表。

高效分析

分析师，使用网易有数·BI进行可视化建模、可视化数据分析

有数·BI：可视化建模

有数·BI：可视化数据分析

数帆技术沙龙 × intel

数据产品的高效交付，第一种方式，我们借用 BI 里面集成的功能实现，就是说把需求转嫁到 BI 上面，通过 BI 当天就可以把报告做出来，



然后通过集成的 API 直接把它集成到我们的数据产品或者是业务系统上面去。现在我们移动数据工作台里面已经有 20 多个报表被集成进去了，基本上都是 CXO 的紧急需求，所以交付要比较高效，很多时候小半天就能交付了，用户对这种高效交付是非常满意的。

另外一种方式是说我们真的要高效研发，我们构建了一个统一查询服务，这个服务其实就只有一个 API，数据需求来了之后，通过它我们只要去设计模型就可以了，这就是“模型即服务”，对于数据产品或业务系统来讲，他完全不用关心这个模型到底用了什么库什么表，只需要关心接口输入。

通过这一层，我们不仅仅把数据带出去，还把指标定义也带出去，这样的的好处是，不管在数据产品里面还是在业务系统里面，但凡是用到了同一个指标，它的定义也是动态获取的，是统一的。严选现在有 70 多个系统在用我们的统一查询服务。

关于数据质量，我们主要来看下指标一致性的保障，指标一致性我们是怎么去解决的？可能大家都听说过指标管理系统，但是如果真的只有这么一个系统，其实它跟 wiki 或者其他文档系统没有什么本质上的差别。指标管理系统的本质上的差别在于，我通过这个系统跟我整个数据设计、开发、使用的流程全部打通，这才是它最核心的能力。

定义指标的时候，要统一定义，因为指标代表了一种数据需求更是一种业务知识，不能说随便就定义一个指标出来。在严选我们是数据产



品经理和分析师一起来定义，我们拿到需求的时候，会一起商量这个指标应该怎么去具体定义。定义完成了之后，我们在有数大数据开发及管理平台里面的模型设计系统去设计它，设计完了之后才会去进行具体的开发。也就是说，我们数仓一定要先定义设计再去开发。



最后一层就是统一的使用，通过指标地图，我们的用户可以很清楚地知道他需要的指标在数仓的哪个地方，分析师和业务也能知道这个指标具体的定义是什么。统一查询服务在提供数据服务的同时也把这个指标带进去了，因为在模型设计的时候，会去定义字段绑定到哪个指标，通过这种关系，指标贯穿打通了从数仓到应用层。

所以同一个指标在应用层，不管是数据产品，还是业务系统，甚至是我们有数 BI（因为 BI 里面也可以动态引用这个定义），在任何一个场景下面，我们看到一个指标，它就是一个定义。我们的理念是说，不让分析师或者业务自己去开发口径，我们口径的计算逻辑基本上都



落在 DW 层，是由数据开发根据指标定义统一开发的，应用层更多只是筛选汇总，这就最大限度地杜绝了相同的指标在不同地方的数据结果不一样的问题。

03

数据治理：平台、规范与考核都很重要

这里只讲数据治理的大概思路，严选数据治理是围绕数仓建设开展的，利用了整个大数据平台以及一系列的流程规范和考核优化机制。数据治理贯穿了整个数据的生命周期，从需求评审就开始治理。



严选数据需求评审的时候，数据架构师、分析师、数据产品经理以及业务方通常都会参加。模型设计评审，数据架构师也会严格把关。到了任务开发，是一线的数据开发人员的责任，还有数据测试以及质量



稽核、链路感知这些以及任务运维问题处理，这些流程在整个有数大数据平台里面，都是有相应的功能去落地的。

同时，还要定一个考核体系。严选核心考核的有三点，一个是**跨层依赖率**，这体现了数仓的建设水平。第二个是**基线完成率**，严选定义了很多基线，比如移动数据工作台，领导们都是 8 点左右就开始看数据了，所以移动数据工作台所有依赖的任务 7:30 时候一定要完成。第三个是**有效响应平均时间**，是指一旦出了问题，我们能不能在业务方发现之前把它解决掉。

任务需要常态优化，为什么是任务？因为很多问题，业务最终感知到的，就是我们的数据不对，产出晚，核心就这两点，比如说我们数据产品里面的这个指标不对，或者说今天这个时候没产出，这些问题追踪下来，最终都归结到任务上面，所以我们会有一些常态化的优化的机制来优化任务。严选最近近 30 天的数据，跨层依赖率只有 0.97%，基线完成率 99.92%，有效平均响应时间是 0，因为最近 30 天没有什么报警，数据还是非常亮眼的。有了上面的方法论和平台工具，真正在落地的时候，我们还是要去以项目的机制去做这件事情，就是专人负责，量化考核。对我们来说，数据治理核心的负责团队就是数仓团队，因为它是围绕数仓展开的。



架构师、数据开发本身有一个固定的职责，是要去建设主题域，这是最核心的一部分。我们还会有很多的虚拟项目小组，针对我们所定义的数据治理的一些 KPI 专门负责。因为如果不这么做，我们会发现任务永远都优化不了，会经常出问题。

04

总结

网易有数核心有两个产品，一个是 BI，一个是大数据开发及管理平台。基于大数据开发及管理平台，可以快速构建数据中台，包括数仓建设和一整套数据管理体系，并对外提供数据服务。数据服务可以为数据产品和业务系统提供数据。



有数 BI 可以提供自助式的高效分析，主要用里面的报告模块，做好的报告也可以集成到数据产品或者业务系统中。

此外，有数 BI 还有一个模块叫数据门户，企业如果没有严选那样的研发能力去开发单独的数据产品，就可以通过这个数据门户高效交付基于报告的数据产品。

今天的分享就到这里，谢谢大家。



“转变”，贝壳找房数据平台演变之路



“转变”贝壳找房数据平台 演变之路

张勍 贝壳 大数据产品负责人



分享嘉宾：张勍 贝壳 大数据产品负责人

编辑整理：李采薇

出品平台：DataFunTalk

导读：本文主要分享如何通过数据产品，帮助具有 20 年历史的传统企业在行业互联网数字化转型，促使业务更高效的应用数据，数据平台产品在公司数字化转型的过程中是如何演进的，会遇到什么样的困难，以及产品建设过程中的思考与实践。并重点介绍贝壳数据平台建设的演进、治理过程。



01

贝壳业务及数据应用的背景

1. 贝壳业务



贝壳是一家产业互联网公司，房屋买卖交易是公司的主业。在房屋买卖和租赁过程中，整个交易过程很大一部分是通过线下完成。从交易视角看，房屋买卖交易是低频，周期较长的。随着科技的进步，贝壳也成功的把很多线下环节拓展到线上。目前，贝壳的商机主要通过线下门店和贝壳 app 获取，之后会带看、签约、最后到成交，这一系列流程中涉及到房源、客源、商机、经纪人、门店等。

从数据视角看，贝壳目前有全国最全的楼盘、房源数据、大量的经纪人行为数据、线上\线下商机数据、门店数据等，数据纬度多、



元素多，复杂度大。与纯粹的线上互联网公司不同的是，贝壳无法把所有交易过程线上化，只能尽可能的将交易关键节点先线上化。因为整个交易过程中，绝大部分关键节点都需要线下带看和经纪人沟通。这也就导致了很多数据是线下收集的，这也是贝壳数据呈线下化特点。另一个就是数据的延迟性。这里的延迟性是指数据的延迟性，并非系统的延迟性。比如签约、带看，并非完全和系统同步。在业务口都有“喜报”的说法，往往这部分数据都是线下先去填报统计但在时间上没有当天走线上流程，这样就会产生实际业务与系统记录的偏差。

综上，贝壳的数据呈类型多、复杂度高、线下化、延迟性的特点。

2. 贝壳数据



从数据建设以及数据应用的视角看，贝壳存在三类用户：



- 第一类，需要用到数据进行管理以及运营的，称之为数据应用用户。这类用户在贝壳包括经纪人在内的有 30 多万，他们通常用数据进行日常管理和运营，对数据诉求也非常多。
- 第二类，将数据进行加工处理、探索，做深度分析形成数据报告与分析结论的用户，如数据研发、数据分析师。从这张图可以看出，因为城市业务很“重”，业务对数据的诉求就是“快”、“准”，所以贝壳在全国近 100 个城市设有分公司以及加盟的品牌商，每个分公司都会设立相应的数据部门，每个部门人数不尽相同，但都承担着这个城市的数据收集、加工、分析、整合、报表制作、数据运维的工作，以满足城市大量用户的数据诉求。所以这类用户分布比较散，每个城市在从人员设定、系统性沉淀、组织协调、以及数据建设文化上会有很大的不同。全国来看，总共有上千人。他们给第一类用户提供管理、运营、店东、经纪人数据，这类用户也是平台的核心用户。
- 第三类，公司。从公司的视角看，在业务不断发展的过程中，日渐积累的大量数据如何衡量它的价值，如何构建良好的数据生态环境，赋能业务，是公司最关心的。对贝壳来说，最典型的数据资产价值是楼盘字典，通过楼盘字典将数据应用到业务应用中去，形成平台竞争优势。对于加盟品牌，在业务并网的同时，平台能否给予一套标准的数据解决方案，促



使业务的增长。另一方面，贝壳大量的数据用户如何形成数据文化，怎样联动城市和品牌商在同一标准下进行良性的数据运转，都是公司视角最关注的。

3. 数据应用场景



贝壳的数据应用场景主要分为管理、实际作业和品牌（系统）的应用。

- **管理：**可以理解为是战略层面的应用。贝壳业务重线下，管理层级深。管理的诉求是希望能够高效、精准的传达管理指令，从总部到城市，管理绩效、业绩、以及推行一些标准和规范，从而得到有力的管理抓手。例如今年在做的经营健康度管理，总部会用近百个健康度指标，通过多维度去观察各地的经营健康度，通过数据、指标达成统一的管理语言，确



保城市和总部的理解一致。在这个过程中，指标数据需要进行高效的传递与交互。

- 作业：可以理解为是战术层面的应用，更细粒度的管理场景，通常是一城一策，覆盖店东、商圈经理、经纪人层面。所以，不同城市业务人员不同，对数据的使用颗粒度以及关注视角都不同。战术层面的数据使用粒度更细，会关注到人、单。例如门店管理时，会关注经纪人的带看情况。
- 品牌：是系统层面的，在品牌加盟的同时，有数据对接与供给、系统对接的诉求，贝壳希望能够给到他们一套完整、有标准化的系统提供数据服务的能力。

02

贝壳数据平台的演进

1. 过去

① 平台的样子



2018 年加入贝壳的时候，主要接手两个平台产品：

- 指标平台：主要基于 Kylin 构建。通过平台构建指标，设定度量和维度，数仓基于指标需求开发数据表，在进行 cube 的构建。用户可基于已经开发好的指标，再进行报表的创建。用户获取数据、报表查看都集中在指标平台，另外还有结合不同用户群体的定制化产品，例如特定面向经纪人、店东的数据产品。
- 数据管理平台：是数据底层能力集，面向数据研发，包括数据采集、加工、调度、以及数据服务的能力。

两个平台从数据加工采集到数据应用都涵盖了，那么对于公司、用户来说，都有哪些问题？以下将从效率、平台、数据质量、安全的角度剖析。



② 面临的问题

公司的数据能力建设以及应用、是一个复杂而庞大的体系化工程，单点突进（例如查询引擎特别好，数仓建设的完备）对用户来说，依然会在某些场景有体感不适的情况。所以数据能力建设一定是齐头并进，抽象聚焦的。一般来说，重点聚焦在：数据应用效率、数据质量、平台系统、数据安全几方面。

效率：



从效率讲，主要是数据流转问题：

- 报表、看板：数据应用中最基础最常见的报表、看板需求。

以往基于指标平台，需要先有指标、开发，然后通过指标数据再进行数据可视化配置。所以这就带来一个问题，必须先有指标，才能配置报表，这样会非常依赖数仓开发指标的



人力资源，一个成本高，另一个是效率会有瓶颈。从管理以及用户的角度看，由于缺少横向拉通，重复建设的情况非常严重，所以平台指标的复用性对效率非常关键。当时的现象是指标设计不够灵活，平台设计、产品引导上也没有引导用户去复用他人的指标，另外受制于权限的审批，导致很多人不会去利用已有的指标，而是新增指标，这就增加了数仓的开发压力，进入恶性循环。业务经常抱怨往往提一个指标，基本都是 T+1 周起，有时候时间长了，指标开发出来了，业务又变化了。这种情况导致用户都自己去写 sql 提数据，集群每天的查询负载非常高。

- 城市：当时的指标、以及数据源是没有办法设定行级权限的，导致城市的用户无法使用指标数据，致使他们的数据获取更复杂，需要在平台上、系统上、线下收集各种数据，然后通过各类第三方工具将数据整合起来。所以每天会花费大量的时间来进行这个操作，效率非常低。各个城市也会有很大差异，有的城市为了简化这个过程，招聘一些有技术的分析师，搭建本地库，通过自动化脚本的方式来提高效率，最后整合成用户需要的数据，通过截图、excel 的方式传递给用户。这种情况一是会导致数据安全性无法保障，另一个会形成无数个数据孤岛，平台逐步变成了数据源供给平台，公司的数据建设没有统一性，数据的准确性、一致性、以及数据运维难度会越来越大。



- 权限：很多线下审批并没有到线上，通常都是固定在每周的某一天固定由专人处理，导致效率非常低。



平台：

从平台视角看，kylin 解决方案满足不了所有场景，贝壳的业务维度多，很容易发生维度灾难。平台的设计是基于当时历史情况来设计，但业务、公司的变化飞快，平台不能适应变化导致系统模块在平台上融合度不够。用户另一个直接感受是技术元素过高，平台的易用性不够，很多功能使用前需要咨询，增加了沟通成本，平台门槛过高。

质量：

同时，对于当时的平台设计，也是缺乏数据管理与管控的。指标需求越来越多，埋点也越来越多，导致指标、埋点、数据表等只




增不减。最后，指标数量破万，埋点事件 2 万多。这样的情况对于用户来说，不知道该用哪个，自己再重新提需求建设，进入恶性循环。对于公司来说，存储、计算压力与日俱增。并且由于效率问题，大家开始自行写 Sql 提数据，下载数据与线下数据整合等，数据出口非常多。没有统一的管理，数据准确性、一致性遭到用户的存疑，数据信赖度降低，每天的对数成本非常高。

安全：

数据安全同样存在问题，平台的主力功能是数据获取，用户从平台下载数据到本地，通过截图、PDF、Excel 进行传播，也没有水印，数据安全存在非常大的隐患。

用户感受：





过去，我们的用户花了 70%-80% 的时间停留在权限获取/数据处理加工和对数上。从右边五个维度看，平台打分也都不是很高。所以对于未来，贝壳平台要如何演进？

③ 需要什么？



我们希望减少用户在数据加工上的时间，提高用户上层的效率，产出更多价值。同时，致力于成为提供高效、安全、可信赖的平台。

④ 怎么做？

贝壳需要怎么做？主要考虑以下两方面：

- 整合扩展：把平台上的能力整合到一个地方，形成闭环。



- 线上化：之前的分析模式包括数据供给模式都是线下，怎么能够将线下跟线上数据做整合，并且用线上的方式实现需求，同时保证质量和安全。

2. 演进

① 平台演进路线



从背景以及平台带来的问题来看，如果要解决效率、质量、安全的问题，需要把用户整个分析流程全部囊括到平台中来，降低门槛，给予用户更多的自主性、灵活度，同时也要有规则标准进行保障约束。

在 2018 年底，结合用户和公司的诉求，公司开始研发数据分析平台——奥丁。希望通过平台建设，将原来不能满足的诉求一一实



现，将用户自成体系的建设数据方式，逐步迁移到平台上来，把数据孤岛逐步整合到一起。

首先要能覆盖用户线下加工分析到传播的全流程模式：

- 接入：我们对数据源接入进行了扩展。不单单是 kylin 为基础，这个期间我们扩充了更多的查询引擎，例如 druid\presto\impala，进行统一的路由，用户也可以直链到 hive、excel、csv。不再单单是指标了。
- 数据建模：分析过程整合集成数据建模、数据探索的能力。原来的数据加工基本是在数仓团队，或者有能力开发的人通过写脚本在客户端开发，绝大部分的人数据整合、探索依赖第三方工具。平台整合后扩展了数据查询、数据建模，可以最佳的自主化，把探索建模过程落地到线上，而不是各自为战。
- 可视化：提供统一的简单可视化配置能力，用户可以方便的通过拖拽的方式完成数据可视化的工作。以上三步其实更多是在分析师的层面上也就是就是数据内容制作者去实现的，可视化内容制作后，我们会结合不同的应用场景给予不同的输出模式。
- 应用：通过数据应用配置结合场景给到相应用户，可以配置移动端、门户以及驾驶舱。



通过提供一套完整的数据分析体系，整合底层数据引擎、权限、数据管理的能力，输出一整套数据平台能力和服务，释放给平台用户。

但在这个过程中，平台的能力建设是重要的一步，另外更重要的是数据内容建设本身，数仓的模型建设是更重要的，用户需求多样，数仓在这个过程中抽象需求，形成高可用、易懂的数据供给。

② 奥丁分析平台



奥丁分析平台于 2018 年启动，前后经过了几个版本，这几个版本都是结合当时不同的情况进行的迭代。实际上线到今天为止，已经把全国 70%-80% 的城市纳入。

③ 数据资产化管理



对于数据资产化管理，我们从底层服务支持上做了扩展，包括数据可管理、权限可管理、资源可管理、数据质量可控：


- 数据权限体系：权限线上化灵活配置，功能数据权限解藕、拆解数据权限，设定行级权限，角色。比如说可以让某个人只看到两室三厅的房子。
- 工作空间：很多公司在搭建大数据体系的时候，资源都是放在一起用的，这样对于公司来讲，很难做到资源管控，成本可控。通过对开发团队的划分，以团队为最小力度进行拆解，把存储资源和计算资源打散切割，基于这个设计，我们可以在资源管控上开展更深的工作，例如监测到不良资产、超级任务等，并且对资源进行弹性设计和隔离。
- 规则引擎：统一构建规则引擎。从平台治理的视角，我们需要识别出各种类型的不合理情况，例如笛卡尔积查询，上万



行的 sql 查询，生命周期的规则，成本分摊规则，计算优化规则等，有正向的，有负向的，有强规则，弱规则，保障平台的运行和可控。

- 元数据管理：将事物可量化，通过评分机制对资产、任务、存储、计算进行评价，形成模型，实现价值的衡量和评估。
- 数据监控、治理：对于数据监控形成事前、事中、事后的全套解决方案。
- IDE：最上层画虚线部分，是开发过程，还没完全做到线上。

④ 数据工厂




数据工厂的演进过程也是从 2018 年底开始，首先做了权限系统的监控，然后希望通过业务的语言了解数据的组织，所以做了元数



据图谱。2019 年相继做了数据开放等，到今年我们将工作空间、规则引擎建设完毕。

⑤ 效果



从效果来说，对于各城市受益最大。数据分析师有更多时间做分析，在效率、质量上都得到保证，从安全上数据能达到不落地。

⑥ 有哪些困难？

在演进的过程中，我们面临如下困难：

- 历史惯性：大家在以往的数据应用上，对于分析师来说，很多内容已经形成基础和规模了，从一种模式到另一种模式是需要很大的迁移成本的。对于用户来说，绝大部分用户是不关注数据怎么给到我，最关心的是数据什么时间能给到我，给我的是否可信。那么一旦换了承载形式，用户会不习惯，



就必须找到一个差异点去引导用户转变。我们在初期，找到了和分析的共鸣-提高数据流转效率，利用这个共鸣点，牵引整个数据体系的建设。

- 组织：如果想在公司中对数据平台、内容的建设上很顺利，组织的适配程度非常重要，一是需要战略上从上至下的顶层设计，另一个是组织在数据应用过程中的关键角色是否存在。例如如何对数据指标口径进行管理，能够拉通平台的数据一致性，服务保障能否联动，都必须在组织层面上达成一致。每个组织的目标，关注点都不同，绝大部分组织更关注业务的变化和增长，数据是辅助的，占比不高，导致数据建设过程协调成本极高。
- 运营：运营是对以上两点的加持，公司在推行数据文化、认知，数据标准化推行，尤其像贝壳，如何对上百的城市达到平台使用的标准化，都是对运营的诉求，非常需要运营去发展。


3. 现在



贝壳现在的平台架构，底层是 hadoop 生态。服务层集成了数据采集，数据开发，数据管理，数据一整套底层服务。上层是应用的建设，包括数据探索，以及轻量化的建模和可视化，以及指标体系能力建设，最终给到用户的内容多端呈现为移动端 app、小程序、大屏、门户。

03

贝壳数据平台的未来构想



贝壳经历多年建设基础，能给用户什么？现在我们将线下数据孤岛整合到线上，还处于现象刻画中，停留在数据使用的基本层次上。未来，希望数据能够智能化，形成知识沉淀，形成数据对话，能指导业务，做出风险预警，同时也要提高分析师素养和培养业务数据应用习惯。



举个例子：



- 从用户感知角度讲，看到的不是一个冰冷的数据，而是可以让用户知道所给数据背后的原因，给出相应的解读。
- 从平台建设角度讲，需要积攒服务厚度，包括服务体系保障、全链路数据监控、数据血缘、指标图谱、归因分析等，在不断沉淀的过程中，可以抽象出来给到用户。


这就是我们整体对未来的规划，从刻画现象到内容解读的过程。

最后，产业互联网和互联网在数据应用上本质上没有什么不同，业务、数据驱动的诉求的场景都是一样的，短时间内，贝壳业务的模式不会发生太大的改变，希望在大数据技术以及产品应用不断发展的今天以及未来，能够打造出一套适用产业互联网的数据产品体系。谢谢大家。

今天的分享就到这里，谢谢大家。



专业数据准备工具的介绍和应用



内容来自：Altair 数据分析团队

出品平台：DataFunTalk

导读：据纽约时报报道，数据科学家在挖掘出有价值的“金块”之前，要花费 50%至 80%的时间在数据准备上。如何更高效地进行数据准备，如何更好地将原始数据转为资产体现价值，如何通过数据将业务和技术紧密结合也是业内热点和难点话题。本文主要通过介绍面向业务用户群体的数据准备过程，聚焦实际应用案例，探讨数据准备工具的企业级应用价值。



01

数据准备工具介绍

1. 数据准备

根据 Gartner 的报告，数据准备是一项必须具备的技术，是一个迭代且灵活的过程，可以用于查找、组合、清理、转换和共享数据集，包括用于分析/商业智能（BI）、数据科学/机器学习（ML）和自主数据集成中。具体来说，数据准备是在处理和分析之前对原始数据进行清洗和转换的过程，通常包括重新格式化数据、更正数据和组合数据集来丰富数据等。

但是对于数据专业人员或业务用户来说，数据准备通常是一项漫长的工作，但同时也是将数据置于上下文环境中的必要前提，以便将其转化为洞察力，并消除由于数据质量差而产生的偏见。

良好的数据准备可以实现高效的分析，减少数据在处理过程中可能出现的错误和不准确性，并使所有处理过的数据更易于用户访问。随着新工具的出现，任何用户都可以更加容易地自己清理数据。

数据准备工具就是这样一类体量轻、适用人群广的专业化工具，能助力业务用户(包括分析师、数据工程师和数据科学家等)为他们的项目案例集成内部和外部数据集，从而保证更快地交付、集



成和管理数据。此外，工具允许用户识别异常和特殊格式，并以可重复的方式改进和审查其发现的数据质量。一些工具嵌入机器学习算法，在某些情况下，可以完全自动化某些可重复和普通的数据准备任务。缩短交付数据和洞察的时间是这个市场的核心。

2. 为什么要有专门的数据准备工具

纽约时报曾有过一篇报道，数据科学家在挖掘出有价值的“金块”之前，要花费 50% 至 80% 的时间在收集数据、准备不规则数据、清理数据的烦冗任务上。没有合适的工具，数据准备将是耗时的、昂贵的、且容易出错的，下面是一些公司在此方面的反馈：

- Blue Hill:

分析师花费 80% 的时间来查找和清理数据，每年每个分析师花费公司 22000 美元。

- Forbes:

88% 手动创建的电子表格包含重大错误。

- IBM:

2016 年，糟糕的数据质量使得美国损失 3.1 万亿美元。

- Harvard Business Review:



大多数企业单位使用小于 50% 的结构化数据和小于 1% 的非结构化数据进行业务决策。

因此，数据准备方案不再是一个可选项任务，它已经变成了数据分析流程中的必选项。同时，在越来越强调团队协作的环境下，企业分工越来越重要。对数据来说，创建社区型的数据市场，一人创建，全体受益的模式，在现代型企业中更受欢迎。

3. 与 ETL 的异同

我们熟知的 ETL 也是包括了数据抽取、数据的清洗转换和数据加载的过程，以此达到将企业中分散凌乱且标准不统一的数据整合在一起，为企业决策提供分析依据的目的。

看到这里可能很多人对于数据准备工具与 ETL 之间的关系充满好奇，甚至觉得我们已经有了完整的 ETL 流程，为什么还需要数据准备工具呢？

如果 ETL 是你日常工作的一部分，那么你就会知道提取、转换和加载有效完成工作所需的关键数据可能需要 1 到 24 个月的时间。作为一名分析师，等待正式的 ETL 流程来访问必要的数据可能会导致项目滞后等问题。

如果不需要等待呢？如果你能在数小时内得到你自己需要的数据呢？你所需要的只是自助数据准备。



如今，分析师 80% 的时间都花在从不同来源提取、清理和准备数据上，但是有了数据准备工具，你就可以花更多时间分析信息以获得重要的业务洞察。

- 用户角色

ETL 工具是为技术用户创建的，而数据准备工具更多的是面向业务用户，例如分析师、销售运营经理、市场经理等各行各业的许多人人都可以使用这些工具。

目前数据准备工具大都设计为可视化的数据表示形式，类似于 Excel 电子表格，用户可以在工作空间的中心看到数据。这允许非技术用户调查数据质量问题、准备数据、验证数据，并查看数据值如何随着应用不同的规则或条件而变化。

- 实际使用

ETL 依赖于一套预先确定的规则和工作流程，需要事先预料到一些潜在的问题，这样就可以将如何处理这些问题的规则构建到工作流中。相反，使用数据准备工具能够在工作流程中直接发现和调查数据。

- 数据复杂性

除了关系型数据源等常见数据来源，数据准备工具在更复杂的数据类型中仍然很强大，例如从 PDF 文件中提取数据等。



总的来说，ETL 和数据准备在概念上相似，解决的是同一个问题，但不同之处在于实际使用方式、数据类型和用户角色等，这些也决定了他们在市场上服务的案例类型。

尽管 ETL 仍然在长期项目中占有一席之地，但自助数据准备可以补充 ETL，为你提供访问关键数据的控制权、所有权、敏捷性和速度，并加快决策制定的时间。

4. 数据准备工具市场

根据 Gartner 预测，到 2022 年，数据准备将成为超过 80% 的数据集成、分析/BI、数据科学、数据工程和数据湖实现平台的关键能力。其中，到 2021 年，那些为用户提供内部和外部准备好的数据分类的企业将比那些不提供企业实现两倍的商业价值。

不久的将来，预计到 2024 年，增强数据准备、数据目录、数据统一、数据虚拟化和数据质量工具将汇聚成一个统一的数据结构，用于大多数新的分析/数据科学项目。

02

实际应用场景和案例



主要结合全球知名的数据准备工具 Altair Monarch™ 介绍在金融领域的应用场景案例。

1. 挑战：减少银行交易中的时间和错误（例如:ATM 机）

银行将每天的 ATM 交易合并成自动生成的文件（通常是电子表格）。每天有成千上万台机器和成千上万条记录，手动对账到余额水平需要数千小时且非常容易出错。

通过数据准备工具可以自动化任务流程，且将每天自动生成的文件附加在一起。无需业务分析师每天花费数小时手动将大量文件加载到数据库中、运行逻辑并与核心银行系统解决方案中的信息进行比较，Monarch 可以在短短几分钟内完成这项任务。数据模型使报告标准化以满足用户和法规的要求，提高运营效率且降低成本。在整个过程中没有加载 ETL，用户可以自己完成数据转换工作，并将最终报告与其他系统/应用程序集成在一起。通过减少花费在手动调节任务上的时间，从银行客户反馈得知，时间成本从每月 3500 小时缩短到 1500 小时。

类似的需要对数据采集、准备和交付等设置大量自动化及周期性任务，比如会计部门的总账、分类账，以及零售银行的申请表、对账单等都可以使用这一解决方案提高终端用户参与的灵活度和高效性。

2. 挑战：减少从数千个数据创建报告时的时间和错误



在企业中，通常有一个集中的文件存储库，半结构化数据（例如：文本、PDF、电子表格）被转储到存储库中。但是不同应用程序之间的报表格式常常不一致，甚至使用相同应用程序创建的报表格式也不一致。

通过数据准备工具和 RPA 的结合，RPA 会自动将数据从总的文件存储库下载到目标文件夹，然后完成从这些文件中批量提取数据。数据准备工具自动将提取的数据转换为符合最终用户和监管要求的标准化报告格式。实际应用于公司得到的反馈为：通过实施该完整的解决方案，其共享服务团队每月在数据提取和数据转换任务上节省了 3000 多个小时，同时最终报告的准确性显著提高。这一方案将帮助用户优化工作流程，并减少了分析师的 300% 所需的 IT 时间。

只要是用户需要手动将数据从文本/PDF 文件中复制到基于电子表格的报表的应用场景，都可以使用这一解决方案节省大量时间并提高准确性，比如用于对账、认证、财务报告、分录、监管备案等。

03

数据准备工具 Altair Monarch™



Altair Monarch™ 是 Altair 数据产品中的数据准备工具，已有三十年的历史。利用 Monarch 可从多种数据来源中快速、简单地提取需要的数据，包括将非结构化数据，如 PDF、文本、网页等，转化为行与列的结构化数据。提取数据后，用户可以在无需编码和基于鼠标点击的方法下进行数据的清理、转换、合并、去重等工作，并且可以导出到任何的数据分析平台或者 BI 工具进行进一步的操作。

2020 年 12 月，Altair Monarch 在 Gartner Peer Insights 数据准备工具评选中荣获“客户之选”称号，在总分为 5 的综合评分中获得 4.5 分的认可。该称号的评选会对工具的多项指标进行综合评分，包括整体评级、供应商比较、针对公司规模、行业和区域的客户选择等，Monarch 在数据准备领域已经获得了众多客户的青睐和来自业界的认可。





使用 Monarch，任何人都可以做到：

- 从多源异构中提取数据，如 PDF、文本、网页等；
- 将非结构化、半结构化和多结构化的数据转换为行与列；
- 使用预先构建的功能进行数据清理，不需要任何编码；
- 记录数据处理的每一步操作，形成命令流文件，对后续同类的文件做到自动化处理，无需手工重复操作；
- 对转换好的行与列数据，进行合并、去重、转置等操作；
- 导出结构化文件到各种数据分析，可视化工具进行下一步的操作。

访问 • Excel • CSV • PDF • TXT • XML • JSON • HTML • Web Scraping • ODBC/OLE DB Compliant Systems • Relational Databases • Line-of-Business Applications • Big Data/NoSQL	清理 • 80+Pre-Built Data Prep Functions • Pivot/Unpivot • Transpose • Group • Sort • Dedupe • Replace • Merge • Filter • Fix Case • Split Address • Strip Characters • Calculated Fields
合并 • Inner & Outer joins • Negative joins • Lookups • Appends	分析 • Reusable Summary Views • Totals & Subtotals
导出 • Excel • CSV • Altair Knowledge Hub • BI/Visualization Tools	审核 • Change History • Data Lineage
	自动化 • Edata Extraction Models • Reusable Workspaces



Altair Monarch 的专业、高效、灵活、极易上手等特征使其被国内外众多知名企业青睐，包括：

- 万事达卡、花旗、汇丰、摩根大通等金融客户（信用风险、市场分析、财务报表等）；
- 辉瑞、联合健康集团等医疗健康客户（收支周期管理、文件处理等）；
- 政府部门（内审、外审、PDF 文件转换等）；
- 麦格纳、福特等制造业客户（HR、交易对账、财务等）。